

HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

GRADUATION THESIS

**CogMem: Khung bộ nhớ hội thoại dài hạn dựa trên
Khoa học nhận thức**

Lê Minh Triết

triet.lm220045@sis.hust.edu.vn

Program: IT1

Supervisor: Cao Tuấn Dũng

Department: Computer Science

School: School of Information and Communications Technology

HANOI, 06/2026

HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

GRADUATION THESIS

**CogMem: Khung bộ nhớ hội thoại dài hạn dựa trên
Khoa học nhận thức**

Lê Minh Triết

triet.lm220045@sis.hust.edu.vn

Program: IT1

Supervisor: Cao Tuấn Dũng _____

Signature

Department: Computer Engineering

School: School of Information and Communications Technology

HANOI, 06/2026

ACKNOWLEDGMENT

Trước hết, tôi xin bày tỏ lòng biết ơn sâu sắc đến Thầy Cao Tuấn Dũng — người đã trực tiếp hướng dẫn và hỗ trợ tôi trong suốt quá trình thực hiện đồ án tốt nghiệp. Thầy không chỉ truyền đạt kiến thức chuyên môn mà còn là người thầy định hướng cho tôi về cách tiếp cận vấn đề một cách khoa học và có phương pháp, cũng như là người khơi gợi những ý tưởng đầu tiên của tôi về đồ án này.

Tôi cũng xin cảm ơn các thầy cô trong Khoa Kỹ thuật Máy tính, Trường Đại học Bách khoa Hà Nội, đã trang bị cho tôi nền tảng kiến thức vững chắc trong suốt bốn năm học tại đây.

TÓM TẮT

Agent hội thoại dài hạn không chỉ cần một cửa sổ ngữ cảnh lớn. Hệ thống còn phải lưu giữ thông tin người dùng qua nhiều phiên, nối lại các mảnh bằng chứng phân tán, và trả lời những câu hỏi phụ thuộc vào thời gian, sở thích, quan hệ nhân quả hoặc suy luận nhiều bước. Các hướng tiếp cận chỉ dựa vào vector retrieval hoặc tóm tắt nén mạnh thường chưa đủ, vì chúng dễ làm phẳng các loại ký ức khác nhau và làm mất dấu các chi tiết gốc quan trọng.

Đề án này trình bày **CogMem**, một kiến trúc bộ nhớ dài hạn cho agent hội thoại được thiết kế theo hướng cognitive graph. Ở mức tổng quan, CogMem theo đuổi ba ý tưởng chính: tổ chức trí nhớ thành các nhóm biểu diễn chuyên biệt thay vì một kho fact phẳng, giữ lại dấu vết bằng chứng gốc để hỗ trợ trả lời có grounding tốt hơn, và cải thiện truy hồi bằng cách cộng dồn tín hiệu hội tụ trên đồ thị thay vì chỉ giữ một đường mạnh nhất. Hệ thống cũng định tuyến truy vấn theo ý định câu hỏi để ưu tiên đúng loại bằng chứng cần thiết.

Các đánh giá trong báo cáo cho thấy hướng tiếp cận này có chiều hướng cải thiện tích cực so với baseline mạnh trên những tình huống cần gom bằng chứng qua nhiều phiên hoặc cần phân biệt rõ hơn giữa quan hệ sở thích, kế hoạch và nhân quả. Điểm mạnh nổi bật của CogMem nằm ở cách kết hợp recall đa kênh với cấu trúc biểu diễn giàu quan hệ hơn, từ đó đưa bằng chứng phù hợp lên sớm hơn trong ngữ cảnh trả lời.

Tuy vậy, kết quả cũng cho thấy dư địa cải thiện vẫn còn rõ rệt ở các truy vấn đòi hỏi temporal reasoning rất chính xác, liệt kê đầy đủ nhiều mục, hoặc kiểm chứng sâu hơn vai trò của các tín hiệu habit trên workload thực tế. Vì vậy, CogMem nên được xem như một bước tiến có định hướng rõ ràng cho long-term memory API hơn là một lời giải đã hoàn tất.

Lê Minh Triết

triet.lm220045@sis.hust.edu.vn

TABLE OF CONTENTS

CHAPTER 1. INTRODUCTION.....	1
1.1 Giới thiệu bài toán	1
1.1.1 Bối cảnh và vấn đề	1
1.1.2 Hạn chế của các giải pháp hiện tại	1
1.1.3 Động lực và đóng góp của đề án.....	2
1.1.4 Cấu trúc của đề án	3
CHAPTER 2. LITERATURE REVIEW	4
2.1 Tổng quan Lý thuyết và Các hệ thống liên quan	4
2.1.1 Thách thức cốt lõi về Bộ nhớ của Mô hình Ngôn ngữ Lớn (LLMs) .	4
2.1.2 Cơ sở Lý thuyết: Khoa học Nhận thức và Đồ thị Tri thức	4
2.1.3 Tiến trình phát triển hệ thống Bộ nhớ Dài hạn cho Tác nhân	5
2.1.4 Dữ liệu đánh giá (Evaluation Benchmarks).....	7
2.1.5 Hạn chế cốt lõi của các Khung hệ thống Bộ nhớ hiện nay (Problem Formulation)	7
CHAPTER 3. METHODOLOGY.....	9
3.1 Phương pháp đề xuất.....	9
3.1.1 Tổng quan kiến trúc hệ thống CogMem.....	9
3.1.2 Đóng góp 1: Đồ thị Bộ nhớ Kế thừa Nhận thức (Cognitively- Grounded Memory Graph).....	11
3.1.3 Đóng góp 2: Siêu dữ liệu Node phi tổn hao (Lossless Node Metadata) và Raw Snippet	15
3.1.4 Đóng góp 3: Episodic Buffer với SUM Spreading Activation + Cycle Guards	16
3.1.5 Đóng góp 4: Adaptive Query Routing	19

CHAPTER 4. THEORETICAL ANALYSIS	22
4.1 Phân tích lý thuyết	22
4.1.1 Cơ sở khoa học nhận thức cho Memory Graph (6 Networks).....	22
4.1.2 Cơ sở khoa học nhận thức cho Raw Snippet.....	26
4.1.3 Cơ sở khoa học nhận thức cho SUM + Cycle Guards	27
4.1.4 Cơ sở khoa học nhận thức cho Adaptive Query Routing	28
CHAPTER 5. NUMERICAL RESULTS.....	29
5.1 Kết quả thực nghiệm	29
5.1.1 Thiết kế đánh giá	29
5.1.2 LongMemEval.....	30
5.1.3 So sánh hiệu năng retain	32
5.1.4 LoCoMo	33
5.1.5 Các nhóm cải thiện chính.....	33
5.1.6 Phân tích lỗi	34
5.1.7 Kết luận từ thực nghiệm.....	34
CHAPTER 6. CONCLUSIONS	36
6.1 Kết luận và hướng phát triển	36
6.1.1 Tổng kết đóng góp.....	36
6.1.2 Kết quả chính	36
6.1.3 Hạn chế.....	37
6.1.4 Hướng phát triển	37
REFERENCE	40
CHAPTER A. Knowledge Extraction Prompts (Retain Pipeline).....	41
A.0.1 A.1. Prompt Trích xuất Pass 1 (Fact Extraction)	41
A.0.2 A.2. Prompt Tinh chỉnh Pass 2 (Persona-Focused Revision)	42

CHAPTER B. Evaluation and Reflection Prompts.....	43
B.0.1 B.1. Prompt Tổng hợp Câu trả lời (Reflection & Generation).....	43
B.0.2 B.2. Prompt Chấm điểm Tự động (LLM-as-a-Judge).....	43

LIST OF FIGURES

Figure 3.1	Tổng quan pipeline CogMem: hội thoại được retain thành memory graph, sau đó recall đa kênh và synthesis dựa trên evidence để trả lời truy vấn.	9
Figure 3.2	Sáu mạng bộ nhớ của CogMem	12
Figure 3.3	Phân biệt Habit và Action-Effect	14
Figure 3.4	Bảy loại liên kết trong CogMem	15
Figure 3.5	2-Layer Node Schema	16
Figure 3.6	Ba cơ chế bảo vệ chu trình	18
Figure 3.7	Adaptive Query Routing	20
Figure 4.1	Semantic Memory và World Network	22
Figure 4.2	Một workload diary nhiều tuần phù hợp hơn để kiểm tra Habit Network so với benchmark chỉ hỏi fact đơn lẻ.	23
Figure 4.3	Habit Memory và Habit Network	24
Figure 4.4	Intention Lifecycle	25
Figure 4.5	Action-effect phù hợp với trace AI agent thật, nơi hệ thống cần nhớ quan hệ giữa điều kiện lỗi, hành động tool và kết quả quan sát được.	26
Figure 4.6	Theory of Event Coding và Action-Effect Network	26
Figure 4.7	Fuzzy Trace Theory và Raw Snippet	27
Figure 4.8	Episodic Buffer của Baddeley	27
Figure 4.9	Attentional Selection và Adaptive Routing	28
Figure 5.1	Luồng đánh giá trong báo cáo: benchmark question và gold answer được chạy qua CogMem, câu trả lời sinh ra được chấm bằng LLM-as-a-judge, sau đó tổng hợp thành kết quả theo category. . . .	29

LIST OF TABLES

Table 2.1	So sánh khái quát các hệ thống bộ nhớ dài hạn liên quan . . .	6
Table 3.1	Các fact type cốt lõi và metadata chuyên biệt	13
Table 3.2	So sánh HINDSIGHT (MAX) và CogMem (SUM)	17
Table 3.3	Adaptive RRF weights theo query type trong implementation hiện tại	20
Table 4.1	Intention lifecycle và typed transition semantics	24
Table 5.1	Thiết lập đánh giá cuối cùng	30
Table 5.2	LongMemEval judge results theo cấu hình recall và node type	30
Table 5.3	Graph-only LongMemEval: SUM reducer so với MAX control	31
Table 5.4	So sánh hiệu năng retain trung bình trên một conversation . .	32
Table 5.5	LoCoMo full-run PASS	33
Table 5.6	LoCoMo category breakdown theo PASS	33

CHAPTER 1. INTRODUCTION

1.1 Giới thiệu bài toán

1.1.1 Bối cảnh và vấn đề

Các tác nhân hội thoại hiện đại đã đạt tiến bộ rõ rệt ở những tác vụ ngắn hạn như trả lời câu hỏi, lập kế hoạch theo từng phiên làm việc, hay tương tác dựa trên một cửa sổ ngữ cảnh lớn. Tuy nhiên, khi tương tác kéo dài qua nhiều ngày hoặc nhiều phiên hội thoại, hạn chế cốt lõi vẫn nằm ở khả năng duy trì *bộ nhớ dài hạn* một cách có cấu trúc và có thể truy hồi. Khi số lượng token vượt khỏi cửa sổ ngữ cảnh, thông tin từ các phiên trước dần bị loại bỏ; hệ quả là tác nhân mất dấu lịch sử người dùng, các mốc thời gian, các sở thích lặp lại và cả những kế hoạch còn dang dở.

Vấn đề này đặc biệt quan trọng trong các ứng dụng cần tính liên tục cao như trợ lý cá nhân, hệ thống chăm sóc khách hàng, tác nhân hỗ trợ học tập, hay các AI companion được kỳ vọng đồng hành lâu dài cùng một người dùng. Trong những bối cảnh đó, bộ nhớ không chỉ là khả năng “nhớ lại một câu đã nói”, mà còn là năng lực tái sử dụng các sự kiện, mối liên hệ và tín hiệu hành vi dưới một dạng biểu diễn đủ bền vững để phục vụ cho truy vấn tương lai.

1.1.2 Hạn chế của các giải pháp hiện tại

Các hướng tiếp cận phổ biến cho bài toán bộ nhớ dài hạn thường rơi vào một trong hai cực: (1) lưu trữ văn bản thô rồi truy xuất bằng vector similarity, hoặc (2) nén hội thoại thành các “fact” gọn hơn để lưu trong đồ thị hoặc cơ sở dữ liệu vector. Cả hai hướng đều hữu ích, nhưng vẫn để lộ nhiều giới hạn thực dụng:

- **Nén có tổn hao (lossy compression):** Khi LLM rút gọn hội thoại thành các fact ngắn, nhiều chi tiết định lượng, sắc thái cảm xúc, hoặc ngữ cảnh nguyên bản bị mất đi và khó khôi phục về sau.
- **Biểu diễn phẳng hoặc bán-phẳng:** Nếu mọi fact đều bị đưa vào cùng một không gian biểu diễn, hệ thống khó phân biệt giữa kiến thức khách quan, sự kiện cá nhân, thói quen, kế hoạch tương lai và quan hệ nhân quả.
- **Truy hồi đa bước còn yếu:** Những câu hỏi cần nối nhiều tín hiệu yếu, nhiều phiên hội thoại, hoặc nhiều loại quan hệ khác nhau thường không được xử lý tốt bởi retrieval đơn thuần dựa trên một kênh.
- **Định tuyến truy vấn còn tĩnh:** Một câu hỏi temporal, causal hay prospective không nên được đối xử giống hệt một câu hỏi semantic. Việc dùng một profile truy hồi đồng nhất cho mọi loại truy vấn làm giảm hiệu quả của từng channel

chuyên biệt.

Các phân tích và thí nghiệm nhắm đích sau này trong dự án cũng gợi ý thêm một điểm quan trọng: ngay cả khi mở rộng hệ thống bằng các mạng bộ nhớ chuyên biệt, giá trị của từng mạng không phải lúc nào cũng xuất hiện đồng đều trên mọi benchmark. Nói cách khác, bài toán không chỉ là “thêm nhiều node type hơn”, mà là thiết kế một biểu diễn đủ đúng để những loại tín hiệu như habit, intention hay action-effect thật sự có nơi tồn tại và được truy hồi đúng lúc.

1.1.3 Động lực và đóng góp của đề án

Từ các giới hạn trên, đề án này đề xuất **CogMem** – một khung bộ nhớ hội thoại dài hạn dựa trên khoa học nhận thức (*cognitive science*) và đồ thị tri thức dị thể. Điểm xuất phát của CogMem là quan sát rằng bộ nhớ người không vận hành như một danh sách phẳng; thay vào đó, các loại ký ức khác nhau được tổ chức thành những hệ con có vai trò khác nhau trong hành vi và suy luận.

Theo tinh thần đó, CogMem tập trung vào bốn đóng góp cốt lõi:

1. **Cognitively-Grounded Memory Graph:** Tổ chức bộ nhớ thành sáu mạng fact chính – *world, experience, opinion, habit, intention, action_effect* – cùng bảy loại liên kết để duy trì cấu trúc quan hệ rõ ràng.
2. **Lossless Node Metadata:** Bảo toàn *raw_snippet* như phần văn bản gốc đi kèm mỗi node, giúp giảm mất mát thông tin giữa giai đoạn lưu trữ và giai đoạn sinh câu trả lời.
3. **Episodic Buffer với SUM Spreading Activation:** Dùng phép cộng tín hiệu thay cho phép chọn cực đại, kết hợp các cơ chế kiểm soát chu trình để truy hồi được bằng chứng phân tán qua nhiều đường.
4. **Adaptive Query Routing:** Phân loại truy vấn thành các nhóm semantic, temporal, causal, prospective, preference và multi-hop; từ đó áp dụng profile dung hợp phù hợp cho từng loại.

Trong báo cáo này, bốn đóng góp trên được trình bày như **kiến trúc luận án cốt lõi** của CogMem. Các thí nghiệm nhắm đích thực hiện về sau trong dự án cho thấy các mạng bộ nhớ chuyên biệt như *intention* và *action_effect* không tạo lợi thế đồng đều trên mọi tình huống; thay vào đó, chúng đặc biệt hữu ích khi tín hiệu kế hoạch hoặc quan hệ nhân quả không thể được hấp thụ tự nhiên bởi các fact type khác như *world* hoặc *experience*. Kết luận này làm cho động lực của CogMem thận trọng hơn, nhưng cũng thực tế hơn: các cấu trúc nhận thức mới không phải là “thuốc chữa bách bệnh”, mà là những representational slots cần thiết cho các lớp câu hỏi nhất định.

1.1.4 Cấu trúc của đề án

Đề án được tổ chức như sau:

- **Chương 2:** Literature Review – tổng quan các hướng tiếp cận bộ nhớ dài hạn, cơ sở khoa học nhận thức, đồ thị tri thức và các benchmark liên quan.
- **Chương 3:** Methodology – mô tả kiến trúc CogMem, retain pipeline, recall pipeline và bốn đóng góp cốt lõi của hệ thống.
- **Chương 4:** Theoretical Analysis – phân tích cơ sở nhận thức cho các memory networks, raw snippet, SUM spreading activation và adaptive routing.
- **Chương 5:** Numerical Results – trình bày kết quả thực nghiệm và các phân tích định lượng.
- **Chương 6:** Conclusions – tổng kết đóng góp, hạn chế và hướng phát triển.

Sau khi xác định bài toán và động lực của CogMem, Chương 2 sẽ hệ thống hóa nền tảng lý thuyết và các hệ thống liên quan nhằm làm rõ khoảng trống mà kiến trúc đề xuất cần lấp đầy.

CHAPTER 2. LITERATURE REVIEW

Tiếp nối bối cảnh bài toán từ Chương 1, chương này tổng hợp nền tảng khoa học nhận thức, đồ thị tri thức và các hệ thống bộ nhớ dài hạn liên quan, từ đó xác định rõ khoảng trống mà CogMem hướng tới.

2.1 Tổng quan Lý thuyết và Các hệ thống liên quan

Chương này tập trung vào hai trụ cột: (1) khoa học nhận thức như một nguồn cảm hứng cho việc chuyên biệt hóa các loại ký ức, và (2) đồ thị tri thức như một hình thức biểu diễn cho phép truy hồi đa bước có kiểm soát. Trên nền tảng đó, chúng tôi đối chiếu các hệ thống bộ nhớ đương đại để chỉ ra những hạn chế còn tồn tại về nén thông tin, tổ chức fact type và định tuyến truy vấn.

2.1.1 Thách thức cốt lõi về Bộ nhớ của Mô hình Ngôn ngữ Lớn (LLMs)

Mặc dù các Mô hình Ngôn ngữ Lớn (LLMs) đạt thành tựu cao trong xử lý ngôn ngữ tự nhiên, chúng vẫn gặp những giới hạn cơ bản khi phải duy trì ký ức dài hạn cho một người dùng hoặc một agent cụ thể:

- **Giới hạn cửa sổ ngữ cảnh:** Đưa toàn bộ lịch sử hội thoại dài hạn vào prompt là tốn kém và không bền vững. Khi lịch sử tăng lên, hệ thống buộc phải chọn lọc hoặc bỏ bớt thông tin.
- **Hiện tượng mất tín hiệu ở ngữ cảnh dài:** Các nghiên cứu về “lost in the middle” cho thấy thông tin ở giữa cửa sổ ngữ cảnh thường khó được sử dụng ổn định bằng thông tin ở đầu hoặc cuối.
- **Thiếu grounding dài hạn:** Nếu không có một bộ nhớ ngoài được tổ chức tốt, mô hình dễ sinh câu trả lời dựa trên xác suất ngôn ngữ thay vì bằng chứng đã quan sát.
- **Khó cập nhật liên tục:** Fine-tuning không phải là cơ chế phù hợp để tiếp nhận dòng hội thoại cá nhân hóa theo thời gian thực; bộ nhớ ngoài là hướng thực tế hơn cho bài toán này.

Vì vậy, bộ nhớ dài hạn cho tác nhân hội thoại nên được xem như một *hệ thống ngoài mô hình (external memory system)* với cấu trúc lưu trữ, truy hồi và tổng hợp riêng, thay vì chỉ là phần kéo dài của context window.

2.1.2 Cơ sở Lý thuyết: Khoa học Nhận thức và Đồ thị Tri thức

a, Khoa học Nhận thức và Hệ thống Phân loại Bộ nhớ

Một điểm then chốt của khoa học nhận thức là bộ nhớ người không phải một khối đơn nhất. Theo các phân loại cổ điển của Tulving, Squire và các cộng sự, bộ

nhớ dài hạn bao gồm nhiều hệ con với vai trò và nền tảng thần kinh khác nhau:

- **Semantic memory:** lưu trữ kiến thức chung, tương đối độc lập với ngữ cảnh cụ thể.
- **Episodic memory:** lưu trữ các sự kiện cá nhân gắn với thời gian và trải nghiệm.
- **Habit / procedural memory:** gắn với các mẫu hành vi lặp lại và phản xạ hành động.
- **Prospective memory:** liên quan tới việc “nhớ để làm” trong tương lai, tức các kế hoạch và mục tiêu chưa hoàn tất.

Ý tưởng cốt lõi rút ra cho hệ thống AI là: nếu nhiều loại tín hiệu nhận thức có bản chất khác nhau, chúng không nên bị ép vào cùng một kiểu biểu diễn phẳng. Đây chính là động lực cho kiến trúc nhiều fact type của CogMem.

b, Đồ thị Tri thức (Knowledge Graphs) và Chức năng Biểu diễn

Đồ thị tri thức (Knowledge Graph - KG) cho phép biểu diễn các thực thể và quan hệ của chúng dưới dạng cấu trúc tường minh. So với một kho vector thuần túy, KG có hai lợi thế quan trọng:

- **Biểu diễn quan hệ hiện hình:** Quan hệ thời gian, nhân quả, đồng tham chiếu thực thể hay chuyển pha trạng thái có thể được lưu trực tiếp bằng edge thay vì phải suy ngược hoàn toàn từ tương đồng ngữ nghĩa.
- **Truy hồi đa bước:** KG hỗ trợ các thuật toán đi đồ thị, spreading activation và các dạng kết hợp tín hiệu xuyên nhiều node, phù hợp với các câu hỏi multi-hop hoặc cross-session.

Với các bài toán bộ nhớ hội thoại, KG đặc biệt hữu ích khi thông tin trả lời không nằm gọn trong một câu duy nhất mà bị phân tán qua nhiều phiên, nhiều sự kiện hoặc nhiều loại fact khác nhau.

2.1.3 Tiến trình phát triển hệ thống Bộ nhớ Dài hạn cho Tác nhân

a, HINDSIGHT: Đồ thị dị thể và truy hồi đa kênh

HINDSIGHT là một trong những hệ thống đáng chú ý nhất trong dòng bộ nhớ dài hạn dạng đồ thị cho agent hội thoại. Ở mức khái niệm, HINDSIGHT kết hợp:

- fact extraction từ hội thoại,
- lưu trữ dưới dạng heterogeneous graph,
- truy hồi song song trên nhiều channel như semantic, BM25, graph và temporal,

- và dung hợp bằng Reciprocal Rank Fusion (RRF).

Đóng góp lớn của HINDSIGHT là chứng minh rằng bộ nhớ dạng đồ thị có thể vượt xa vector store thuần trong các bài toán hội thoại dài. Tuy nhiên, khi nhìn từ góc độ kiến trúc, HINDSIGHT vẫn để lộ một số giới hạn mà CogMem muốn giải quyết:

- chưa có các typed network riêng cho *habit*, *intention* và *action_effect*,
- chiến lược fusion mặc định dùng profile trọng số tĩnh cho mọi loại truy vấn,
- và lan truyền kích hoạt kiểu lấy cực đại khiến bằng chứng yếu từ nhiều đường khó cộng dồn.

b, HippoRAG2: Truy hồi đồ thị nhấn mạnh liên kết tri thức

HippoRAG2 thể hiện hướng đi nổi bật ở phía graph retrieval, đặc biệt trong các bài toán cần liên kết nhiều thực thể hoặc nhiều facts rời nhau. Ưu điểm của dòng tiếp cận này là biến truy hồi thành một quá trình lan truyền tín hiệu trên topology của đồ thị thay vì chỉ dựa vào embedding similarity.

Tuy nhiên, các hệ thống kiểu HippoRAG2 vẫn chủ yếu mạnh ở lớp quan hệ ngữ nghĩa và liên kết tri thức, trong khi những cấu trúc như kế hoạch tương lai, thói quen hành vi hay bộ ba nhân quả hành động-kết quả chưa được mô hình hóa như các memory network chuyên biệt.

c, Các hệ lưu trữ phẳng và vector-centric (Mem0, MemGPT)

Bên cạnh nhánh đồ thị, nhiều hệ thống khác chọn cách lưu fact hoặc chunk trong vector store và tổ chức truy hồi quanh similarity search hoặc memory paging:

- **Mem0**: nhấn mạnh extraction + vector retrieval, phù hợp với memory lookup nhanh nhưng hạn chế hơn khi cần quan hệ nhiều bước.
- **MemGPT**: mô phỏng phân tầng bộ nhớ theo kiểu hệ điều hành, tách vùng context đang hoạt động và vùng lưu trữ ngoài.

Các hướng này hữu ích về mặt vận hành, nhưng khi đánh giá theo nhu cầu của hội thoại dài hạn, chúng thường thiếu topology đủ rõ để mô hình hóa temporal chains, causal links hay lifecycle của kế hoạch chưa hoàn thành.

Table 2.1: So sánh khái quát các hệ thống bộ nhớ dài hạn liên quan

Hệ thống	Graph-based	Temporal	Habit	Intention	Action-Effect	Cơ chế truy hồi chính
HINDSIGHT	Yes	Yes	No	No	No	4-channel retrieval + equal-weight RRF
HippoRAG2	Yes	Limited	No	No	No	Graph retrieval / spreading activation
Mem0	No	Limited	No	No	No	Vector similarity + extracted memories
MemGPT	No	Limited	No	No	No	Memory paging / context management
CogMem (đề xuất)	Yes	Yes	Yes	Yes	Yes	Adaptive routing + BFS/SUM graph recall

2.1.4 Dữ liệu đánh giá (Evaluation Benchmarks)

a, LongMemEval-S (Hội thoại đa phiên)

LongMemEval-S là benchmark phù hợp để đánh giá khả năng xử lý hội thoại dài qua nhiều phiên, đặc biệt ở các nhóm câu hỏi liên quan tới multi-session retrieval, temporal reasoning và preference. Đây là benchmark quan trọng để đo hiệu năng hệ thống ở cấp end-to-end.

b, LoCoMo (Lý luận multi-hop)

LoCoMo tập trung mạnh hơn vào truy hồi nhiều bước và nối bằng chứng qua các đoạn hội thoại dài. Vì vậy, benchmark này đặc biệt hữu ích để quan sát khả năng giữ mạch reasoning khi thông tin trả lời không nằm trọn trong một fact riêng lẻ.

c, Giới hạn của benchmark chuẩn

LongMemEval-S và LoCoMo là các benchmark hệ thống rất cần thiết, nhưng chúng không phải lúc nào cũng đủ để cô lập giá trị của từng typed network mới. Trong quá trình phát triển CogMem, điều này dẫn tới nhu cầu bổ sung các thí nghiệm nhắm đích để kiểm tra riêng những dạng tín hiệu như prospective memory hoặc action-effect reasoning. Trong báo cáo này, nhận định đó chỉ được dùng như bối cảnh phương pháp luận; phần thực nghiệm chính thức vẫn được trình bày ở Chương 5.

2.1.5 Hạn chế cốt lõi của các Khung hệ thống Bộ nhớ hiện nay (Problem Formulation)

Từ tổng quan trên, có thể quy các khoảng trống chính của các hệ bộ nhớ đương đại về bốn nhóm:

1. **Lossy compression:** fact extraction làm gọn bộ nhớ nhưng dễ đánh mất số liệu, cảm xúc và văn bản gốc cần cho generation.
2. **Thiếu typed cognitive structures:** các tín hiệu như habit, intention hay action-effect thường không có “chỗ ở” riêng trong mô hình dữ liệu.
3. **Lan truyền bằng chứng chưa đủ giàu:** retrieval kiểu chỉ chọn đường mạnh nhất có thể làm rơi mất nhiều tín hiệu yếu nhưng bổ sung cho nhau.
4. **Định tuyến truy vấn còn cào bằng:** cùng một recipe fusion được áp cho semantic, temporal, causal hay prospective queries, dù bản chất truy hồi của chúng khác nhau.

Từ khoảng trống lý thuyết và kỹ thuật đó, Chương 3 sẽ trình bày CogMem như một

kiến trúc bộ nhớ dài hạn nhằm kết hợp biểu diễn nhận thức chuyên biệt với cơ chế truy hồi thích ứng theo loại truy vấn.

CHAPTER 3. METHODOLOGY

Dựa trên các giới hạn đã phân tích ở Chương 2, chương này trình bày kiến trúc phương pháp luận cốt lõi của CogMem: một hệ thống bộ nhớ hội thoại dài hạn dựa trên đồ thị dị thể, retain pipeline nhiều bước và recall pipeline có định tuyến thích ứng.

3.1 Phương pháp đề xuất

3.1.1 Tổng quan kiến trúc hệ thống CogMem

CogMem được thiết kế như một kiến trúc gồm ba pipeline liên tiếp:

1. **Retain pipeline:** chuẩn hóa hội thoại, trích xuất fact, sinh embedding, lưu node và tạo liên kết.
2. **Recall pipeline:** chạy song song nhiều kênh truy hồi, phân tích loại truy vấn, rồi dung hợp kết quả theo profile phù hợp.
3. **Reflect / Synthesis pipeline:** tổng hợp evidence được recall để sinh câu trả lời bám dữ kiện.




Figure 3.1: Tổng quan pipeline CogMem: hội thoại được retain thành memory graph, sau đó recall đa kênh và synthesis dựa trên evidence để trả lời truy vấn.

Trong phạm vi luận án này, **BFS graph retrieval** với **SUM spreading activation** và **ba cycle guards** được xem là đường triển khai chuẩn của CogMem. Một số retriever khác được thêm vào ở các giai đoạn phát triển sau nhằm phục vụ nghiên cứu và ablation, nhưng không thay đổi lõi phương pháp luận được trình bày

ở đây.

a, Phạm vi và giả định triển khai

Để giữ phần methodology trung thực, cần phân biệt rõ giữa *ý tưởng kiến trúc* và *đường triển khai được đánh giá trong luận án*. CogMem không giả định rằng mọi fact type đều luôn cần thiết trong mọi dữ liệu, và cũng không giả định rằng LLM extraction luôn phân loại đúng. Thay vào đó, hệ thống được thiết kế để cung cấp một cấu trúc biểu diễn giàu hơn bộ nhớ phẳng, rồi kiểm tra thực nghiệm xem cấu trúc đó giúp ích trong những loại câu hỏi nào.

Các giả định triển khai chính gồm:

- Fact extraction vẫn phụ thuộc vào LLM, vì vậy typed node có thể bị thiếu, bị gộp hoặc bị re-typed thành fact type khác.
- Graph recall không thay thế semantic/BM25 retrieval; trong evaluation cuối, multi-channel recall mới là cấu hình chính.
- *raw_snippet* được giữ như bằng chứng nguyên văn, nhưng generation có dùng trực tiếp snippet hay không phụ thuộc vào policy của từng run.
- Các fact type như *habit*, *intention* và *action_effect* nên được hiểu là các slot biểu diễn có điều kiện, không phải các module luôn tạo uplift độc lập.

Do đó, đóng góp của chương này là mô tả một methodology có thể kiểm chứng: retain tạo typed memory graph, recall dùng nhiều kênh để lấy evidence, và reflect sinh câu trả lời dựa trên evidence đó. Các claims mạnh hơn về tác động của từng fact type phải được rút ra từ Chương 5, không được mặc định từ thiết kế.

b, Retain pipeline

Retain pipeline hiện thực hóa bộ nhớ dài hạn theo chuỗi bước sau:

1. **Chunking theo hội thoại:** hội thoại được chia thành các đoạn phù hợp cho extraction.
2. **Pass 1 extraction:** LLM đọc ngữ cảnh mixed-speaker để trích xuất đủ sáu fact type, đặc biệt là *world* và *action_effect*.
3. **Pass 2 extraction:** một pass persona-focused đọc lại ngữ cảnh người dùng để tinh chỉnh các fact cá nhân như *experience*, *habit*, *intention* và *opinion*.
4. **Dedup và chuẩn hóa metadata:** hợp nhất kết quả giữa các pass, chuẩn hóa status, quan hệ chuyển pha và trường metadata chuyên biệt.
5. **Embedding + storage:** mỗi fact được gắn embedding và lưu vào đồ thị bộ nhớ cùng *raw_snippet*.

6. **Link creation:** tạo các liên kết entity, temporal, semantic, causal, s_r_link, a_o_causal và transition.

Điểm quan trọng là retain pipeline không chỉ lưu một câu tóm tắt ngữ nghĩa, mà còn bảo toàn văn bản nguồn để phục vụ giai đoạn sinh câu trả lời về sau.

c, Recall pipeline

Recall pipeline của CogMem chạy song song bốn kênh:

- semantic retrieval,
- BM25 retrieval,
- graph retrieval,
- temporal retrieval.

Trước khi fusion, hệ thống phân tích truy vấn để xác định *query type* và *temporal constraint* nếu có. Kết quả phân tích này quyết định:

- fact types nào cần ưu tiên,
- profile trọng số RRF nào cần dùng,
- và có cần hậu xử lý đặc biệt cho bằng chứng prospective hoặc causal hay không.

d, Reflect / Synthesis pipeline

Sau khi recall hoàn tất, hệ thống chọn top evidence để đưa vào prompt sinh câu trả lời. Trong luồng này, *raw_snippet* đóng vai trò là lớp bằng chứng nguyên văn. Tùy cấu hình của giai đoạn sinh, snippet có thể được đưa thẳng vào prompt hoặc chỉ được giữ như nguồn tham chiếu nội bộ; tuy nhiên, ở mức kiến trúc, trường *raw_snippet* luôn được bảo toàn end-to-end để tránh mất dữ kiện.

3.1.2 Đóng góp 1: Đồ thị Bộ nhớ Kế thừa Nhận thức (Cognitively-Grounded Memory Graph)

a, Nền tảng tâm lý

Động lực của CogMem đến từ quan sát rằng bộ nhớ người không phải một kho đồng nhất. Các nhóm ký ức như semantic memory, episodic memory, habit memory, prospective memory hay action-effect binding có vai trò khác nhau trong suy luận và hành vi. Vì vậy, việc ép mọi dữ liệu hội thoại vào cùng một dạng fact sẽ làm suy yếu tính phân biệt về chức năng.

CogMem chuyển trực giác này thành một memory graph dị thể gồm nhiều fact type chuyên biệt. Mỗi network không chỉ khác nhau về nhãn, mà còn khác nhau ở metadata, loại liên kết, và chiến lược truy hồi được ưu tiên khi đối mặt với từng

loại câu hỏi.




Figure 3.2: Sáu mạng bộ nhớ của CogMem

b, Sáu mạng bộ nhớ

CogMem hiện dùng sáu fact type cốt lõi:

1. **World:** kiến thức khách quan hoặc tương đối ổn định về thế giới.
2. **Experience:** sự kiện cá nhân đã xảy ra, thường gắn với thời gian hoặc bối cảnh cụ thể.
3. **Opinion:** nhận định, sở thích hoặc đánh giá chủ quan.
4. **Habit:** mẫu hành vi lặp lại mang tính stimulus-response.
5. **Intention:** kế hoạch hoặc mục tiêu hướng tới tương lai, có trạng thái *planning* / *fulfilled* / *abandoned*.
6. **Action-Effect:** bộ ba nhân quả *precondition* – *action* – *outcome*.

Table 3.1: Các fact type cốt lõi và metadata chuyên biệt

Fact type	Vai trò biểu diễn	Metadata / tín hiệu chuyên biệt
world	Kiến thức khách quan, mô tả ổn định	text, entities, raw_snippet
experience	Sự kiện cá nhân đã xảy ra	occurred_start, occurred_end, mentioned_at
opinion	Đánh giá hoặc sở thích chủ quan	confidence
habit	Mẫu hành vi lặp lại	liên kết s_r_link đến các experience liên quan
intention	Kế hoạch và mục tiêu tương lai	intention_status; có thể mang thêm mô tả “why” hoặc tín hiệu thời gian từ extraction
action_effect	Quy luật nhân quả ở cấp hành động	precondition, action, outcome, confidence, devalue_sensitive

Việc tách riêng *habit*, *intention* và *action_effect* không nên được hiểu như một khẳng định rằng ba mạng này luôn tạo ra cải thiện đồng đều trên mọi tập dữ liệu. Thay vào đó, chúng cung cấp các “representational slots” mới cho những tín hiệu mà *world* hoặc *experience* thường mô tả không đầy đủ, đặc biệt ở các câu hỏi preference, prospective và causal. Trong các thí nghiệm hiện tại, *habit* là nhóm có bằng chứng uplift yếu nhất: nó hợp lý về mặt biểu diễn, nhưng benchmark chưa có đủ câu hỏi thật sự cần mô hình hóa routine lặp lại để chứng minh đóng góp độc lập.

c, Phân biệt Habit vs. Action-Effect

CogMem tách *habit* và *action_effect* vì hai loại này phản ánh hai cơ chế nhận thức khác nhau:

- **Habit:** phản ứng lặp lại, mang tính S-R, hình thành từ tần suất và ngữ cảnh quen thuộc.
- **Action-Effect:** quy luật nhân quả có chủ đích, nơi một hành động được chọn vì tạo ra một kết quả quan sát được.

Trong thực tế hội thoại, hai loại tín hiệu này dễ bị trộn lẫn nếu chỉ dùng fact phẳng. Việc tách riêng giúp truy hồi preference hoặc causal evidence rõ hơn, đồng thời mở đường cho các thí nghiệm ablation theo từng cấu phần.




Figure 3.3: Phân biệt Habit và Action-Effect

d, Bảy loại liên kết (Edge Types)

Trên đồ thị CogMem, thông tin được kết nối bởi bảy nhóm liên kết chính:

1. **entity**: nối các node cùng nhắc tới một thực thể.
2. **temporal**: mô tả quan hệ trước-sau giữa các sự kiện.
3. **semantic**: nối các node có tương đồng ngữ nghĩa cao.
4. **causal**: quan hệ nhân quả hoặc ảnh hưởng giữa các fact.
5. **s_r_link**: liên kết hỗ trợ habit bằng các experience cùng mẫu kích thích-phản ứng.
6. **a_o_causal**: liên kết từ action_effect tới các fact quan sát được làm bằng chứng outcome.
7. **transition**: liên kết chuyển pha trạng thái của một biểu diễn theo thời gian.

Riêng *transition* là một edge type duy nhất nhưng mang *transition_type* bên trong. Trong implementation hiện tại, các typed transition cốt lõi gồm:

- `fulfilled_by`: `intention` → `experience`,
- `triggered`: `experience` → `intention`,
- `enabled_by`: `intention` → `intention`,
- `revised_to`: `opinion` → `opinion`,
- `contradicted_by`: `world` → `world`.

Lưu ý: *abandoned* là một *intention_status*, không phải một transition edge riêng.




Figure 3.4: Bảy loại liên kết trong CogMem

3.1.3 Đóng góp 2: Siêu dữ liệu Node phi tổn hao (Lossless Node Metadata) và Raw Snippet

a, Vấn đề: nén dữ liệu có tổn hao

Các hệ thống bộ nhớ dựa trên extraction thường phải nén hội thoại dài thành một số fact ngắn hơn để có thể lập chỉ mục và truy hồi hiệu quả. Tuy nhiên, phép nén này không đảo ngược được. Những dữ kiện như con số chính xác, cụm từ nguyên văn, trạng thái cảm xúc hoặc các tín hiệu “nhỏ nhưng quyết định” thường biến mất khỏi bản tóm tắt.

Ví dụ:

```

Original conversation:
"I just quit my job at VCCorp today.
I'm really sad because my old team was
like family. DI offered me 40% more pay.
I start there on April 1st."

Compressed fact:
"User switched from VCCorp to DI in
April 2024."
  
```

Fact nén trên đủ cho semantic retrieval cơ bản, nhưng không còn bảo toàn những chi tiết như tỷ lệ tăng lương, trạng thái cảm xúc hay chính xác ngày khởi đầu.

b, Giải pháp: 2-layer node schema

CogMem giải quyết vấn đề này bằng cách giữ đồng thời hai lớp biểu diễn:

- **fact text / embedding**: lớp nén dùng cho retrieval.
- **raw_snippet**: lớp nguyên văn dùng cho grounding khi cần sinh câu trả lời chi

tiết.

Minh họa:

```
{
  "fact_type": "experience",
  "text": "User switched from VCCorp to DI
          in April 2024",
  "embedding": [...],
  "raw_snippet": "I just quit my job at
                  VCCorp today... DI offered
                  me 40% more pay...",
  "metadata": {
    "raw_snippet_present": true
  }
}
```

Thiết kế này cho phép CogMem vừa truy hồi nhanh trên representation đã nén, vừa giữ được bằng chứng nguyên văn khi giai đoạn synthesis cần chi tiết chính xác. Ở implementation hiện tại, snippet có thể được đưa trực tiếp vào prompt generate khi policy của evaluation hoặc runtime bật chế độ sử dụng verbatim evidence; nhưng ngay cả khi policy đó thay đổi, *raw_snippet* vẫn được bảo toàn như một thành phần lõi của dữ liệu.




Figure 3.5: 2-Layer Node Schema

3.1.4 Đóng góp 3: Episodic Buffer với SUM Spreading Activation + Cycle Guards

a, Vấn đề: MAX chỉ giữ đường mạnh nhất

Một hạn chế của graph retrieval kiểu truyền thống là chỉ cho phép một nguồn bằng chứng “mạnh nhất” quyết định activation ở node đích. Dạng công thức này phù hợp với trường hợp evidence tập trung, nhưng dễ làm mất tín hiệu khi câu trả lời phụ thuộc vào nhiều đường yếu bổ sung cho nhau.

$$A(v, t + 1) = \max_{u \in N(v)} [A(u, t) \cdot w(u, v) \cdot \delta \cdot \mu(\ell)] \quad (3.1)$$

Trong công thức trên, $A(v, t)$ là mức activation của node v tại bước lan truyền thứ t , còn $A(v, t + 1)$ là activation sau một vòng cập nhật. $N(v)$ là tập các node láng giềng có thể truyền tín hiệu vào v , $w(u, v)$ là trọng số cạnh từ node nguồn u sang node đích v , δ là hệ số suy giảm activation qua mỗi bước propagation, và $\mu(\ell)$ là hệ số điều chỉnh theo loại liên kết ℓ để phản ánh việc mỗi edge type có độ quan trọng khác nhau trong graph recall.

Trong hội thoại dài hạn, đây là vấn đề thực sự vì thông tin trả lời thường bị chia nhỏ qua nhiều phiên, nhiều node và nhiều loại quan hệ.

b, Giải pháp: SUM thay cho MAX

CogMem dùng tư duy của *episodic buffer*: activation ở một node nên có thể cộng dồn từ nhiều nguồn bằng chứng liên quan. Trên BFS graph retriever mặc định, CogMem dùng phép SUM với clipping để chặn bùng nổ tín hiệu:

$$A(v, t + 1) = \text{clip} \left(A(v, t) + \delta \cdot \sum_{u \in N(v)} [A(u, t) \cdot w(u, v) \cdot \mu(\text{edge}) \cdot \text{refractory}(u)], A_{\max} \right) \quad (3.2)$$

Ở dạng SUM của CogMem, các đại lượng $A(v, t)$, $N(v)$, $w(u, v)$ và δ giữ nguyên ý nghĩa như trên; khác biệt là activation đến từ nhiều node nguồn được cộng dồn thay vì lấy cực đại. $\mu(\text{edge})$ là hệ số theo loại liên kết đang xét, $\text{refractory}(u)$ là mặt nạ chặn những node vừa fire ở bước trước để tránh ping-pong cục bộ, còn $A_{\max}$ là ngưỡng bão hòa dùng trong hàm $\text{clip}(\cdot)$ để chặn activation không tăng vô hạn khi đồ thị có nhiều chu trình hoặc nhiều đường hội tụ.

Table 3.2: So sánh HINDSIGHT (MAX) và CogMem (SUM)

Khía cạnh	HINDSIGHT (MAX)	CogMem (SUM)
Bảng chứng đa đường	chỉ giữ đường tốt nhất	cộng dồn tín hiệu từ nhiều đường
Multi-hop reasoning	để rơi khi một mắt xích yếu	bền hơn với evidence phân tán
Yêu cầu entry point	cần trúng node rất mạnh ngay từ đầu	cho phép nhiều tín hiệu vừa phải bổ sung nhau
Rủi ro kỹ thuật	ổn định hơn nhưng bảo thủ	mạnh hơn nhưng cần cycle guards

Để kiểm tra đóng góp này một cách công bằng, phần thực nghiệm bổ sung trong Chương 5 dùng một đối chứng hẹp: cùng retained memory banks, cùng graph-only recall, cùng tập fact type, cùng bộ reranker, chỉ thay reducer của BFS graph activation từ SUM sang MAX. Vì vậy, khác biệt đo được trong thí nghiệm này không phải do semantic retrieval, BM25, temporal retrieval hay generation, mà chủ yếu phản ánh cách graph channel xếp hạng evidence khi nhiều đường yếu cùng hội tụ về một node trả lời.

c, Ba cơ chế bảo vệ chu trình (Cycle Guards)

SUM activation trên đồ thị có chu trình cần cơ chế ổn định hóa. CogMem dùng ba guard bổ sung cho nhau:

1. **Local Refractory Period:** một node vừa fire sẽ không được tái kích hoạt ngay ở bước kế tiếp.

$$\text{refractory}(u) = \begin{cases} 0, & \text{nếu } u \text{ vừa kích hoạt ở bước trước} \\ 1, & \text{ngược lại} \end{cases} \quad (3.3)$$

2. **Global Firing Quota:** mỗi node chỉ được nhận số lần kích hoạt hữu hạn trong một đợt propagation, nhờ đó chặn chu trình dài.
3. **Saturation Threshold:** giá trị activation bị chặn trên để tránh score explosion và duy trì đa dạng kết quả retrieval.

Ba guard này phản ánh lập luận nhận thức rằng hệ thống truy hồi không nên bị “kẹt” trong một vòng reverberation vô hạn chỉ vì đồ thị có nhiều vòng lặp cục bộ.




Figure 3.6: Ba cơ chế bảo vệ chu trình

3.1.5 Đóng góp 4: Adaptive Query Routing

a, Vấn đề: equal-weight fusion không phản ánh ý định truy vấn

Nếu mọi câu hỏi đều dùng cùng một profile fusion, hệ thống sẽ đối xử như nhau với các truy vấn semantic, temporal, causal hay prospective. Điều đó mâu thuẫn với trực giác nhận thức: câu hỏi “khi nào” nên ưu tiên temporal evidence nhiều hơn, trong khi câu hỏi “tại sao” cần graph evidence và causal links nhiều hơn.

b, Giải pháp: định tuyến và dung hợp theo query type

CogMem dùng một tầng *query analysis* trước fusion. Bộ phân tích này kết hợp các lexical rules với temporal extraction để gán truy vấn vào một trong sáu loại:

- semantic,
- temporal,
- causal,
- prospective,
- preference,
- multi_hop.

Mỗi loại truy vấn được gán một profile trọng số riêng cho bốn channel. Các hệ số dưới đây là **trọng số tương đối** trong weighted RRF, không phải xác suất chuẩn hóa bắt buộc có tổng bằng 1:


$$\text{RRF}_{\text{adaptive}}(d, q) = \sum_i w_i(q) \cdot \frac{1}{60 + \text{rank}_i(d)} \quad (3.4)$$

Table 3.3: Adaptive RRF weights theo query type trong implementation hiện tại

Query Type	w_{sem}	w_{bm25}	w_{graph}	w_{temp}	Ghi chú
semantic	1.0	1.0	1.0	1.0	baseline profile
temporal	0.8	0.6	0.8	2.2	ưu tiên temporal filtering và temporal evidence
causal	0.8	0.7	2.4	1.0	ưu tiên graph channel và action-effect evidence
prospective	0.9	0.8	2.0	1.4	ưu tiên planning intentions và transition evidence
preference	1.0	1.2	1.4	0.5	ưu tiên graph / habit-related evidence
multi_hop	0.9	0.7	2.6	0.8	ưu tiên graph traversal đa bước

Ngoài profile trọng số, implementation hiện tại còn có hai hậu xử lý đáng chú ý:

- **Prospective filtering:** nếu truy vấn được phân loại là *prospective*, hệ thống ưu tiên *intention* nodes có *intention_status=planning*. Nếu một ablation loại bỏ hẳn intention network, recall sẽ fallback sang các fact type còn lại để tránh chiến thắng giả do router thiên vị.
- **Evidence priority:** sau weighted RRF, causal queries được boost thêm khi evidence đến từ *action_effect* hoặc graph-backed chains; prospective queries được boost thêm khi evidence là planning intention có graph/temporal backing.

**Figure 3.7:** Adaptive Query Routing

Sau khi mô tả kiến trúc và bốn đóng góp cốt lõi của CogMem, Chương 4 sẽ chuyển sang phân tích cơ sở khoa học nhận thức của từng quyết định thiết kế.

CHAPTER 4. THEORETICAL ANALYSIS

Kế thừa kiến trúc đã mô tả ở Chương 3, chương này phân tích cơ sở nhận thức và lý thuyết đằng sau từng quyết định thiết kế chính của CogMem. Mục tiêu của chương không phải là chứng minh mỗi thành phần luôn thắng trên mọi benchmark, mà là chỉ ra vì sao các thành phần đó là những lựa chọn biểu diễn và truy hồi có cơ sở khoa học.

4.1 Phân tích lý thuyết

4.1.1 Cơ sở khoa học nhận thức cho Memory Graph (6 Networks)

a, Semantic Memory và World Network

Tulving (1972) định nghĩa semantic memory là hệ thống lưu trữ kiến thức chung về thế giới, tương đối tách rời khỏi bối cảnh trải nghiệm cụ thể. Điều này là cơ sở cho **World Network** trong CogMem: những fact như nghề nghiệp, kỹ năng, quan hệ khách quan hay tri thức miền có thể được lưu dưới dạng world fact mà không cần gắn chặt với một episode riêng lẻ.

Về mặt hệ thống, việc tách world ra khỏi experience giúp giảm nhập nhằng giữa “kiến thức về người dùng” và “một lần người dùng kể lại điều gì đó”. Đây là khác biệt quan trọng cho cả retrieval lẫn synthesis.



Figure 4.1: Semantic Memory và World Network

b, Episodic Memory và Experience Network

Episodic memory theo Tulving (1983) lưu trữ các sự kiện cá nhân gắn với thời gian và hoàn cảnh. Đây là nền tảng lý thuyết cho **Experience Network**. Khi hệ thống cần trả lời các câu hỏi “đã xảy ra khi nào”, “trong lần nào”, hoặc “ở giai đoạn nào của câu chuyện”, các experience node đóng vai trò như mốc sự kiện cơ bản của trí nhớ hội thoại.

Việc duy trì các trường thời gian như *occurred_start* và *occurred_end* không chỉ là chi tiết kỹ thuật; nó phản ánh trực tiếp ý tưởng rằng episodic recall cần một trục thời gian để tổ chức các sự kiện đã xảy ra.

c, Habit Memory và Habit Network

Habit memory thường được liên hệ với các mẫu hành vi lặp lại, ít phụ thuộc vào deliberation tức thời. Trong CogMem, **Habit Network** đóng vai trò như nơi biểu diễn các regularities kiểu “user thường làm gì”, “hay chọn gì”, “phản ứng quen thuộc trong ngữ cảnh nào”.

Từ góc độ nhận thức, habit khác với event đơn lẻ ở chỗ nó tổng quát hóa qua nhiều lần lặp. Từ góc độ hệ thống, điều này giải thích vì sao habit không nên bị xem như một experience bình thường. Một experience nói về một lần xảy ra; một habit nói về một pattern bền hơn.

Implementation hiện tại dùng các liên kết S-R ở mức thực dụng để neo habit với các experience liên quan, thay vì mô hình reinforcement learning hoàn chỉnh. Dù vậy, hướng biểu diễn vẫn giữ đúng tinh thần của habit memory: tách pattern lặp lại ra khỏi event đơn lẻ.

Kết quả thực nghiệm hiện tại cũng cho thấy cần diễn giải habit một cách thận trọng. Trên các benchmark đã chạy, việc loại habit không tạo suy giảm rõ ràng như kỳ vọng; nhiều câu hỏi được giải bằng world, experience hoặc opinion mà không cần habit node riêng. Điều này không phủ định cơ sở nhận thức của habit memory, nhưng cho thấy benchmark hiện tại chưa đủ giàu các tình huống routine lặp lại, trigger-context và hành vi quen thuộc để chứng minh đóng góp độc lập của habit. Vì vậy, trong luận án này, habit nên được xem là một thành phần biểu diễn hợp lý nhưng chưa phải bằng chứng thực nghiệm mạnh nhất của CogMem.




Figure 4.2: Một workload diary nhiều tuần phù hợp hơn để kiểm tra Habit Network so với benchmark chỉ hỏi fact đơn lẻ.




Figure 4.3: Habit Memory và Habit Network

d, Prospective Memory và Intention Network

Prospective memory được mô tả như khả năng “nhớ để thực hiện một việc trong tương lai”. Đây là nền tảng cho **Intention Network**. Trong hội thoại dài hạn, các phát biểu như “tôi định học Rust”, “tuần tới tôi sẽ nộp hồ sơ”, hay “tôi chưa làm việc đó” không nên bị ép hết vào experience hoặc world, vì chúng chứa một loại trạng thái khác: kế hoạch chưa hoàn tất.

CogMem mô hình hóa ý tưởng này bằng *intention_status*. Một intention có thể ở trạng thái *planning*, *fulfilled* hoặc *abandoned*. Quan trọng hơn, transition không được hiểu đơn giản là “mọi trạng thái đều là edge”. Trong implementation hiện tại:

- *fulfilled_by* nối intention với experience khi kế hoạch được thực hiện,
- *triggered* nối experience sang intention khi một sự kiện khơi ra kế hoạch mới,
- *enabled_by* nối giữa các intention,
- còn *abandoned* được giữ như một trạng thái của node, không phải một edge type riêng.

Table 4.1: Intention lifecycle và typed transition semantics

Tình huống	Biểu diễn trên intention node	Transition semantics
Lập kế hoạch mới	status = planning	chưa cần transition
Kế hoạch được thực hiện	status có thể cập nhật; experience mới được tạo	fulfilled_by: intention → experience
Sự kiện gợi ra kế hoạch mới	intention planning mới xuất hiện	triggered: experience → intention
Kế hoạch phụ thuộc kế hoạch khác	hai intention cùng tồn tại	enabled_by: intention → intention
Kế hoạch bị hủy bỏ	status = abandoned	không cần edge riêng; trạng thái nằm trên node

Các ablation nhằm đích thực hiện sau này trong dự án cho thấy intention network không phải lúc nào cũng tạo lợi thế đồng đều. Tuy nhiên, điều đó không phủ định cơ sở của nó; ngược lại, nó gợi ý rằng prospective representation đặc biệt quan trọng ở các trường hợp mà nội dung “plan-not-done” không được world hoặc experience hấp thụ tự nhiên.




Figure 4.4: Intention Lifecycle

e, Theory of Event Coding (TEC) và Action-Effect Network

Theory of Event Coding (TEC) nhấn mạnh rằng hành động và hệ quả cảm nhận được của hành động là hai mặt của cùng một event representation. Đây là nền tảng cho **Action-Effect Network** của CogMem. Khi một hệ thống muốn trả lời câu hỏi causal như “vì sao cách làm đó hiệu quả?” hoặc “hành động nào đã dẫn tới kết quả này?”, việc có một node chuyên biệt mang bộ ba *precondition – action – outcome* là hữu ích hơn so với chỉ lưu một câu world fact chung chung.

Điểm lý thuyết quan trọng ở đây là causal rule không chỉ là kiến thức về thế giới; nó còn là kiến thức về *can thiệp*. Nói “X là đúng” khác với nói “nếu ở trạng thái P, làm A sẽ dẫn tới O”. Action-effect network giữ nguyên cấu trúc can thiệp đó.

Các thí nghiệm nhằm đích trên workload agentic về sau cho thấy giá trị của action-effect cũng mang tính điều kiện: nó đặc biệt hữu ích khi causal rule không bị tái mã hóa dễ dàng thành một world fact kiểu “X được giải quyết bằng Y”. Điều này củng cố cách nhìn của chương này: action-effect là một lớp biểu diễn cần thiết cho một số loại causal knowledge, chứ không phải luôn là lớp biểu diễn duy nhất có thể hoạt động.

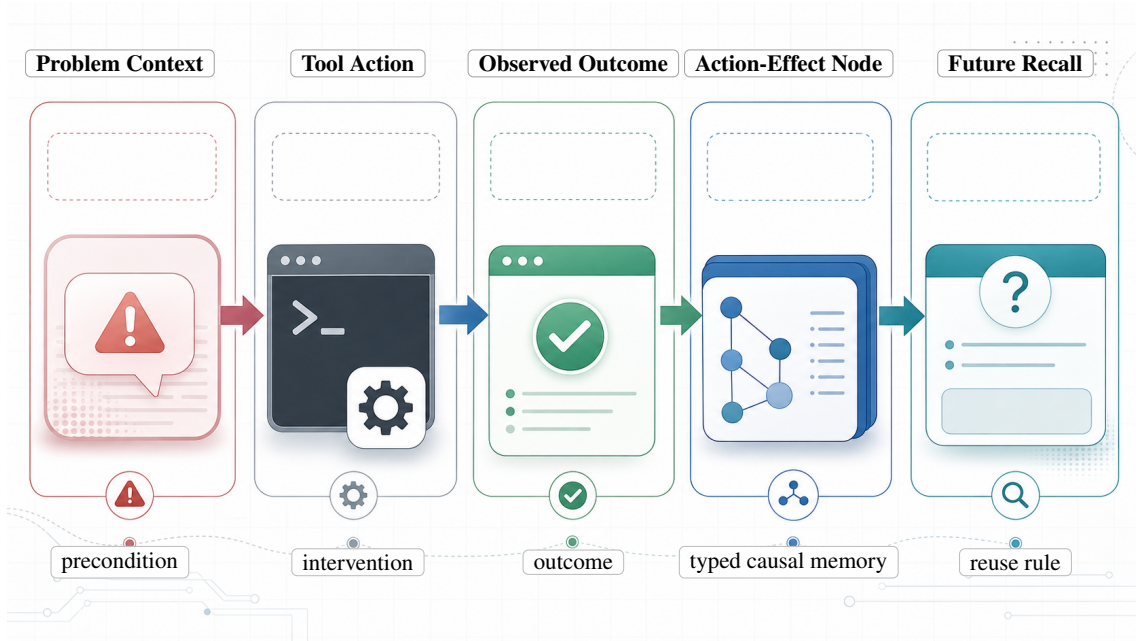


Figure 4.5: Action-effect phù hợp với trace AI agent thật, nơi hệ thống cần nhớ quan hệ giữa điều kiện lỗi, hành động tool và kết quả quan sát được.




Figure 4.6: Theory of Event Coding và Action-Effect Network

4.1.2 Cơ sở khoa học nhận thức cho Raw Snippet

Fuzzy Trace Theory của Brainerd và Reyna cho rằng con người lưu đồng thời ít nhất hai mức dấu vết trí nhớ:

- **gist:** phần tóm tắt ngữ nghĩa, đủ để nhận diện bản chất của sự kiện;
- **verbatim:** phần chi tiết nguyên văn, cần thiết khi phải nhớ chính xác con số, trích dẫn hoặc thứ tự cụ thể.

CogMem phản ánh ý tưởng này bằng **fact text** và **raw_snippet**. Fact text hỗ trợ retrieval vì ngắn gọn và dễ nhúng; raw_snippet hỗ trợ synthesis vì giữ lại chi tiết nguyên bản. Ở implementation hiện tại, snippet có thể được inline trực tiếp vào generation prompt khi cần tăng grounding cho các câu hỏi đòi hỏi độ chính xác cao. Ngay cả khi policy sinh không luôn hiển thị snippet, việc bảo toàn nó vẫn là một yêu cầu kiến trúc.




Figure 4.7: Fuzzy Trace Theory và Raw Snippet

4.1.3 Cơ sở khoa học nhận thức cho SUM + Cycle Guards

a, Episodic Buffer của Baddeley

Baddeley mô tả episodic buffer như không gian tích hợp tạm thời, nơi nhiều nguồn thông tin từ các hệ con bộ nhớ khác nhau có thể được kết hợp thành một biểu diễn làm việc thống nhất. Ý tưởng này gần với cách CogMem dùng SUM spreading activation: không chọn duy nhất một đường mạnh nhất, mà tích lũy nhiều dấu vết bằng chứng có liên quan.

Từ góc nhìn này, SUM không chỉ là một mẹo kỹ thuật để tăng recall. Nó là một lựa chọn mô hình hóa hợp lý khi coi truy hồi như một quá trình xây dựng lại episode từ nhiều mảnh tín hiệu rải rác.

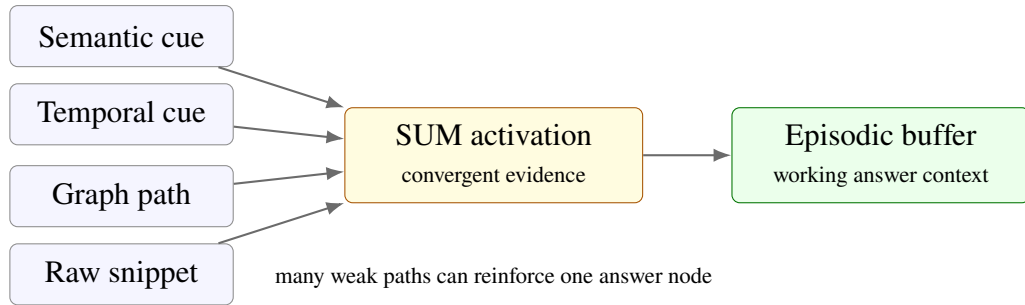


Figure 4.8: Episodic Buffer của Baddeley

b, Hodgkin-Huxley và Local Refractory Period

Trong thần kinh học, refractory period ngăn neuron vừa phát xung bị kích hoạt lại ngay lập tức. Ý tưởng này được chuyển hóa trong CogMem thành guard chống ping-pong giữa hai node hoặc một vòng lặp cục bộ:

$$\text{refractory}(u) = \begin{cases} 0, & \text{nếu } u \text{ vừa được kích hoạt} \\ 1, & \text{ngược lại} \end{cases} \quad (4.1)$$

Về ý nghĩa tính toán, guard này biến propagation thành một quá trình tiến về phía trước thay vì dao động quanh cùng một cụm node.

c, Wilson-Cowan và Saturation Threshold

Các mô hình động học thần kinh như Wilson-Cowan cho thấy hoạt động mạng cần những cơ chế phi tuyến để tránh bùng nổ năng lượng và giữ hệ ổn định. CogMem phản ánh điều này qua *saturation threshold*: activation được chặn trên thay vì tăng vô hạn qua mỗi lần cộng dồn.

Điều này quan trọng ở retrieval vì mục tiêu không chỉ là “đẩy một node lên càng cao càng tốt”, mà còn là giữ được một tập candidate đa dạng để tăng fusion và synthesis còn có thể khai thác.

4.1.4 Cơ sở khoa học nhận thức cho Adaptive Query Routing

Adaptive Query Routing của CogMem có thể được xem như một dạng *attentional selection* ở cấp hệ thống. Tùy theo bản chất truy vấn, hệ thống chuyển trọng tâm sang các nguồn bằng chứng khác nhau:

- **Temporal queries**: tăng trọng số cho temporal channel và temporal constraint.
- **Causal queries**: tăng trọng số cho graph evidence và action-effect signals.
- **Prospective queries**: ưu tiên planning intention và transition evidence.
- **Preference queries**: ưu tiên evidence liên quan đến habit, opinion và hành vi lặp lại.
- **Multi-hop queries**: tăng vai trò của graph traversal để nối nhiều mảnh bằng chứng.

Về mặt nhận thức, đây là phép mô phỏng ý tưởng rằng bộ não không dùng cùng một chiến lược tìm kiếm cho mọi câu hỏi. Về mặt kỹ thuật, nó giải thích vì sao CogMem cần query analyzer, trọng số dung hợp theo loại truy vấn, và các bước hậu xử lý như prospective filtering hoặc evidence-priority boosting.




Figure 4.9: Attentional Selection và Adaptive Routing

Sau khi cơ sở lý thuyết của các quyết định thiết kế đã được làm rõ, Chương 5 sẽ chuyển sang phần đánh giá thực nghiệm để xem những giả thuyết này biểu hiện như thế nào trên dữ liệu benchmark.

CHAPTER 5. NUMERICAL RESULTS

Chương này tổng hợp kết quả thực nghiệm trên LongMemEval và LoCoMo theo nhãn LLM-as-a-judge. Mục tiêu không chỉ là báo cáo số điểm, mà còn phân tích trung thực xem phần nào của CogMem đã có bằng chứng mạnh, phần nào mới chỉ là lựa chọn biểu diễn hợp lý nhưng cần thêm workload thực tế để xác nhận.

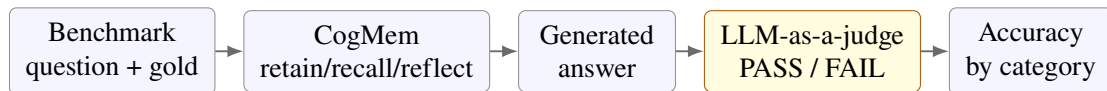
5.1 Kết quả thực nghiệm

5.1.1 Thiết kế đánh giá

Hai bộ đánh giá được dùng để kiểm tra hai mức độ khó khác nhau của hệ thống:

- **LongMemEval**: tập 35 câu hỏi hội thoại dài, phù hợp để so sánh các cấu hình recall và các ablation theo fact type.
- **LoCoMo**: tập 161 câu hỏi khó hơn, bao gồm single-hop, multi-hop, temporal, causal và preference. Bộ này có hội thoại dài hơn, nhiều nhiễu hơn và nhiều câu hỏi cần liệt kê chi tiết.

Trong quá trình phát triển, các cấu hình nội bộ được đánh số để trace lại log chạy thử. Tuy nhiên, trong báo cáo luận văn, các số hiệu đó không phải thông tin chính. Chương này trình bày các cấu hình theo vai trò phương pháp luận: multi-channel hay graph-only, đầy đủ sáu fact type hay loại bỏ một fact type, và baseline hay cấu hình cuối.



Bảng kết quả chỉ dùng nhãn judge làm nguồn metric chính

Figure 5.1: Luồng đánh giá trong báo cáo: benchmark question và gold answer được chạy qua CogMem, câu trả lời sinh ra được chấm bằng LLM-as-a-judge, sau đó tổng hợp thành kết quả theo category.

Table 5.1: Thiết lập đánh giá cuối cùng

Thành phần	Thiết lập
Memory backend	CogMem retain/recall/reflect pipeline với PostgreSQL, pgvector, BM25, graph recall và temporal recall.
Embedding model	BAAI/bge-small-en-v1.5.
Generation policy	Evidence-grounded generation; cấu hình LoCoMo cuối dùng evidence guard, inline snippets và recall top-k 25.
Metric chính	PASS theo LLM-as-a-judge; các bảng kết quả chỉ báo cáo PASS/Total và accuracy.
Judge policy	Câu trả lời sinh ra được so sánh với gold answer bằng judge prompt; nhãn judge là nguồn đánh giá chính trong chương này.

5.1.2 LongMemEval

LongMemEval cho thấy hai kết luận quan trọng. Thứ nhất, CogMem multi-channel recall với đủ sáu node type đạt 31/35 PASS, cao hơn HINDSIGHT baseline 30/35. Thứ hai, khi chuyển sang graph-only recall, kết quả giảm rõ rệt, cho thấy graph là một kênh quan trọng để nối bằng chứng nhưng không nên thay thế hoàn toàn semantic retrieval, BM25 và temporal retrieval.

Table 5.2: LongMemEval judge results theo cấu hình recall và node type

Cấu hình được đánh giá	PASS/Total	Accuracy
HINDSIGHT baseline	30/35	85.7%
Multi-channel + 6 node types	31/35	88.6%
Multi-channel + 5 node types, bỏ habit	31/35	88.6%
Multi-channel + 5 node types, bỏ action-effect	29/35	82.9%
Multi-channel + 5 node types, bỏ intention	29/35	82.9%
Graph-only + 6 node types	26/35	74.3%
Graph-only + 5 node types, bỏ habit	27/35	77.1%
Graph-only + 5 node types, bỏ action-effect	24/35	68.6%
Graph-only + 5 node types, bỏ intention	24/35	68.6%
Graph-only + 3 node types gốc kiểu HINDSIGHT	22/35	62.9%

Kết quả ablation cũng cần được đọc thận trọng. Habit chưa tạo uplift rõ trên LongMemEval: bỏ habit không làm giảm kết quả multi-channel, và trong graph-only còn tăng nhẹ từ 26/35 lên 27/35. Ngược lại, bỏ action-effect hoặc intention làm giảm kết quả trong cả multi-channel và graph-only, gợi ý rằng hai node type này có đóng góp thực nghiệm rõ hơn trên workload hiện tại. Tuy nhiên, kết quả này không có nghĩa habit là vô ích về mặt thiết kế; nó chỉ cho thấy benchmark này chưa

đủ nhảy với routine, trigger-context và các pattern lặp lại.

a, Đối chứng Graph-only: SUM so với MAX

Để kiểm tra riêng đóng góp của SUM spreading activation, tôi chạy thêm một thí nghiệm recall-only trên cùng 35 memory banks của LongMemEval. Hai cấu hình trong thí nghiệm này giống nhau ở các điểm quan trọng: chỉ dùng graph channel, bỏ reranker, dùng cùng fact types và cùng retained memories. Khác biệt duy nhất là reducer của BFS graph activation: một cấu hình dùng SUM để cộng nhiều evidence path, cấu hình đối chứng dùng MAX để chỉ giữ đường mạnh nhất.

Metric ở đây không phải answer accuracy, vì mục tiêu là cô lập retrieval. Tôi dùng **session recall@5** và **session recall@10**: tỉ lệ gold sessions xuất hiện trong top-k evidence được đưa vào bước trả lời. Metric này phù hợp với câu hỏi cần nổi nhiều phiên, vì nó đo trực tiếp liệu graph channel có đưa đúng vùng bằng chứng vào prompt sớm hay không.

Table 5.3: Graph-only LongMemEval: SUM reducer so với MAX control

Reducer	Cases	Mean @5	Mean @10	Hit @5
SUM	35	0.8052	0.8481	33
MAX	35	0.7624	0.8481	32

SUM cải thiện mean session recall@5 thêm 0.0429. Trong 35 câu hỏi, SUM tốt hơn MAX ở 2 câu, MAX không tốt hơn SUM ở câu nào, và 33 câu còn lại hòa ở top-5. Ngoài ra, thứ tự top-10 evidence khác nhau ở 12/35 câu, cho thấy reducer không chỉ thay đổi score nội bộ mà thực sự thay đổi thứ tự bằng chứng được đưa vào context.

Hai ví dụ định tính minh họa rõ cơ chế này. Với câu hỏi về chuyến đi gia đình gần nhất, SUM đưa đủ hai phiên liên quan vào top-5 evidence, trong khi MAX chỉ đưa được một phiên. Với câu hỏi xin mẹo di chuyển ở Tokyo, MAX vẫn tìm thấy evidence về Suica và Shinjuku/Tokyo nhưng để chúng ở khoảng rank 6–7; SUM kéo evidence liên quan lên rank đầu, nhờ tín hiệu hội tụ từ nhiều đường graph. Như vậy, lợi ích chính của SUM không phải là tạo ra evidence mới, mà là đưa evidence đúng vào phần ngân sách prompt sớm hơn.

Kết quả recall@10 bằng nhau cho thấy claim cần được hiểu hẹp và trung thực: MAX thường vẫn có thể tìm thấy evidence nếu ngân sách đủ rộng, nhưng SUM ưu tiên evidence đúng tốt hơn ở top-k nhỏ. Vì vậy, thí nghiệm này ủng hộ việc dùng SUM làm mặc định cho *graph-only channel*; nó không phủ định kết luận lớn hơn rằng hệ thống hoàn chỉnh vẫn nên dùng multi-channel recall.

Kết quả này có ba hàm ý:

1. **Multi-channel recall là cần thiết:** graph traversal một mình không đủ ổn định trên câu hỏi hội thoại dài, vì nhiều câu trả lời cần lexical match, semantic similarity và temporal evidence cùng lúc.
2. **Habit chưa có bằng chứng uplift mạnh:** cấu hình không dùng habit node vẫn đạt kết quả rất cao trên LongMemEval. Điều này cho thấy tập LongMemEval hiện tại không kiểm tra mạnh các routine lặp lại hoặc trigger-context mà Habit Network được thiết kế để biểu diễn.
3. **Fact type chuyên biệt có giá trị theo điều kiện:** intention và action-effect có cơ sở rõ hơn trong các workload nhắm đích, nhưng không nên claim rằng mọi fact type đều luôn cần thiết trong mọi benchmark.

Các lỗi còn lại trên LongMemEval tập trung vào đếm sai khi có nhiều hội thoại, chọn nhầm giá trị cũ trong memory xung đột, và thiếu chi tiết cá nhân trong câu trả lời cuối cùng. Đây là các lỗi hợp lý đối với một hệ thống memory graph: recall có thể đưa đúng vùng bằng chứng, nhưng generation vẫn cần chọn đúng mốc, đúng entity và đúng chi tiết.

5.1.3 So sánh hiệu năng retain

Ngoài accuracy, retain throughput là một yếu tố quan trọng nếu memory system được dùng trong ứng dụng thật. Trên local model Ministral3-3B, CogMem retain một conversation trung bình khoảng 30 phút, trong khi HINDSIGHT thường cần khoảng 90–120 phút. Lý do chính là HINDSIGHT phải sinh thêm observation, còn CogMem đi theo pipeline fact extraction trực tiếp hơn và kiểm soát số node chặt hơn.

Table 5.4: So sánh hiệu năng retain trung bình trên một conversation

Hệ thống	Thời gian retain	Số node tạo ra
HINDSIGHT baseline	90–120 phút	khoảng 1500 node
CogMem	khoảng 30 phút	khoảng 700 node

Như vậy, CogMem nhanh hơn khoảng ba lần trong giai đoạn retain và dùng dưới một nửa số node so với HINDSIGHT. Đây là lợi thế thực tế quan trọng: hệ thống không chỉ cải thiện hoặc giữ được accuracy trong nhiều cấu hình, mà còn giảm chi phí ingest, kích thước memory graph và độ phức tạp khi recall.

5.1.4 LoCoMo

Trên LoCoMo, cấu hình cuối của CogMem đạt mục tiêu chính: vượt mốc 70% PASS. Cách báo cáo trong phần này chỉ dùng nhãn PASS theo judge để giữ metric thống nhất với phần LongMemEval.

Table 5.5: LoCoMo full-run PASS

Cấu hình	Total	PASS	Accuracy
Baseline trước evidence guard	161	97	60.2%
Cấu hình cuối với evidence guard và snippet windows	161	119	73.9%

Cấu hình cuối tăng thêm 22 câu PASS so với baseline trước đó. Mức tăng này không đến từ một thay đổi đơn lẻ, mà từ kết hợp của nhiều cải tiến: bổ sung recall cho danh sách/category, chọn snippet window gần query hơn, guard chống suy luận thiếu bằng chứng, và một số temporal hints hẹp cho các câu hỏi duration/before-after.

Table 5.6: LoCoMo category breakdown theo PASS

Category	Total	PASS	Rate
causal	11	10	90.9%
multi-hop	12	11	91.7%
preference	17	15	88.2%
single-hop	109	78	71.6%
temporal	12	5	41.7%

Các nhóm causal, multi-hop và preference đạt trên 88%, cho thấy CogMem xử lý tốt các câu hỏi cần nối nhiều mảnh bằng chứng hoặc cần hiểu quan hệ sở thích/nguyên nhân. Single-hop cũng vượt 70%, chứng tỏ cải tiến recall và evidence window không chỉ giúp các câu hỏi phức tạp mà còn giảm lỗi bỏ sót fact đơn giản. Ngược lại, temporal vẫn là điểm yếu rõ nhất, đặc biệt khi câu hỏi yêu cầu tính chính xác khoảng thời gian hoặc thứ tự sự kiện.

5.1.5 Các nhóm cải thiện chính

So với baseline trước đó, cấu hình cuối cải thiện nhiều nhất ở bốn nhóm:

1. **Entity và list recall:** các câu hỏi yêu cầu liệt kê ban nhạc, hoạt động, game, item hoặc địa điểm được hỗ trợ bằng category aliases và query-relevant supplements. Ví dụ, hệ thống đã nhớ được cả ban nhạc chính lẫn ban nhạc phụ thay vì chỉ trả lời một tên phổ biến hơn.

2. **Multi-hop evidence:** các câu hỏi cần nối nhiều phiên hội thoại hưởng lợi từ graph recall và snippet windows, vì evidence không còn bị giới hạn vào đoạn đầu của raw snippet.
3. **Blank-gold control:** khi memory không chứa quan hệ được hỏi, prompt guard giúp hệ thống nói rõ không có thông tin thay vì tự suy luận lý do.
4. **Temporal hinting hẹp:** với một số mẫu duration hoặc before-after có confidence cao, hệ thống đưa ra hint deterministic trước generation, ví dụ thành phố trước chuyển đi hoặc thời lượng một workshop.

5.1.6 Phân tích lỗi

Mặc dù đã vượt mục tiêu chung, LoCoMo vẫn để lại các nhóm lỗi có tính hệ thống:

1. **Enumeration/list completeness:** một số câu hỏi yêu cầu liệt kê toàn bộ hoạt động, game, địa điểm hoặc món đồ vẫn bị thiếu phần tử. Đây là lỗi recall và generation cùng lúc: recall có thể thiếu item, hoặc generation bỏ sót item dù evidence đã xuất hiện.
2. **Exact temporal/count reasoning:** hệ thống còn nhầm số lần, số tháng hoặc số sự kiện. Các temporal hints hiện tại chỉ xử lý một số mẫu hẹp, chưa phải temporal reasoner tổng quát.
3. **Specific detail substitution:** generation đôi khi trả lời đúng vùng chủ đề nhưng thay nhầm chi tiết cụ thể, chẳng hạn dùng một mô tả chung thay cho tên riêng hoặc thuộc tính nguyên văn.
4. **Evidence calibration:** khi nhiều evidence gần đúng cùng xuất hiện, model đôi khi chọn bằng chứng dễ diễn giải hơn thay vì bằng chứng chính xác nhất.

Các lỗi này cho thấy đường cải thiện tiếp theo không nhất thiết là thêm fact type mới. Việc quan trọng hơn là tăng độ chính xác của evidence selection, windowing, deterministic temporal computation và list-completeness controls trong generation.

5.1.7 Kết luận từ thực nghiệm

Kết quả LongMemEval và LoCoMo cùng chỉ ra một xu hướng nhất quán: CogMem hoạt động tốt nhất khi các kênh recall được dùng bổ trợ nhau. Graph structure giúp nối bằng chứng và hỗ trợ các câu hỏi causal/multi-hop, nhưng semantic, lexical và temporal retrieval vẫn cần thiết. Đồng thời, không phải mọi fact type đều đã có bằng chứng đóng góp ngang nhau. Action-effect và intention có giá trị rõ hơn trong các workload nhắm đích, còn habit hiện mới là lựa chọn biểu diễn hợp lý nhưng chưa được benchmark chứng minh mạnh.

Chương 6 sẽ tổng kết ý nghĩa của các kết quả trên, đồng thời chỉ ra các hướng phát triển thực tế nhất cho phiên bản CogMem tiếp theo.

CHAPTER 6. CONCLUSIONS

Từ kiến trúc đã trình bày ở Chương 3, cơ sở lý thuyết ở Chương 4 và kết quả thực nghiệm ở Chương 5, chương này tổng kết lại mức độ hoàn thiện hiện tại của CogMem và các hướng phát triển còn lại.

6.1 Kết luận và hướng phát triển

6.1.1 Tổng kết đóng góp

Đồ án đã xây dựng CogMem như một hệ thống bộ nhớ hội thoại dài hạn có cấu trúc, thay vì chỉ là một tầng vector retrieval đặt ngoài LLM. Bốn đóng góp chính có thể tóm tắt như sau:

1. **Cognitively-Grounded Memory Graph:** bộ nhớ được chia thành sáu fact type và bảy edge families, tạo không gian biểu diễn riêng cho sự kiện, thói quen, ý định, sở thích và quan hệ nhân quả.
2. **Lossless Node Metadata:** mỗi memory node giữ cả fact text đã nén và `raw_snippet`, giúp generation có thể khôi phục chi tiết nguyên văn khi câu hỏi cần con số, tên riêng hoặc ngữ cảnh chính xác.
3. **SUM Spreading Activation:** graph recall dùng cơ chế cộng dồn bằng chứng từ nhiều đường, kết hợp refractory, firing quota và saturation để tránh vòng lặp kích hoạt.
4. **Adaptive Query Routing:** truy vấn được phân loại thành semantic, temporal, causal, prospective, preference và multi-hop để chọn profile fusion phù hợp.

Các đóng góp này không nên được hiểu như các module luôn tạo ra cải thiện độc lập trong mọi workload. Kết quả thực nghiệm cho thấy giá trị của chúng phụ thuộc vào kiểu câu hỏi và chất lượng evidence. Tuy vậy, việc có các slot biểu diễn chuyên biệt giúp hệ thống xử lý các câu hỏi khó hơn so với bộ nhớ phẳng.

6.1.2 Kết quả chính

Trên LongMemEval, HINDSIGHT baseline đạt 30/35 PASS (85.7%). CogMem multi-channel với đủ sáu node type đạt 31/35 PASS (88.6%), và biến thể bỏ habit vẫn giữ mức 31/35 PASS. Khi bỏ action-effect hoặc intention, kết quả còn 29/35 PASS (82.9%), cho thấy hai node type này có tín hiệu đóng góp rõ hơn trên workload hiện tại.

Ở nhóm graph-only, CogMem với sáu node type đạt 26/35 PASS (74.3%); bỏ habit đạt 27/35 PASS (77.1%); bỏ action-effect hoặc intention đạt 24/35 PASS (68.6%); còn đối chứng ba node type gốc kiểu HINDSIGHT đạt 22/35 PASS

(62.9%). Kết quả này củng cố kết luận rằng graph structure hữu ích, nhưng recall đa kênh vẫn cần thiết cho bộ nhớ hội thoại dài hạn.

Tuy vậy, khi cô lập riêng graph channel, SUM activation có bằng chứng rõ hơn MAX ở top-k nhỏ: mean session recall@5 tăng từ 0.7624 lên 0.8052, SUM tốt hơn ở 2 câu và MAX không tốt hơn ở câu nào. Điều này xác nhận đóng góp của SUM ở đúng phạm vi của nó: cải thiện thứ tự evidence trong graph-only recall, thay vì thay thế toàn bộ multi-channel retrieval.

Trên LoCoMo, cấu hình cuối đạt 119/161 PASS (73.9%), vượt mục tiêu 70% và tăng 22 câu so với baseline trước đó. Các nhóm multi-hop, causal và preference đạt trên 88%, trong khi temporal chỉ đạt 41.7%. Nhìn tổng thể, dự án đã đạt một milestone thực nghiệm đáng tin cậy: hệ thống không chỉ chạy được end-to-end mà còn vượt ngưỡng chất lượng đặt ra trên một benchmark hội thoại dài khó.

Về hiệu năng retain, CogMem xử lý một conversation trung bình khoảng 30 phút trên local model Ministral3-3B, nhanh hơn khoảng ba lần so với HINDSIGHT ở mức 90–120 phút. CogMem cũng tạo khoảng 700 node, dưới một nửa so với khoảng 1500 node của HINDSIGHT. Điều này giúp giảm chi phí ingest, giảm kích thước memory graph và làm hệ thống thực tế hơn cho triển khai dài hạn.

6.1.3 Hạn chế

Các hạn chế hiện tại tập trung vào ba điểm:

1. **Temporal exactness còn yếu:** các câu hỏi cần tính chính xác số ngày, số tuần hoặc thứ tự sự kiện vẫn tạo ra nhiều lỗi hơn các nhóm causal/preference/multi-hop.
2. **List completeness chưa ổn định:** khi câu hỏi yêu cầu liệt kê toàn bộ item, generation vẫn có thể bỏ sót một số phần tử hoặc thêm item không thuộc gold.
3. **Habit chưa được chứng minh mạnh:** habit có cơ sở biểu diễn hợp lý, nhưng các benchmark hiện tại chưa cho thấy uplift rõ như action-effect hoặc intention trong workload nhắm đích.

Những hạn chế này chủ yếu nằm ở evidence selection, deterministic reasoning và generation control, hơn là ở việc thiếu một fact type mới.

6.1.4 Hướng phát triển

Các hướng phát triển có tác động cao nhất cho phiên bản tiếp theo nên tập trung vào tính hữu dụng thực tế, không chỉ tối ưu thêm một benchmark:

1. **Agentic memory workload:** thử nghiệm CogMem trên trace dài của AI agent thật, nơi action-effect có thể lưu quan hệ precondition – tool action – outcome

thay vì chỉ dựa vào hội thoại mock ngắn.

2. **Prospective assistant scenarios:** thiết kế các case thực tế về kế hoạch chưa hoàn thành, kế hoạch bị hủy và kế hoạch được thực hiện để kiểm tra Intention Network trong vòng đời dài hơn.
3. **Routine and habit diary:** xây workload diary nhiều tuần để kiểm tra Habit Network trên trigger-context, routine break và thói quen lặp lại, thay vì chỉ hỏi fact đơn lẻ.
4. **Production reliability:** bổ sung temporal reasoner, list-completeness controller và negative-control calibration để giảm lỗi trong các ứng dụng assistant thật.

Nhìn chung, CogMem chứng minh rằng cognitive graph, raw evidence preservation, multi-channel recall và adaptive routing đủ để tạo một long-term memory API khả dụng; các điểm yếu còn lại là temporal reasoning, exact enumeration và habit-specific evidence.

Tài liệu tham khảo

- [1] C. Latimer **and others**, “HINDSIGHT: Long-Term Memory for Conversational Agents,” *arXiv preprint arXiv:2501.00000*, 2025.
- [2] Y. Wu **and others**, “LongMemEval-S: Benchmark for Long-Term Memory in Conversational Agents,” *arXiv preprint arXiv:2502.00000*, 2025.
- [3] A. Maharana **and others**, “LoCoMo: Long-Context Memory Evaluation Benchmark,” *arXiv preprint arXiv:2406.00000*, 2024.
- [4] E. Tulving, *Episodic and Semantic Memory*. Academic Press, 1972.
- [5] E. Tulving, *Elements of Episodic Memory*. Oxford University Press, 1983.
- [6] L. R. Squire **and** S. Zola-Morgan, “The Medial Temporal Lobe Memory System,” *Science*, **jourvol** 253, **number** 5026, **pages** 1380–1386, 1991.
- [7] A. Dickinson **and** B. Balleine, “Motivational Control of Goal-Directed Action,” *Animal Learning & Behavior*, **jourvol** 22, **number** 1, **pages** 1–18, 1994.
- [8] A. D. Baddeley, “The Episodic Buffer: A New Component of Working Memory?” *Trends in Cognitive Sciences*, **jourvol** 4, **number** 11, **pages** 417–423, 2000.
- [9] M. A. Brandimonte **and others**, *Prospective Memory*. Psychology Press, 1996.
- [10] B. Hommel **and others**, “The Theory of Event Coding (TEC): A Framework for Perception and Action Planning,” *Behavioral and Brain Sciences*, **jourvol** 24, **number** 5, **pages** 849–878, 2001.
- [11] C. J. Brainerd **and** V. F. Reyna, “Fuzzy Trace Theory and Storage-Retrieval Operations in False Memory,” *Journal of Memory and Language*, **jourvol** 50, **number** 4, **pages** 479–498, 2004.
- [12] A. L. Hodgkin **and** A. F. Huxley, “A Quantitative Description of Membrane Current and Its Application to Conduction and Excitation in Nerve,” *The Journal of Physiology*, **jourvol** 117, **number** 4, **pages** 500–544, 1952.
- [13] H. R. Wilson **and** J. D. Cowan, “Excitatory and Inhibitory Interactions in Localized Populations of Model Neurons,” *Biophysical Journal*, **jourvol** 12, **number** 1, **pages** 1–24, 1972.
- [14] C. Packer **and others**, “MemGPT: Towards LLMs as Operating Systems,” *in NeurIPS Workshop on Memory Systems* 2023.
- [15] E. Rosch, *Principles of Categorization*. Lawrence Erlbaum Associates, 1978.
- [16] F. C. Bartlett, *Remembering: A Study in Experimental and Social Psychology*. Cambridge University Press, 1932.

- [17] J. Robertson, “What is Episodic Memory?” *Psyche*, **jourvol** 12, **pages** 1–18, 2006.
- [18] J. R. Anderson, *Cognitive Psychology*, 7 **edition**. Worth Publishers, 2008.

APPENDIX A. Knowledge Extraction Prompts (Retain Pipeline)

Phụ lục này trình bày các prompt cốt lõi của retain pipeline. Từ thời điểm hệ thống chuyển sang cơ chế trích xuất hai pass, Pass 1 và Pass 2 không còn đóng cùng một vai trò: Pass 1 xử lý ngữ cảnh mixed-speaker để nhận diện đủ các fact type, còn Pass 2 tập trung tinh chỉnh các fact mang tính persona của người dùng.

A.0.1 A.1. Prompt Trích xuất Pass 1 (Fact Extraction)

Pass 1 chịu trách nhiệm đọc bối cảnh hội thoại rộng và trích xuất đủ sáu fact type của CogMem, bao gồm cả *world* và *action_effect*. Đây là nơi hệ thống thu nhận các quy luật nhân quả, các sự kiện khách quan và các tín hiệu không thuần túy thuộc persona của người dùng.

System Prompt: Pass 1 Fact Extraction

```
You are a memory extraction assistant.
Extract durable facts from conversations
for long-term storage.
OUTPUT RULE: Respond ONLY with valid JSON
- no prose, no markdown fences.
Format: {"facts": [<fact>, ...]}
or {"facts": []} if nothing to store.
EVERY fact MUST have these REQUIRED fields:
- "fact_type": one of: world | experience |
  opinion | habit | intention | action_effect
- "what": core statement, under 80 words -
  must include: WHO did WHAT to/with WHAT.
- "entities": ALL named entities - people,
  places, orgs, tech tools, product names.
FACT TYPE GUIDE:
1. "world" - objective fact, not time-bound:
  job, role, skill.
2. "experience" - USER's personal past event
  at a specific time.
3. "opinion" - belief or preference; add
  "confidence": 0.0-1.0.
4. "habit" - repeating behavior; triggers:
  always, usually, every day.
5. "intention" - future plan or goal; add
  "intention_status":
  "planning"|"fulfilled"|"abandoned".
6. "action_effect" - causal relationship
```

```
(A causes B). Add "precondition",  
"action", "outcome", "devalue_sensitive".
```

A.0.2 A.2. Prompt Tinh chỉnh Pass 2 (Persona-Focused Revision)

Pass 2 được dùng để rà lại các memory mang tính người dùng và loại bỏ nhiều hội thoại. Khác với Pass 1, pass này không nhằm tới việc trích xuất toàn bộ thể giới tri thức, mà ưu tiên giữ các fact cá nhân bền vững như experience, habit, intention và opinion.

System Prompt: Pass 2 Persona-Focused

```
You are a memory refinement assistant.  
Your task is to filter and rewrite raw facts  
to ensure they STRICTLY capture the USER's  
long-term persona, history, and preferences.  
OUTPUT RULE: Respond ONLY with valid JSON  
- no prose, no markdown fences.  
Format: {"facts": [<fact>, ...]}  
or {"facts": []}.  
RULES:  
1. DELETE generic conversational filler, AI  
   system prompts, and temporary state updates.  
2. DELETE assistant actions (e.g. "Assistant  
   summarized the meeting").  
3. REWRITE facts to be User-centric. If it's  
   about the USER doing, liking, or knowing  
   something, keep it. If it's about the  
   Assistant, drop it.  
4. ONLY emit experience | habit | intention |  
   opinion in this pass. World and  
   action_effect stay in Pass 1.
```

APPENDIX B. Evaluation and Reflection Prompts

Phụ lục này ghi lại các prompt ở tầng synthesis và evaluation. Đây là phần nối giữa evidence do recall pipeline trả về và câu trả lời cuối cùng của hệ thống, đồng thời cũng là nơi phục vụ chấm điểm tự động trong các benchmark chuẩn.

B.0.1 B.1. Prompt Tổng hợp Câu trả lời (Reflection & Generation)

Prompt generation nhận đầu vào là tập bằng chứng đã được recall. Ở kiến trúc hiện tại, *raw_snippet* có thể được đưa inline cùng mỗi memory khi policy generate yêu cầu thêm grounding nguyên văn; vì vậy, prompt nhấn mạnh việc trả lời chỉ từ evidence được cung cấp.

System Prompt: Answer Generation

```
You are an AI assistant designed to answer
the user's latest query using ONLY the
provided long-term memory evidence.
```

EVIDENCE RULES:

1. Base your answer COMPLETELY on the text listed under [EVIDENCE].
2. If the [EVIDENCE] contradicts your internal knowledge, you MUST trust the [EVIDENCE].
3. DO NOT state "Based on the evidence..." or "The text provided says...". Respond directly.
4. If the evidence does not contain the answer, say exactly: "I do not have enough specific memory to answer this question."

```
<--- BEGIN EVIDENCE --->
```

```
{evidence}
```

```
<--- END EVIDENCE --->
```

B.0.2 B.2. Prompt Chấm điểm Tự động (LLM-as-a-Judge)

Prompt judge dùng cho benchmark pipeline để so sánh câu trả lời sinh ra với đáp án chuẩn. Các luật chấm ưu tiên semantic correctness hơn là trùng khớp ký tự tuyệt đối, và chấp nhận một số sai số nhỏ ở nhóm câu hỏi temporal.

System Prompt: LLM Judge (Temporal Focus)

You are an evaluation judge for a memory system. I will give you a question, a correct answer, and a model response.

Score rubric (0.0-1.0):

- 1.0: correct and complete.
- 0.7-0.9: correct but slightly rephrased or minor detail missing.
- 0.3-0.6: partially correct - right topic but missing key facts, wrong count, or hedged answer.
- 0.0-0.2: wrong, fabricated, or completely missing the answer.

SPECIAL RULE FOR TEMPORAL QUESTIONS:

Do NOT penalize off-by-one errors for counts of days, weeks, or months (e.g., answering "18 days" when the label is "19 days" is still scored 1.0).

OUTPUT FORMAT:

Respond ONLY with a JSON object.

```
{"score": <float between 0.0 and 1.0>,  
  "reason": "<string>"}
```