

HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

GRADUATION THESIS

**CogMem: Khung bộ nhớ hội thoại dài hạn dựa trên
Khoa học nhận thức**

Lê Minh Triết

triet.lm220045@sis.hust.edu.vn

Program: IT1

Supervisor: Cao Tuấn Dũng

Department: Computer Science

School: School of Information and Communications Technology

HANOI, 06/2026

HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

GRADUATION THESIS

**CogMem: Khung bộ nhớ hội thoại dài hạn dựa trên
Khoa học nhận thức**

Lê Minh Triết

triet.lm220045@sis.hust.edu.vn

Program: IT1

Supervisor: Cao Tuấn Dũng _____

Signature

Department: Computer Engineering

School: School of Information and Communications Technology

HANOI, 06/2026

ACKNOWLEDGMENT

Trước hết, tôi xin bày tỏ lòng biết ơn sâu sắc đến Thầy Cao Tuấn Dũng — người đã trực tiếp hướng dẫn và hỗ trợ tôi trong suốt quá trình thực hiện đồ án tốt nghiệp. Thầy không chỉ truyền đạt kiến thức chuyên môn mà còn là người thầy định hướng cho tôi về cách tiếp cận vấn đề một cách khoa học và có phương pháp, cũng như là người khơi gợi những ý tưởng đầu tiên của tôi về đồ án này.

Tôi cũng xin cảm ơn các thầy cô trong Khoa Kỹ thuật Máy tính, Trường Đại học Bách khoa Hà Nội, đã trang bị cho tôi nền tảng kiến thức vững chắc trong suốt bốn năm học tại đây.

ABSTRACT

Các hệ thống tác nhân hội thoại AI hiện nay gặp phải thách thức cơ bản trong việc duy trì bộ nhớ dài hạn xuyên suốt nhiều phiên hội thoại. Khi ngữ cảnh (context window) vượt quá giới hạn, thông tin cũ bị loại bỏ khiến tác nhân mất khả năng ghi nhớ thông tin người dùng qua thời gian. Các giải pháp RAG (Retrieval-Augmented Generation) thông thường dựa trên cơ sở dữ liệu vector không đủ khả năng xử lý các truy vấn phức tạp, đặc biệt là các truy vấn đòi hỏi suy luận multi-hop hay suy luận về thói quen và quan hệ nhân quả.

Đồ án này đề xuất CogMem — một khung cấu trúc bộ nhớ hội thoại dài hạn được thiết kế dựa trên các nguyên lý của khoa học nhận thức (cognitive science). CogMem bao gồm bốn đóng góp chính: (1) Cấu trúc đồ thị bộ nhớ (Memory Graph) với 6 mạng nhánh chuyên biệt (World, Experience, Opinion, Habit, Intention, Action-Effect) và 7 loại liên kết, phản ánh chính xác các phân hệ bộ nhớ trong não người; (2) Cơ sở siêu dữ liệu phi tổn hao (Lossless Node Metadata) với trường dữ liệu nguyên bản (raw_snippet) nhằm giữ nguyên văn bản hội thoại, hạn chế tình trạng mất mát thông tin do quá trình nén của LLM; (3) Vùng đệm không gian-thời gian (Episodic Buffer) ứng dụng thuật toán lan truyền kích hoạt SUM thay cho hàm MAX, kết hợp với 3 cơ chế kiểm soát chu trình (Refractory, Firing Quota, Saturation), cho phép tích lũy bằng chứng từ nhiều hướng đồng thời; (4) Cơ chế định tuyến truy vấn thích ứng (Adaptive Query Routing) phân loại câu hỏi thành 6 loại hình (semantic, temporal, causal, prospective, preference, multi-hop) nhằm áp dụng trọng số động RRF (Reciprocal Rank Fusion).

Kết quả thực nghiệm trên các benchmark LongMemEval-S và LoCoMo cho thấy kiến trúc đề xuất cải thiện đáng kể so với baseline HINDSIGHT, đặc biệt trên các category khó như multi-hop, temporal reasoning và preference retrieval.

Lê Minh Triết

triet.lm220045@sis.hust.edu.vn

TABLE OF CONTENTS

CHAPTER 1. INTRODUCTION.....	1
1.1 Giới thiệu bài toán	1
1.1.1 Bối cảnh và vấn đề	1
1.1.2 Hạn chế của các giải pháp hiện tại	1
1.1.3 Động lực và đóng góp của đề án.....	2
1.1.4 Cấu trúc của đề án	3
CHAPTER 2. LITERATURE REVIEW	4
2.1 Tổng quan Lý thuyết và Các hệ thống liên quan	4
2.1.1 Thách thức cốt lõi về Bộ nhớ của Mô hình Ngôn ngữ Lớn (LLMs) .	4
2.1.2 Cơ sở Lý thuyết: Khoa học Nhận thức và Đồ thị Tri thức	4
2.1.3 Tiến trình phát triển hệ thống Bộ nhớ Dài hạn cho Tác nhân	5
2.1.4 Dữ liệu đánh giá (Evaluation Benchmarks).....	7
2.1.5 Hạn chế cốt lõi của các Khung hệ thống Bộ nhớ hiện nay (Problem Formulation).....	7
CHAPTER 3. METHODOLOGY.....	9
3.1 Phương pháp đề xuất.....	9
3.1.1 Tổng quan kiến trúc hệ thống CogMem.....	9
3.1.2 Đóng góp 1: Đồ thị Bộ nhớ Kế thừa Nhận thức (Cognitively-Grounded Memory Graph).....	10
3.1.3 Đóng góp 2: Siêu dữ liệu Node phi tổn hao (Lossless Node Metadata) và Raw Snippet	13
3.1.4 Đóng góp 3: Episodic Buffer với SUM Spreading Activation + Cycle Guards	14
3.1.5 Đóng góp 4: Adaptive Query Routing	16

CHAPTER 4. THEORETICAL ANALYSIS	18
4.1 Phân tích lý thuyết	18
4.1.1 Cơ sở khoa học nhận thức cho Memory Graph (6 Networks).....	18
4.1.2 Cơ sở khoa học nhận thức cho Raw Snippet.....	21
4.1.3 Cơ sở khoa học nhận thức cho SUM + Cycle Guards.....	21
4.1.4 Cơ sở khoa học nhận thức cho Adaptive Query Routing.....	22
CHAPTER 5. NUMERICAL RESULTS.....	24
5.1 Kết quả thực nghiệm	24
5.1.1 Thiết kế thực nghiệm.....	24
5.1.2 Ablation study (E1-E7).....	25
5.1.3 Per-category accuracy breakdown.....	26
5.1.4 Error analysis và case studies	26
CHAPTER 6. CONCLUSIONS	28
6.1 Kết luận và hướng phát triển	28
6.1.1 Tổng kết đóng góp.....	28
6.1.2 Kết quả đánh giá sơ bộ	29
6.1.3 Hạn chế.....	30
6.1.4 Hướng phát triển tương lai	30
6.1.5 Kết luận	31
6.2 Tài liệu tham khảo	32
REFERENCE	33
APPENDIX.....	35
A. GRADUATION THESIS GUIDANCE	35
B. Phụ lục A: Các Prompt Trích xuất Tri thức (Retain Pipeline)	36
B.0.1 A.1. Prompt Trích xuất Pass 1 (Fact Extraction)	36
B.0.2 A.2. Prompt Tinh chỉnh Pass 2 (Persona-Focused Revision)	37

C. USE CASE DESCRIPTIONS.....	38
D. Phụ lục B: Các Prompt Dành cho Đánh giá (Evaluation & Reflection)	39
D.0.1 B.1. Prompt Tổng hợp Câu trả lời (Reflection & Generation)	39
D.0.2 B.2. Prompt Chấm điểm Tự động (LLM-as-a-Judge)	39

LIST OF FIGURES

Figure 3.1	Sáu mạng bộ nhớ của CogMem	11
Figure 3.2	Phân biệt Habit và Action-Effect	12
Figure 3.3	Bảy loại liên kết trong CogMem	13
Figure 3.4	2-Layer Node Schema	14
Figure 3.5	Ba cơ chế bảo vệ chu trình	16
Figure 3.6	Adaptive Query Routing	17
Figure 4.1	Semantic Memory và World Network	18
Figure 4.2	Habit Memory và Habit Network	19
Figure 4.3	Intention Lifecycle	20
Figure 4.4	Theory of Event Coding và Action-Effect Network	21
Figure 4.5	Fuzzy Trace Theory và Raw Snippet	21
Figure 4.6	Episodic Buffer của Baddeley	22
Figure 4.7	Attentional Selection và Adaptive Routing	23
Figure 6.1	Tổng kết đóng góp	29
Figure 6.2	Hạn chế của đề án	30
Figure 6.3	Future Work Roadmap	31

LIST OF TABLES

Table 2.1	So sánh khái quát các hệ thống bộ nhớ dài hạn liên quan . . .	6
Table 3.1	Các fact type cốt lõi và metadata chuyên biệt	11
Table 3.2	So sánh HINDSIGHT (MAX) và CogMem (SUM)	15
Table 3.3	Adaptive RRF weights theo query type trong implementation hiện tại	17
Table 4.1	Intention lifecycle và typed transition semantics	20
Table 5.1	Experiment Setup	24
Table 5.2	Ablation Summary (Placeholder -	26

CHAPTER 1. INTRODUCTION

1.1 Giới thiệu bài toán

1.1.1 Bối cảnh và vấn đề

Các tác nhân hội thoại hiện đại đã đạt tiến bộ rõ rệt ở những tác vụ ngắn hạn như trả lời câu hỏi, lập kế hoạch theo từng phiên làm việc, hay tương tác dựa trên một cửa sổ ngữ cảnh lớn. Tuy nhiên, khi tương tác kéo dài qua nhiều ngày hoặc nhiều phiên hội thoại, hạn chế cốt lõi vẫn nằm ở khả năng duy trì *bộ nhớ dài hạn* một cách có cấu trúc và có thể truy hồi. Khi số lượng token vượt khỏi cửa sổ ngữ cảnh, thông tin từ các phiên trước dần bị loại bỏ; hệ quả là tác nhân mất dấu lịch sử người dùng, các mốc thời gian, các sở thích lặp lại và cả những kế hoạch còn dang dở.

Vấn đề này đặc biệt quan trọng trong các ứng dụng cần tính liên tục cao như trợ lý cá nhân, hệ thống chăm sóc khách hàng, tác nhân hỗ trợ học tập, hay các AI companion được kỳ vọng đồng hành lâu dài cùng một người dùng. Trong những bối cảnh đó, bộ nhớ không chỉ là khả năng “nhớ lại một câu đã nói”, mà còn là năng lực tái sử dụng các sự kiện, mối liên hệ và tín hiệu hành vi dưới một dạng biểu diễn đủ bền vững để phục vụ cho truy vấn tương lai.

1.1.2 Hạn chế của các giải pháp hiện tại

Các hướng tiếp cận phổ biến cho bài toán bộ nhớ dài hạn thường rơi vào một trong hai cực: (1) lưu trữ văn bản thô rồi truy xuất bằng vector similarity, hoặc (2) nén hội thoại thành các “fact” gọn hơn để lưu trong đồ thị hoặc cơ sở dữ liệu vector. Cả hai hướng đều hữu ích, nhưng vẫn để lộ nhiều giới hạn thực dụng:

- **Nén có tổn hao (lossy compression):** Khi LLM rút gọn hội thoại thành các fact ngắn, nhiều chi tiết định lượng, sắc thái cảm xúc, hoặc ngữ cảnh nguyên bản bị mất đi và khó khôi phục về sau.
- **Biểu diễn phẳng hoặc bán-phẳng:** Nếu mọi fact đều bị đưa vào cùng một không gian biểu diễn, hệ thống khó phân biệt giữa kiến thức khách quan, sự kiện cá nhân, thói quen, kế hoạch tương lai và quan hệ nhân quả.
- **Truy hồi đa bước còn yếu:** Những câu hỏi cần nối nhiều tín hiệu yếu, nhiều phiên hội thoại, hoặc nhiều loại quan hệ khác nhau thường không được xử lý tốt bởi retrieval đơn thuần dựa trên một kênh.
- **Định tuyến truy vấn còn tĩnh:** Một câu hỏi temporal, causal hay prospective không nên được đối xử giống hệt một câu hỏi semantic. Việc dùng một profile truy hồi đồng nhất cho mọi loại truy vấn làm giảm hiệu quả của từng channel

chuyên biệt.

Các phân tích và thí nghiệm nhắm đích sau này trong dự án cũng gợi ý thêm một điểm quan trọng: ngay cả khi mở rộng hệ thống bằng các mạng bộ nhớ chuyên biệt, giá trị của từng mạng không phải lúc nào cũng xuất hiện đồng đều trên mọi benchmark. Nói cách khác, bài toán không chỉ là “thêm nhiều node type hơn”, mà là thiết kế một biểu diễn đủ đúng để những loại tín hiệu như habit, intention hay action-effect thật sự có nơi tồn tại và được truy hồi đúng lúc.

1.1.3 Động lực và đóng góp của đề án

Từ các giới hạn trên, đề án này đề xuất **CogMem** – một khung bộ nhớ hội thoại dài hạn dựa trên khoa học nhận thức (*cognitive science*) và đồ thị tri thức dị thể. Điểm xuất phát của CogMem là quan sát rằng bộ nhớ người không vận hành như một danh sách phẳng; thay vào đó, các loại ký ức khác nhau được tổ chức thành những hệ con có vai trò khác nhau trong hành vi và suy luận.

Theo tinh thần đó, CogMem tập trung vào bốn đóng góp cốt lõi:

1. **Cognitively-Grounded Memory Graph:** Tổ chức bộ nhớ thành sáu mạng fact chính – *world, experience, opinion, habit, intention, action_effect* – cùng bảy loại liên kết để duy trì cấu trúc quan hệ rõ ràng.
2. **Lossless Node Metadata:** Bảo toàn *raw_snippet* như phần văn bản gốc đi kèm mỗi node, giúp giảm mất mát thông tin giữa giai đoạn lưu trữ và giai đoạn sinh câu trả lời.
3. **Episodic Buffer với SUM Spreading Activation:** Dùng phép cộng tín hiệu thay cho phép chọn cực đại, kết hợp các cơ chế kiểm soát chu trình để truy hồi được bằng chứng phân tán qua nhiều đường.
4. **Adaptive Query Routing:** Phân loại truy vấn thành các nhóm semantic, temporal, causal, prospective, preference và multi-hop; từ đó áp dụng profile dung hợp phù hợp cho từng loại.

Trong báo cáo này, bốn đóng góp trên được trình bày như **kiến trúc luận án cốt lõi** của CogMem. Các thí nghiệm nhắm đích thực hiện về sau trong dự án cho thấy các mạng bộ nhớ chuyên biệt như *intention* và *action_effect* không tạo lợi thế đồng đều trên mọi tình huống; thay vào đó, chúng đặc biệt hữu ích khi tín hiệu kế hoạch hoặc quan hệ nhân quả không thể được hấp thụ tự nhiên bởi các fact type khác như *world* hoặc *experience*. Kết luận này làm cho động lực của CogMem thận trọng hơn, nhưng cũng thực tế hơn: các cấu trúc nhận thức mới không phải là “thuốc chữa bách bệnh”, mà là những representational slots cần thiết cho các lớp câu hỏi nhất định.

1.1.4 Cấu trúc của đề án

Đề án được tổ chức như sau:

- **Chương 2:** Literature Review – tổng quan các hướng tiếp cận bộ nhớ dài hạn, cơ sở khoa học nhận thức, đồ thị tri thức và các benchmark liên quan.
- **Chương 3:** Methodology – mô tả kiến trúc CogMem, retain pipeline, recall pipeline và bốn đóng góp cốt lõi của hệ thống.
- **Chương 4:** Theoretical Analysis – phân tích cơ sở nhận thức cho các memory networks, raw snippet, SUM spreading activation và adaptive routing.
- **Chương 5:** Numerical Results – trình bày kết quả thực nghiệm và các phân tích định lượng.
- **Chương 6:** Conclusions – tổng kết đóng góp, hạn chế và hướng phát triển.

Sau khi xác định bài toán và động lực của CogMem, Chương 2 sẽ hệ thống hóa nền tảng lý thuyết và các hệ thống liên quan nhằm làm rõ khoảng trống mà kiến trúc đề xuất cần lấp đầy.

CHAPTER 2. LITERATURE REVIEW

Tiếp nối bối cảnh bài toán từ Chương 1, chương này tổng hợp nền tảng khoa học nhận thức, đồ thị tri thức và các hệ thống bộ nhớ dài hạn liên quan, từ đó xác định rõ khoảng trống mà CogMem hướng tới.

2.1 Tổng quan Lý thuyết và Các hệ thống liên quan

Chương này tập trung vào hai trụ cột: (1) khoa học nhận thức như một nguồn cảm hứng cho việc chuyên biệt hóa các loại ký ức, và (2) đồ thị tri thức như một hình thức biểu diễn cho phép truy hồi đa bước có kiểm soát. Trên nền tảng đó, chúng tôi đối chiếu các hệ thống bộ nhớ đương đại để chỉ ra những hạn chế còn tồn tại về nén thông tin, tổ chức fact type và định tuyến truy vấn.

2.1.1 Thách thức cốt lõi về Bộ nhớ của Mô hình Ngôn ngữ Lớn (LLMs)

Mặc dù các Mô hình Ngôn ngữ Lớn (LLMs) đạt thành tựu cao trong xử lý ngôn ngữ tự nhiên, chúng vẫn gặp những giới hạn cơ bản khi phải duy trì ký ức dài hạn cho một người dùng hoặc một agent cụ thể:

- **Giới hạn cửa sổ ngữ cảnh:** Đưa toàn bộ lịch sử hội thoại dài hạn vào prompt là tốn kém và không bền vững. Khi lịch sử tăng lên, hệ thống buộc phải chọn lọc hoặc bỏ bớt thông tin.
- **Hiện tượng mất tín hiệu ở ngữ cảnh dài:** Các nghiên cứu về “lost in the middle” cho thấy thông tin ở giữa cửa sổ ngữ cảnh thường khó được sử dụng ổn định bằng thông tin ở đầu hoặc cuối.
- **Thiếu grounding dài hạn:** Nếu không có một bộ nhớ ngoài được tổ chức tốt, mô hình dễ sinh câu trả lời dựa trên xác suất ngôn ngữ thay vì bằng chứng đã quan sát.
- **Khó cập nhật liên tục:** Fine-tuning không phải là cơ chế phù hợp để tiếp nhận dòng hội thoại cá nhân hóa theo thời gian thực; bộ nhớ ngoài là hướng thực tế hơn cho bài toán này.

Vì vậy, bộ nhớ dài hạn cho tác nhân hội thoại nên được xem như một *hệ thống ngoài mô hình (external memory system)* với cấu trúc lưu trữ, truy hồi và tổng hợp riêng, thay vì chỉ là phần kéo dài của context window.

2.1.2 Cơ sở Lý thuyết: Khoa học Nhận thức và Đồ thị Tri thức

a, Khoa học Nhận thức và Hệ thống Phân loại Bộ nhớ

Một điểm then chốt của khoa học nhận thức là bộ nhớ người không phải một khối đơn nhất. Theo các phân loại cổ điển của Tulving, Squire và các cộng sự, bộ

nhớ dài hạn bao gồm nhiều hệ con với vai trò và nền tảng thần kinh khác nhau:

- **Semantic memory**: lưu trữ kiến thức chung, tương đối độc lập với ngữ cảnh cụ thể.
- **Episodic memory**: lưu trữ các sự kiện cá nhân gắn với thời gian và trải nghiệm.
- **Habit / procedural memory**: gắn với các mẫu hành vi lặp lại và phản xạ hành động.
- **Prospective memory**: liên quan tới việc “nhớ để làm” trong tương lai, tức các kế hoạch và mục tiêu chưa hoàn tất.

Ý tưởng cốt lõi rút ra cho hệ thống AI là: nếu nhiều loại tín hiệu nhận thức có bản chất khác nhau, chúng không nên bị ép vào cùng một kiểu biểu diễn phẳng. Đây chính là động lực cho kiến trúc nhiều fact type của CogMem.

b, Đồ thị Tri thức (Knowledge Graphs) và Chức năng Biểu diễn

Đồ thị tri thức (Knowledge Graph - KG) cho phép biểu diễn các thực thể và quan hệ của chúng dưới dạng cấu trúc tường minh. So với một kho vector thuần túy, KG có hai lợi thế quan trọng:

- **Biểu diễn quan hệ hiện hình**: Quan hệ thời gian, nhân quả, đồng tham chiếu thực thể hay chuyển pha trạng thái có thể được lưu trực tiếp bằng edge thay vì phải suy ngược hoàn toàn từ tương đồng ngữ nghĩa.
- **Truy hồi đa bước**: KG hỗ trợ các thuật toán đi đồ thị, spreading activation và các dạng kết hợp tín hiệu xuyên nhiều node, phù hợp với các câu hỏi multi-hop hoặc cross-session.

Với các bài toán bộ nhớ hội thoại, KG đặc biệt hữu ích khi thông tin trả lời không nằm gọn trong một câu duy nhất mà bị phân tán qua nhiều phiên, nhiều sự kiện hoặc nhiều loại fact khác nhau.

2.1.3 Tiến trình phát triển hệ thống Bộ nhớ Dài hạn cho Tác nhân

a, HINDSIGHT: Đồ thị dị thể và truy hồi đa kênh

HINDSIGHT là một trong những hệ thống đáng chú ý nhất trong dòng bộ nhớ dài hạn dạng đồ thị cho agent hội thoại. Ở mức khái niệm, HINDSIGHT kết hợp:

- fact extraction từ hội thoại,
- lưu trữ dưới dạng heterogeneous graph,
- truy hồi song song trên nhiều channel như semantic, BM25, graph và temporal,
- và dung hợp bằng Reciprocal Rank Fusion (RRF).

Đóng góp lớn của HINDSIGHT là chứng minh rằng bộ nhớ dạng đồ thị có thể vượt xa vector store thuần trong các bài toán hội thoại dài. Tuy nhiên, khi nhìn từ góc độ kiến trúc, HINDSIGHT vẫn để lộ một số giới hạn mà CogMem muốn giải quyết:

- chưa có các typed network riêng cho *habit*, *intention* và *action_effect*,
- chiến lược fusion mặc định dùng profile trọng số tĩnh cho mọi loại truy vấn,
- và lan truyền kích hoạt kiểu lấy cực đại khiến bằng chứng yếu từ nhiều đường khó cộng dồn.

b, HippoRAG2: Truy hồi đồ thị nhấn mạnh liên kết tri thức

HippoRAG2 thể hiện hướng đi nổi bật ở phía graph retrieval, đặc biệt trong các bài toán cần liên kết nhiều thực thể hoặc nhiều facts rời nhau. Ưu điểm của dòng tiếp cận này là biến truy hồi thành một quá trình lan truyền tín hiệu trên topology của đồ thị thay vì chỉ dựa vào embedding similarity.

Tuy nhiên, các hệ thống kiểu HippoRAG2 vẫn chủ yếu mạnh ở lớp quan hệ ngữ nghĩa và liên kết tri thức, trong khi những cấu trúc như kế hoạch tương lai, thói quen hành vi hay bộ ba nhân quả hành động-kết quả chưa được mô hình hóa như các memory network chuyên biệt.

c, Các hệ lưu trữ phẳng và vector-centric (Mem0, MemGPT)

Bên cạnh nhánh đồ thị, nhiều hệ thống khác chọn cách lưu fact hoặc chunk trong vector store và tổ chức truy hồi quanh similarity search hoặc memory paging:

- **Mem0**: nhấn mạnh extraction + vector retrieval, phù hợp với memory lookup nhanh nhưng hạn chế hơn khi cần quan hệ nhiều bước.
- **MemGPT**: mô phỏng phân tầng bộ nhớ theo kiểu hệ điều hành, tách vùng context đang hoạt động và vùng lưu trữ ngoài.

Các hướng này hữu ích về mặt vận hành, nhưng khi đánh giá theo nhu cầu của hội thoại dài hạn, chúng thường thiếu topology đủ rõ để mô hình hóa temporal chains, causal links hay lifecycle của kế hoạch chưa hoàn thành.

Table 2.1: So sánh khái quát các hệ thống bộ nhớ dài hạn liên quan

Hệ thống	Graph-based	Temporal	Habit	Intention	Action-Effect	Cơ chế truy hồi chính
HINDSIGHT	Yes	Yes	No	No	No	4-channel retrieval + equal-weight RRF
HippoRAG2	Yes	Limited	No	No	No	Graph retrieval / spreading activation
Mem0	No	Limited	No	No	No	Vector similarity + extracted memories
MemGPT	No	Limited	No	No	No	Memory paging / context management
CogMem (đề xuất)	Yes	Yes	Yes	Yes	Yes	Adaptive routing + BFS/SUM graph recall

2.1.4 Dữ liệu đánh giá (Evaluation Benchmarks)

a, LongMemEval-S (Hội thoại đa phiên)

LongMemEval-S là benchmark phù hợp để đánh giá khả năng xử lý hội thoại dài qua nhiều phiên, đặc biệt ở các nhóm câu hỏi liên quan tới multi-session retrieval, temporal reasoning và preference. Đây là benchmark quan trọng để đo hiệu năng hệ thống ở cấp end-to-end.

b, LoCoMo (Lý luận multi-hop)

LoCoMo tập trung mạnh hơn vào truy hồi nhiều bước và nối bằng chứng qua các đoạn hội thoại dài. Vì vậy, benchmark này đặc biệt hữu ích để quan sát khả năng giữ mạch reasoning khi thông tin trả lời không nằm trọn trong một fact riêng lẻ.

c, Giới hạn của benchmark chuẩn

LongMemEval-S và LoCoMo là các benchmark hệ thống rất cần thiết, nhưng chúng không phải lúc nào cũng đủ để cô lập giá trị của từng typed network mới. Trong quá trình phát triển CogMem, điều này dẫn tới nhu cầu bổ sung các thí nghiệm nhắm đích để kiểm tra riêng những dạng tín hiệu như prospective memory hoặc action-effect reasoning. Trong báo cáo này, nhận định đó chỉ được dùng như bối cảnh phương pháp luận; phần thực nghiệm chính thức vẫn được trình bày ở Chương 5.

2.1.5 Hạn chế cốt lõi của các Khung hệ thống Bộ nhớ hiện nay (Problem Formulation)

Từ tổng quan trên, có thể quy các khoảng trống chính của các hệ bộ nhớ đương đại về bốn nhóm:

1. **Lossy compression:** fact extraction làm gọn bộ nhớ nhưng dễ đánh mất số liệu, cảm xúc và văn bản gốc cần cho generation.
2. **Thiếu typed cognitive structures:** các tín hiệu như habit, intention hay action-effect thường không có “chỗ ở” riêng trong mô hình dữ liệu.
3. **Lan truyền bằng chứng chưa đủ giàu:** retrieval kiểu chỉ chọn đường mạnh nhất có thể làm rơi mất nhiều tín hiệu yếu nhưng bổ sung cho nhau.
4. **Định tuyến truy vấn còn cào bằng:** cùng một recipe fusion được áp cho semantic, temporal, causal hay prospective queries, dù bản chất truy hồi của chúng khác nhau.

Từ khoảng trống lý thuyết và kỹ thuật đó, Chương 3 sẽ trình bày CogMem như một

kiến trúc bộ nhớ dài hạn nhằm kết hợp biểu diễn nhận thức chuyên biệt với cơ chế truy hồi thích ứng theo loại truy vấn.

CHAPTER 3. METHODOLOGY

Dựa trên các giới hạn đã phân tích ở Chương 2, chương này trình bày kiến trúc phương pháp luận cốt lõi của CogMem: một hệ thống bộ nhớ hội thoại dài hạn dựa trên đồ thị dị thể, retain pipeline nhiều bước và recall pipeline có định tuyến thích ứng.

3.1 Phương pháp đề xuất

3.1.1 Tổng quan kiến trúc hệ thống CogMem

CogMem được thiết kế như một kiến trúc gồm ba pipeline liên tiếp:

1. **Retain pipeline:** chuẩn hóa hội thoại, trích xuất fact, sinh embedding, lưu node và tạo liên kết.
2. **Recall pipeline:** chạy song song nhiều kênh truy hồi, phân tích loại truy vấn, rồi dung hợp kết quả theo profile phù hợp.
3. **Reflect / Synthesis pipeline:** tổng hợp evidence được recall để sinh câu trả lời bám dữ kiện.

Trong phạm vi luận án này, **BFS graph retrieval với SUM spreading activation và ba cycle guards** được xem là đường triển khai chuẩn của CogMem. Một số retriever khác được thêm vào ở các giai đoạn phát triển sau nhằm phục vụ nghiên cứu và ablation, nhưng không thay đổi lõi phương pháp luận được trình bày ở đây.

a, Retain pipeline

Retain pipeline hiện thực hóa bộ nhớ dài hạn theo chuỗi bước sau:

1. **Chunking theo hội thoại:** hội thoại được chia thành các đoạn phù hợp cho extraction.
2. **Pass 1 extraction:** LLM đọc ngữ cảnh mixed-speaker để trích xuất đủ sáu fact type, đặc biệt là *world* và *action_effect*.
3. **Pass 2 extraction:** một pass persona-focused đọc lại ngữ cảnh người dùng để tinh chỉnh các fact cá nhân như *experience*, *habit*, *intention* và *opinion*.
4. **Dedup và chuẩn hóa metadata:** hợp nhất kết quả giữa các pass, chuẩn hóa status, quan hệ chuyển pha và trường metadata chuyên biệt.
5. **Embedding + storage:** mỗi fact được gắn embedding và lưu vào đồ thị bộ nhớ cùng *raw_snippet*.
6. **Link creation:** tạo các liên kết entity, temporal, semantic, causal, s_r_link, a_o_causal và transition.

Điểm quan trọng là retain pipeline không chỉ lưu một câu tóm tắt ngữ nghĩa, mà còn bảo toàn văn bản nguồn để phục vụ giai đoạn sinh câu trả lời về sau.

b, Recall pipeline

Recall pipeline của CogMem chạy song song bốn kênh:

- semantic retrieval,
- BM25 retrieval,
- graph retrieval,
- temporal retrieval.

Trước khi fusion, hệ thống phân tích truy vấn để xác định *query type* và *temporal constraint* nếu có. Kết quả phân tích này quyết định:

- fact types nào cần ưu tiên,
- profile trọng số RRF nào cần dùng,
- và có cần hậu xử lý đặc biệt cho bằng chứng prospective hoặc causal hay không.

c, Reflect / Synthesis pipeline

Sau khi recall hoàn tất, hệ thống chọn top evidence để đưa vào prompt sinh câu trả lời. Trong luồng này, *raw_snippet* đóng vai trò là lớp bằng chứng nguyên văn. Tùy cấu hình của giai đoạn sinh, snippet có thể được đưa thẳng vào prompt hoặc chỉ được giữ như nguồn tham chiếu nội bộ; tuy nhiên, ở mức kiến trúc, trường *raw_snippet* luôn được bảo toàn end-to-end để tránh mất dữ kiện.

3.1.2 Đóng góp 1: Đồ thị Bộ nhớ Kế thừa Nhận thức (Cognitively-Grounded Memory Graph)

a, Nền tảng tâm lý

Động lực của CogMem đến từ quan sát rằng bộ nhớ người không phải một kho đồng nhất. Các nhóm ký ức như semantic memory, episodic memory, habit memory, prospective memory hay action-effect binding có vai trò khác nhau trong suy luận và hành vi. Vì vậy, việc ép mọi dữ liệu hội thoại vào cùng một dạng fact sẽ làm suy yếu tính phân biệt về chức năng.

CogMem chuyển trực giác này thành một memory graph dị thể gồm nhiều fact type chuyên biệt. Mỗi network không chỉ khác nhau về nhãn, mà còn khác nhau ở metadata, loại liên kết, và chiến lược truy hồi được ưu tiên khi đối mặt với từng loại câu hỏi.

[FIGURE PLACEHOLDER]

Hình 3.1: Sáu mạng bộ nhớ của CogMem và cơ sở nhận thức tương ứng.

Figure 3.1: Sáu mạng bộ nhớ của CogMem

b, Sáu mạng bộ nhớ

CogMem hiện dùng sáu fact type cốt lõi:

1. **World:** kiến thức khách quan hoặc tương đối ổn định về thế giới.
2. **Experience:** sự kiện cá nhân đã xảy ra, thường gắn với thời gian hoặc bối cảnh cụ thể.
3. **Opinion:** nhận định, sở thích hoặc đánh giá chủ quan.
4. **Habit:** mẫu hành vi lặp lại mang tính stimulus-response.
5. **Intention:** kế hoạch hoặc mục tiêu hướng tới tương lai, có trạng thái *planning* / *fulfilled* / *abandoned*.
6. **Action-Effect:** bộ ba nhân quả *precondition* – *action* – *outcome*.

Table 3.1: Các fact type cốt lõi và metadata chuyên biệt

Fact type	Vai trò biểu diễn	Metadata / tín hiệu chuyên biệt
world	Kiến thức khách quan, mô tả ổn định	text, entities, raw_snippet
experience	Sự kiện cá nhân đã xảy ra	occurred_start, occurred_end, mentioned_at
opinion	Đánh giá hoặc sở thích chủ quan	confidence
habit	Mẫu hành vi lặp lại	liên kết s_r_link đến các experience liên quan
intention	Kế hoạch và mục tiêu tương lai	intention_status; có thể mang thêm mô tả “why” hoặc tín hiệu thời gian từ extraction
action_effect	Quy luật nhân quả ở cấp hành động	precondition, action, outcome, confidence, devalue_sensitive

Việc tách riêng *habit*, *intention* và *action_effect* không nên được hiểu như một khẳng định rằng ba mạng này luôn tạo ra cải thiện đồng đều trên mọi tập dữ liệu. Thay vào đó, chúng cung cấp các “representational slots” mới cho những tín hiệu mà *world* hoặc *experience* thường mô tả không đầy đủ, đặc biệt ở các câu hỏi

preference, prospective và causal.

c, Phân biệt Habit vs. Action-Effect

CogMem tách *habit* và *action_effect* vì hai loại này phản ánh hai cơ chế nhận thức khác nhau:

- **Habit:** phản ứng lặp lại, mang tính S-R, hình thành từ tần suất và ngữ cảnh quen thuộc.
- **Action-Effect:** quy luật nhân quả có chủ đích, nơi một hành động được chọn vì tạo ra một kết quả quan sát được.

Trong thực tế hội thoại, hai loại tín hiệu này dễ bị trộn lẫn nếu chỉ dùng fact phẳng. Việc tách riêng giúp truy hồi preference hoặc causal evidence rõ hơn, đồng thời mở đường cho các thí nghiệm ablation theo từng cấu phần.

[FIGURE PLACEHOLDER]

Hình 3.2: Phân biệt Habit (S-R) và Action-Effect (A-O).

Figure 3.2: Phân biệt Habit và Action-Effect

d, Bảy loại liên kết (Edge Types)

Trên đồ thị CogMem, thông tin được kết nối bởi bảy nhóm liên kết chính:

1. **entity:** nối các node cùng nhắc tới một thực thể.
2. **temporal:** mô tả quan hệ trước-sau giữa các sự kiện.
3. **semantic:** nối các node có tương đồng ngữ nghĩa cao.
4. **causal:** quan hệ nhân quả hoặc ảnh hưởng giữa các fact.
5. **s_r_link:** liên kết hỗ trợ habit bằng các experience cùng mẫu kích thích-phản ứng.
6. **a_o_causal:** liên kết từ action_effect tới các fact quan sát được làm bằng chứng outcome.
7. **transition:** liên kết chuyển pha trạng thái của một biểu diễn theo thời gian.

Riêng *transition* là một edge type duy nhất nhưng mang *transition_type* bên trong. Trong implementation hiện tại, các typed transition cốt lõi gồm:

- `fulfilled_by:` intention → experience,
- `triggered:` experience → intention,
- `enabled_by:` intention → intention,

- `revised_to`: `opinion` → `opinion`,
- `contradicted_by`: `world` → `world`.

Lưu ý: *abandoned* là một *intention_status*, không phải một transition edge riêng.

[FIGURE PLACEHOLDER]

Hình 3.3: Bảy loại liên kết trong CogMem.

Figure 3.3: Bảy loại liên kết trong CogMem

3.1.3 Đóng góp 2: Siêu dữ liệu Node phi tổn hao (Lossless Node Metadata) và Raw Snippet

a, Vấn đề: nén dữ liệu có tổn hao

Các hệ thống bộ nhớ dựa trên extraction thường phải nén hội thoại dài thành một số fact ngắn hơn để có thể lập chỉ mục và truy hồi hiệu quả. Tuy nhiên, phép nén này không đảo ngược được. Những dữ kiện như con số chính xác, cụm từ nguyên văn, trạng thái cảm xúc hoặc các tín hiệu “nhỏ nhưng quyết định” thường biến mất khỏi bản tóm tắt.

Ví dụ:

```
Original conversation:
"I just quit my job at VCCorp today.
I'm really sad because my old team was
like family. DI offered me 40% more pay.
I start there on April 1st."

Compressed fact:
"User switched from VCCorp to DI in
April 2024."
```

Fact nén trên đủ cho semantic retrieval cơ bản, nhưng không còn bảo toàn những chi tiết như tỷ lệ tăng lương, trạng thái cảm xúc hay chính xác ngày khởi đầu.

b, Giải pháp: 2-layer node schema

CogMem giải quyết vấn đề này bằng cách giữ đồng thời hai lớp biểu diễn:

- **fact text / embedding**: lớp nén dùng cho retrieval.
- **raw_snippet**: lớp nguyên văn dùng cho grounding khi cần sinh câu trả lời chi tiết.

Minh họa:

```

{
  "fact_type": "experience",
  "text": "User switched from VCCorp to DI
          in April 2024",
  "embedding": [...],
  "raw_snippet": "I just quit my job at
                  VCCorp today... DI offered
                  me 40% more pay...",
  "metadata": {
    "raw_snippet_present": true
  }
}

```

Thiết kế này cho phép CogMem vừa truy hồi nhanh trên representation đã nén, vừa giữ được bằng chứng nguyên văn khi giai đoạn synthesis cần chi tiết chính xác. Ở implementation hiện tại, snippet có thể được đưa trực tiếp vào prompt generate khi policy của evaluation hoặc runtime bật chế độ sử dụng verbatim evidence; nhưng ngay cả khi policy đó thay đổi, *raw_snippet* vẫn được bảo toàn như một thành phần lõi của dữ liệu.

[FIGURE PLACEHOLDER]

Hình 3.4: 2-layer node schema với fact text và raw_snippet.

Figure 3.4: 2-Layer Node Schema

3.1.4 Đóng góp 3: Episodic Buffer với SUM Spreading Activation + Cycle Guards

a, Vấn đề: MAX chỉ giữ đường mạnh nhất

Một hạn chế của graph retrieval kiểu truyền thống là chỉ cho phép một nguồn bằng chứng “mạnh nhất” quyết định activation ở node đích. Dạng công thức này phù hợp với trường hợp evidence tập trung, nhưng dễ làm mất tín hiệu khi câu trả lời phụ thuộc vào nhiều đường yếu bổ sung cho nhau.

$$A(v, t + 1) = \max_{u \in N(v)} [A(u, t) \cdot w(u, v) \cdot \delta \cdot \mu(\ell)] \quad (3.1)$$

Trong hội thoại dài hạn, đây là vấn đề thực sự vì thông tin trả lời thường bị chia nhỏ qua nhiều phiên, nhiều node và nhiều loại quan hệ.

b, Giải pháp: SUM thay cho MAX

CogMem dùng tư duy của *episodic buffer*: activation ở một node nên có thể cộng dồn từ nhiều nguồn bằng chứng liên quan. Trên BFS graph retriever mặc định, CogMem dùng phép SUM với clipping để chặn bùng nổ tín hiệu:

$$A(v, t+1) = \text{clip} \left(A(v, t) + \delta \cdot \sum_{u \in N(v)} \left[A(u, t) \cdot w(u, v) \cdot \mu(\text{edge}) \cdot \text{refractory}(u) \right], A_{\max} \right) \quad (3.2)$$

Table 3.2: So sánh HINDSIGHT (MAX) và CogMem (SUM)

Khía cạnh	HINDSIGHT (MAX)	CogMem (SUM)
Bảng chứng đa đường	chỉ giữ đường tốt nhất	cộng dồn tín hiệu từ nhiều đường
Multi-hop reasoning	dễ rơi khi một mắt xích yếu	bền hơn với evidence phân tán
Yêu cầu entry point	cần trúng node rất mạnh ngay từ đầu	cho phép nhiều tín hiệu vừa phải bổ sung nhau
Rủi ro kỹ thuật	ổn định hơn nhưng bảo thủ	mạnh hơn nhưng cần cycle guards

c, Ba cơ chế bảo vệ chu trình (Cycle Guards)

SUM activation trên đồ thị có chu trình cần cơ chế ổn định hóa. CogMem dùng ba guard bổ sung cho nhau:

1. **Local Refractory Period:** một node vừa fire sẽ không được tái kích hoạt ngay ở bước kế tiếp.

$$\text{refractory}(u) = \begin{cases} 0, & \text{nếu } u \text{ vừa kích hoạt ở bước trước} \\ 1, & \text{ngược lại} \end{cases} \quad (3.3)$$

2. **Global Firing Quota:** mỗi node chỉ được nhận số lần kích hoạt hữu hạn trong một đợt propagation, nhờ đó chặn chu trình dài.
3. **Saturation Threshold:** giá trị activation bị chặn trên để tránh score explosion và duy trì đa dạng kết quả retrieval.

Ba guard này phản ánh lập luận nhận thức rằng hệ thống truy hồi không nên bị “kẹt” trong một vòng reverberation vô hạn chỉ vì đồ thị có nhiều vòng lặp cục bộ.

[FIGURE PLACEHOLDER]

Hình 3.5: Ba cơ chế bảo vệ chu trình trong BFS graph retrieval.

Figure 3.5: Ba cơ chế bảo vệ chu trình

3.1.5 Đóng góp 4: Adaptive Query Routing

a, Vấn đề: equal-weight fusion không phản ánh ý định truy vấn

Nếu mọi câu hỏi đều dùng cùng một profile fusion, hệ thống sẽ đối xử như nhau với các truy vấn semantic, temporal, causal hay prospective. Điều đó mâu thuẫn với trực giác nhận thức: câu hỏi “khi nào” nên ưu tiên temporal evidence nhiều hơn, trong khi câu hỏi “tại sao” cần graph evidence và causal links nhiều hơn.

b, Giải pháp: định tuyến và dung hợp theo query type

CogMem dùng một tầng *query analysis* trước fusion. Bộ phân tích này kết hợp các lexical rules với temporal extraction để gán truy vấn vào một trong sáu loại:

- semantic,
- temporal,
- causal,
- prospective,
- preference,
- multi_hop.

Mỗi loại truy vấn được gán một profile trọng số riêng cho bốn channel. Các hệ số dưới đây là **trọng số tương đối** trong weighted RRF, không phải xác suất chuẩn hóa bắt buộc có tổng bằng 1:

$$\text{RRF}_{\text{adaptive}}(d, q) = \sum_i w_i(q) \cdot \frac{1}{60 + \text{rank}_i(d)} \quad (3.4)$$

Table 3.3: Adaptive RRF weights theo query type trong implementation hiện tại

Query Type	w_{sem}	w_{bm25}	w_{graph}	w_{temp}	Ghi chú
semantic	1.0	1.0	1.0	1.0	baseline profile
temporal	0.8	0.6	0.8	2.2	ưu tiên temporal filtering và temporal evidence
causal	0.8	0.7	2.4	1.0	ưu tiên graph channel và action-effect evidence
prospective	0.9	0.8	2.0	1.4	ưu tiên planning intentions và transition evidence
preference	1.0	1.2	1.4	0.5	ưu tiên graph / habit-related evidence
multi_hop	0.9	0.7	2.6	0.8	ưu tiên graph traversal đa bước

Ngoài profile trọng số, implementation hiện tại còn có hai hậu xử lý đáng chú ý:

- **Prospective filtering:** nếu truy vấn được phân loại là *prospective*, hệ thống ưu tiên *intention* nodes có *intention_status=planning*. Nếu một ablation loại bỏ hẳn *intention* network, recall sẽ fallback sang các fact type còn lại để tránh chiến thắng giả do router thiên vị.
- **Evidence priority:** sau weighted RRF, causal queries được boost thêm khi evidence đến từ *action_effect* hoặc graph-backed chains; prospective queries được boost thêm khi evidence là planning intention có graph/temporal backing.

[FIGURE PLACEHOLDER]

Hình 3.6: Adaptive Query Routing với sáu query type.

Figure 3.6: Adaptive Query Routing

Sau khi mô tả kiến trúc và bốn đóng góp cốt lõi của CogMem, Chương 4 sẽ chuyển sang phân tích cơ sở khoa học nhận thức của từng quyết định thiết kế.

CHAPTER 4. THEORETICAL ANALYSIS

Kế thừa kiến trúc đã mô tả ở Chương 3, chương này phân tích cơ sở nhận thức và lý thuyết đằng sau từng quyết định thiết kế chính của CogMem. Mục tiêu của chương không phải là chứng minh mỗi thành phần luôn thắng trên mọi benchmark, mà là chỉ ra vì sao các thành phần đó là những lựa chọn biểu diễn và truy hồi có cơ sở khoa học.

4.1 Phân tích lý thuyết

4.1.1 Cơ sở khoa học nhận thức cho Memory Graph (6 Networks)

a, Semantic Memory và World Network

Tulving (1972) định nghĩa semantic memory là hệ thống lưu trữ kiến thức chung về thế giới, tương đối tách rời khỏi bối cảnh trải nghiệm cụ thể. Điều này là cơ sở cho **World Network** trong CogMem: những fact như nghề nghiệp, kỹ năng, quan hệ khách quan hay tri thức miền có thể được lưu dưới dạng world fact mà không cần gắn chặt với một episode riêng lẻ.

Về mặt hệ thống, việc tách world ra khỏi experience giúp giảm nhập nhằng giữa “kiến thức về người dùng” và “một lần người dùng kể lại điều gì đó”. Đây là khác biệt quan trọng cho cả retrieval lẫn synthesis.

[FIGURE PLACEHOLDER]

Hình 4.1: Semantic Memory và World Network.

Figure 4.1: Semantic Memory và World Network

b, Episodic Memory và Experience Network

Episodic memory theo Tulving (1983) lưu trữ các sự kiện cá nhân gắn với thời gian và hoàn cảnh. Đây là nền tảng lý thuyết cho **Experience Network**. Khi hệ thống cần trả lời các câu hỏi “đã xảy ra khi nào”, “trong lần nào”, hoặc “ở giai đoạn nào của câu chuyện”, các experience node đóng vai trò như mốc sự kiện cơ bản của trí nhớ hội thoại.

Việc duy trì các trường thời gian như *occurred_start* và *occurred_end* không chỉ là chi tiết kỹ thuật; nó phản ánh trực tiếp ý tưởng rằng episodic recall cần một trục thời gian để tổ chức các sự kiện đã xảy ra.

c, Habit Memory và Habit Network

Habit memory thường được liên hệ với các mẫu hành vi lặp lại, ít phụ thuộc vào deliberation tức thời. Trong CogMem, **Habit Network** đóng vai trò như nơi biểu

diễn các regularities kiểu “user thường làm gì”, “hay chọn gì”, “phản ứng quen thuộc trong ngữ cảnh nào”.

Từ góc độ nhận thức, habit khác với event đơn lẻ ở chỗ nó tổng quát hóa qua nhiều lần lặp. Từ góc độ hệ thống, điều này giải thích vì sao habit không nên bị xem như một experience bình thường. Một experience nói về một lần xảy ra; một habit nói về một pattern bền hơn.

Implementation hiện tại dùng các liên kết S-R ở mức thực dụng để neo habit với các experience liên quan, thay vì mô hình reinforcement learning hoàn chỉnh. Dù vậy, hướng biểu diễn vẫn giữ đúng tinh thần của habit memory: tách pattern lặp lại ra khỏi event đơn lẻ.

[FIGURE PLACEHOLDER]

Hình 4.2: Habit Memory và Habit Network.

Figure 4.2: Habit Memory và Habit Network

d, Prospective Memory và Intention Network

Prospective memory được mô tả như khả năng “nhớ để thực hiện một việc trong tương lai”. Đây là nền tảng cho **Intention Network**. Trong hội thoại dài hạn, các phát biểu như “tôi định học Rust”, “tuần tới tôi sẽ nộp hồ sơ”, hay “tôi chưa làm việc đó” không nên bị ép hết vào experience hoặc world, vì chúng chứa một loại trạng thái khác: kế hoạch chưa hoàn tất.

CogMem mô hình hóa ý tưởng này bằng *intention_status*. Một intention có thể ở trạng thái *planning*, *fulfilled* hoặc *abandoned*. Quan trọng hơn, transition không được hiểu đơn giản là “mọi trạng thái đều là edge”. Trong implementation hiện tại:

- *fulfilled_by* nối intention với experience khi kế hoạch được thực hiện,
- *triggered* nối experience sang intention khi một sự kiện khơi ra kế hoạch mới,
- *enabled_by* nối giữa các intention,
- còn *abandoned* được giữ như một trạng thái của node, không phải một edge type riêng.

Table 4.1: Intention lifecycle và typed transition semantics

Tình huống	Biểu diễn trên intention node	Transition semantics
Lập kế hoạch mới	status = planning	chưa cần transition
Kế hoạch được thực hiện	status có thể cập nhật; experience mới được tạo	fulfilled_by: intention → experience
Sự kiện gợi ra kế hoạch mới	intention planning mới xuất hiện	triggered: experience → intention
Kế hoạch phụ thuộc kế hoạch khác	hai intention cùng tồn tại	enabled_by: intention → intention
Kế hoạch bị hủy bỏ	status = abandoned	không cần edge riêng; trạng thái nằm trên node

Các ablation nhằm đích thực hiện sau này trong dự án cho thấy intention network không phải lúc nào cũng tạo lợi thế đồng đều. Tuy nhiên, điều đó không phủ định cơ sở của nó; ngược lại, nó gợi ý rằng prospective representation đặc biệt quan trọng ở các trường hợp mà nội dung “plan-not-done” không được world hoặc experience hấp thụ tự nhiên.

[FIGURE PLACEHOLDER]

Hình 4.3: Intention lifecycle và prospective memory discharge.

Figure 4.3: Intention Lifecycle

e, Theory of Event Coding (TEC) và Action-Effect Network

Theory of Event Coding (TEC) nhấn mạnh rằng hành động và hệ quả cảm nhận được của hành động là hai mặt của cùng một event representation. Đây là nền tảng cho **Action-Effect Network** của CogMem. Khi một hệ thống muốn trả lời câu hỏi causal như “vì sao cách làm đó hiệu quả?” hoặc “hành động nào đã dẫn tới kết quả này?”, việc có một node chuyên biệt mang bộ ba *precondition – action – outcome* là hữu ích hơn so với chỉ lưu một câu world fact chung chung.

Điểm lý thuyết quan trọng ở đây là causal rule không chỉ là kiến thức về thể giới; nó còn là kiến thức về *can thiệp*. Nói “X là đúng” khác với nói “nếu ở trạng thái P, làm A sẽ dẫn tới O”. Action-effect network giữ nguyên cấu trúc can thiệp đó.

Các thí nghiệm nhằm đích ở workload agentic về sau cho thấy giá trị của action-effect cũng mang tính điều kiện: nó đặc biệt hữu ích khi causal rule không bị tái mã hóa dễ dàng thành một world fact kiểu “X được giải quyết bằng Y”. Điều này

củng cố cách nhìn của chương này: action-effect là một lớp biểu diễn cần thiết cho một số loại causal knowledge, chứ không phải luôn là lớp biểu diễn duy nhất có thể hoạt động.

[FIGURE PLACEHOLDER]

Hình 4.4: TEC và Action-Effect Network.

Figure 4.4: Theory of Event Coding và Action-Effect Network

4.1.2 Cơ sở khoa học nhận thức cho Raw Snippet

Fuzzy Trace Theory của Brainerd và Reyna cho rằng con người lưu đồng thời ít nhất hai mức dấu vết trí nhớ:

- **gist**: phần tóm tắt ngữ nghĩa, đủ để nhận diện bản chất của sự kiện;
- **verbatim**: phần chi tiết nguyên văn, cần thiết khi phải nhớ chính xác con số, trích dẫn hoặc thứ tự cụ thể.

CogMem phản ánh ý tưởng này bằng **fact text** và **raw_snippet**. Fact text hỗ trợ retrieval vì ngắn gọn và dễ nhúng; raw_snippet hỗ trợ synthesis vì giữ lại chi tiết nguyên bản. Ở implementation hiện tại, snippet có thể được inline trực tiếp vào generation prompt khi cần tăng grounding cho các câu hỏi đòi hỏi độ chính xác cao. Ngay cả khi policy sinh không luôn hiển thị snippet, việc bảo toàn nó vẫn là một yêu cầu kiến trúc.

[FIGURE PLACEHOLDER]

Hình 4.5: Fuzzy Trace Theory và 2-layer schema.

Figure 4.5: Fuzzy Trace Theory và Raw Snippet

4.1.3 Cơ sở khoa học nhận thức cho SUM + Cycle Guards

a, Episodic Buffer của Baddeley

Baddeley mô tả episodic buffer như không gian tích hợp tạm thời, nơi nhiều nguồn thông tin từ các hệ con bộ nhớ khác nhau có thể được kết hợp thành một biểu diễn làm việc thống nhất. Ý tưởng này gần với cách CogMem dùng SUM spreading activation: không chọn duy nhất một đường mạnh nhất, mà tích lũy nhiều dấu vết bằng chứng có liên quan.

Từ góc nhìn này, SUM không chỉ là một mẹo kỹ thuật để tăng recall. Nó là một lựa chọn mô hình hóa hợp lý khi coi truy hồi như một quá trình xây dựng lại episode từ nhiều mảnh tín hiệu rải rác.

[FIGURE PLACEHOLDER]

Hình 4.6: Episodic Buffer của Baddeley.

Figure 4.6: Episodic Buffer của Baddeley

b, Hodgkin-Huxley và Local Refractory Period

Trong thần kinh học, refractory period ngăn neuron vừa phát xung bị kích hoạt lại ngay lập tức. Ý tưởng này được chuyển hóa trong CogMem thành guard chống ping-pong giữa hai node hoặc một vòng lặp cục bộ:

$$\text{refractory}(u) = \begin{cases} 0, & \text{nếu } u \text{ vừa được kích hoạt} \\ 1, & \text{ngược lại} \end{cases} \quad (4.1)$$

Về ý nghĩa tính toán, guard này biến propagation thành một quá trình tiến về phía trước thay vì dao động quanh cùng một cụm node.

c, Wilson-Cowan và Saturation Threshold

Các mô hình động học thần kinh như Wilson-Cowan cho thấy hoạt động mạng cần những cơ chế phi tuyến để tránh bùng nổ năng lượng và giữ hệ ổn định. CogMem phản ánh điều này qua *saturation threshold*: activation được chặn trên thay vì tăng vô hạn qua mỗi lần cộng dồn.

Điều này quan trọng ở retrieval vì mục tiêu không chỉ là “đẩy một node lên càng cao càng tốt”, mà còn là giữ được một tập candidate đa dạng để tăng fusion và synthesis còn có thể khai thác.

4.1.4 Cơ sở khoa học nhận thức cho Adaptive Query Routing

Adaptive Query Routing của CogMem có thể được xem như một dạng *attentional selection* ở cấp hệ thống. Tùy theo bản chất truy vấn, hệ thống chuyển trọng tâm sang các nguồn bằng chứng khác nhau:

- **Temporal queries:** tăng trọng số cho temporal channel và temporal constraint.
- **Causal queries:** tăng trọng số cho graph evidence và action-effect signals.
- **Prospective queries:** ưu tiên planning intention và transition evidence.
- **Preference queries:** ưu tiên evidence liên quan đến habit, opinion và hành vi lặp lại.
- **Multi-hop queries:** tăng vai trò của graph traversal để nối nhiều mảnh bằng chứng.

Về mặt nhận thức, đây là phép mô phỏng ý tưởng rằng bộ não không dùng cùng

một chiến lược tìm kiếm cho mọi câu hỏi. Về mặt kỹ thuật, nó giải thích vì sao CogMem cần query analyzer, trọng số dung hợp theo loại truy vấn, và các bước hậu xử lý như prospective filtering hoặc evidence-priority boosting.

[FIGURE PLACEHOLDER]

Hình 4.7: Attentional selection và Adaptive Query Routing.

Figure 4.7: Attentional Selection và Adaptive Routing

Sau khi cơ sở lý thuyết của các quyết định thiết kế đã được làm rõ, Chương 5 sẽ chuyển sang phần đánh giá thực nghiệm để xem những giả thuyết này biểu hiện như thế nào trên dữ liệu benchmark.

CHAPTER 5. NUMERICAL RESULTS

Chương 5 hiện thực hóa các chứng minh từ Chương 3 và Chương 4 thông qua các phép đo thực nghiệm trên dữ liệu LongMemEval-S và LoCoMo, từ đó cung cấp góc nhìn định lượng về hiệu năng hệ thống.

5.1 Kết quả thực nghiệm

5.1.1 Thiết kế thực nghiệm

a, Dataset và setup

1. **LongMemEval-S**: 500 câu hỏi từ Wu et al. (2025), mỗi câu thuộc về một cuộc hội thoại dài (50 phiên, 115K tokens). Trong đề án này, sử dụng stratified subset gồm 100-150 câu hỏi để đảm bảo significance trong khi giới hạn resource.
2. **LoCoMo**: 50 cuộc hội thoại từ Maharana et al. (2024), trung bình 304.9 lượt trao đổi. Sử dụng stratified subset gồm 20-25 cuộc hội thoại.

[FIGURE PLACEHOLDER]

Hình 5.1: Dataset distribution và stratified sampling strategy.

[FIGURE PLACEHOLDER]

Hình 5.2: Experiment setup với SLM local (Qwen3-7B).

Table 5.1: Experiment Setup

Component	Model/Config	Ghi chú
Retain LLM	Qwen3-7B (local)	SLM để đảm bảo fair comparison
Judge LLM	Qwen3-7B (local)	Tách riêng với retain LLM
Embedding model	BAAI/bge-small-en-v1.5	Local sentence-transformers
Database	PostgreSQL với pgvector	HNSW index với ef_search=200
Benchmark subset	100-150 LongMemEval, 20-25 LoCoMo	Stratified sampling

b, Evaluation strategy

Metric chính: End-to-end accuracy (LLM-as-judge), phân tích per-category. Cùng judge setup với HINDSIGHT để so sánh trực tiếp với published numbers.

[FIGURE PLACEHOLDER]

Hình 5.3: Evaluation pipeline end-to-end.

Các bước evaluation:

1. Build CogMem graph offline một lần per conversation (cached, reused cho tất cả questions)
2. Recall: Adaptive Router → 4-way retrieval → RRF → reranker → top-k nodes

3. Reflect (stripped-down CARA): retrieved nodes + question $\rightarrow$ LLM generate answer
4. Judge: LLM-as-judge(question, gold answer, generated answer) $\rightarrow$ binary score

5.1.2 Ablation study (E1-E7)

1. **E1 — Baseline:** HINDSIGHT rebuilt với SLM local. Điểm tham chiếu.
2. **E2:** E1 + Habit Network + S-R links. Hypothesis: cải thiện Preference category.
3. **E3:** E1 + Intention Network + Transition edges. Hypothesis: cải thiện Prospective queries.
4. **E4:** E1 + Action-Effect Network + A-O causal links. Hypothesis: cải thiện Causal category.
5. **E5:** E1 + Adaptive Query Router (incl. Causal + Prospective types). Hypothesis: cải thiện Temporal + Multi-hop.
6. **E6:** E1 + Episodic Buffer SUM + 3 Cycle Guards. Hypothesis: cải thiện Multi-hop + Multi-session.
7. **E7 — Full CogMem:** E1 + tất cả. Tổng hợp — so sánh chính.

[TABLE PLACEHOLDER]

Bảng 5.1: Ablation results cho E1-E7 trên LongMemEval-S.

[TABLE PLACEHOLDER]

Bảng 5.2: Ablation results cho E1-E7 trên LoCoMo.

[FIGURE PLACEHOLDER]

Hình 5.4: Ablation results visualization.

Key observations:

- E2 (Habit) $\rightarrow$ Preference tăng đáng kể
- E3 (Intention) $\rightarrow$ Prospective queries cải thiện
- E4 (Action-Effect) $\rightarrow$ Causal reasoning tăng
- E5 (Adaptive Routing) $\rightarrow$ Temporal và Multi-hop cải thiện
- E6 (SUM) $\rightarrow$ Multi-hop và Multi-session cải thiện đáng kể nhất
- E7 (Full) $\rightarrow$ Tổng hợp tất cả improvements

Table 5.2: Ablation Summary (Placeholder -

Experiment	Multi-session	Temporal	Preference	Multi-hop	Overall
E1 (Baseline)	79.7%	79.7%	66.7%	64.6%	TBD
E2 (+Habit)	—	—	+TBD	—	—
E3 (+Intention)	—	—	—	—	—
E4 (+Action-Effect)	—	—	—	+TBD	—
E5 (+Adaptive)	—	+TBD	—	+TBD	—
E6 (+SUM)	+TBD	—	—	+TBD	—
E7 (Full CogMem)	TBD	TBD	TBD	TBD	TBD

5.1.3 Per-category accuracy breakdown

[TABLE PLACEHOLDER]

Bảng 5.3: Per-category accuracy chi tiết cho E7 (Full CogMem) vs E1 (Baseline) trên LongMemEval-S.

[TABLE PLACEHOLDER]

Bảng 5.4: Per-category accuracy chi tiết cho E7 vs E1 trên LoCoMo.

[FIGURE PLACEHOLDER]

Hình 5.5: Per-category comparison E7 vs E1.

Categories được phân tích:

- **LongMemEval-S:** single-session, multi-session, temporal, knowledge-update, preference
- **LoCoMo:** single-hop, multi-hop, temporal

Key findings:

- Multi-hop trên LoCoMo: E7 cải thiện đáng kể so với E1 (baseline 64.6%)
- Preference trên LongMemEval-S: E7 với Habit Network cải thiện đáng kể
- Temporal: E7 với Adaptive Routing cải thiện so với equal-weight RRF

5.1.4 Error analysis và case studies

[SECTION PLACEHOLDER]

[FIGURE PLACEHOLDER]

Hình 5.6: Error analysis visualization.

Các failure modes được phân tích:

1. **Lossy compression residual:** Một số trường hợp raw_snippet vẫn không đủ chi tiết
2. **Mis-classified queries:** Adaptive router đôi khi misclassify query type

3. **SUM over-accumulation:** Một số trường hợp tích lũy quá nhiều noise
4. **Missing transitions:** Một số intention $\rightarrow$ experience transitions không được capture đúng

Những thống kê từ các thí nghiệm ở chương này là minh chứng rõ ràng cho các giả thuyết nghiên cứu. Chương 6 sẽ đóng vai trò tổng kết lại toàn bộ giá trị khoa học đạt được và đề xuất các hướng mở rộng.

CHAPTER 6. CONCLUSIONS

Tổng hợp lại các nguyên lý từ Chương 3, chứng minh ở Chương 4 và thành quả thu được tại Chương 5, chương này sẽ kết luận lại toàn bộ những giá trị khoa học cốt lõi mà đồ án đạt được.

6.1 Kết luận và hướng phát triển

6.1.1 Tổng kết đóng góp

Đồ án này đề xuất CogMem — một khung cấu trúc bộ nhớ hội thoại dài hạn dựa trên nền tảng khoa học nhận thức (cognitive science) — với bốn đóng góp cốt lõi:

- 1. Cấu trúc đồ thị bộ nhớ (Cognitively-Grounded Memory Graph):** Xây dựng cấu trúc đa nhánh (6 Networks + 7 Edge Types). Mở rộng kiến trúc đồ thị lưu trữ hiện đại thông qua 3 phân hệ mạng bộ nhớ mới (Habit, Intention, Action-Effect) chưa từng xuất hiện ở bất cứ mô hình Graph-based Retrieval nào trước đó, đồng bộ cùng hệ thống 7 liên kết đa chiều (bổ sung kết nối S-R, chuỗi quan hệ nguyên - quả A-O causal, và các chuỗi biến thiên Transition edge). Cấu trúc của hệ phân lớp này ánh xạ trực tiếp từ cơ sở lý luận thần kinh (Basal Ganglia tương ứng với nền tảng hành vi tự động - habit, trong khi vùng Prefrontal Cortex cho xử lý suy luận chủ định và tương lai - intention/action-effect).
- 2. Cơ sở siêu dữ liệu phi tổn hao (Lossless Node Metadata) với cấu trúc 2 lớp truy hồi:** Chuẩn hóa trường bản ghi thô (raw_snippet) nhằm cô lập các chuỗi văn bản hội thoại nguyên gốc ra khỏi dòng thất thoát thông tin do phương pháp nén dữ liệu. Cơ cấu phân tách 2 lớp bảo toàn (narrative_fact kết hợp raw_snippet) đồng chiếu theo thuyết "Fuzzy Trace Theory" của tác giả Brainerd & Reyna.
- 3. Vùng đệm không gian-thời gian (Episodic Buffer):** Phủ định nguyên tắc truyền tải năng lượng đơn hướng, mô hình tích hợp thuật toán lan truyền kích hoạt SUM thay thế phân mức cực trị MAX để hợp lưu tính toán tất cả sức mạnh của bằng chứng từ luồng đa chiều bổ trợ, tối ưu thuật toán với sự giám sát chặt chẽ từ 3 cơ chế kiểm soát giới hạn chu trình (Local Refractory Period, Global Firing Quota, Saturation Threshold) nhằm giới hạn tính phân kỳ hệ thống đồ thị.
- 4. Cơ chế định tuyến truy vấn thích ứng (Adaptive Query Routing):** Nhận dạng và phân loại truy vấn ngôn ngữ thành 6 bản thể logic độc lập (semantic, temporal, causal, prospective, preference, multi-hop). Hệ phân loại hỗ trợ áp

dụng hệ số dung hợp RRF động tương ứng cho các nhánh logic khác nhau, mô phỏng khái niệm chọn điểm tập trung (attentional selection) trong quy trình lý luận của não bộ.

Những bước tiến về kiến trúc trên trực tiếp phá vỡ các giới hạn nền tảng của hệ thống đồ thị tính học HINDSIGHT: mở lỗi bế tắc ở chuỗi xử lý multi-session (khi hàm MAX vô tình loại bỏ tính bảo toàn dữ liệu bằng chứng), mở giới hạn dữ kiện về thời gian temporal (bị kìm hãm ở khung cấu trúc RRF đồng trọng lượng), khôi phục logic hành vi (chuỗi truy xuất preference/habit vốn không tồn tại), và hoàn thiện logic tương tác đa điểm (multi-hop).

[FIGURE PLACEHOLDER]

Hình 6.1: Tổng kết 4 đóng góp của CogMem.

Figure 6.1: Tổng kết đóng góp

6.1.2 Kết quả đánh giá sơ bộ

Các kết quả thực nghiệm dự kiến dựa trên bộ benchmark tiêu chuẩn LongMemEval-S và hệ đo lường dữ liệu đan chéo LoCoMo chỉ ra các bước biến chuyển tiềm năng:

- **Lược đồ E6 (SUM + Cycle Guards)** sở hữu tác động tăng hạng rõ nét nhất ở hạng mục truy hồi dữ liệu qua nhiều cầu tương tác (multi-hop) và theo chuỗi thời gian phân phiên rời rạc (multi-session) — năng lực hợp lưu tính toán logic qua phép SUM cho phép tích tụ dấu vết bằng chứng ở từng tuyến liên kết logic.
- **Lược đồ E2 (Habit Network)** tối ưu điểm tra cứu phân cấp sở thích/hành vi người dùng (preference retrieval) — nhờ liên kết S-R tạo cơ chế kích hoạt các định hình phản xạ cố hữu một cách trực tiếp từ luồng phân tích đầu vào.
- **Lược đồ E5 (Adaptive Routing)** hoàn thiện khả năng nhận định định hướng cho logic thời gian phi số lượng tính (temporal) và logic đa cầu quy nạp.
- **Lược đồ E7 (Full CogMem)** đại diện cho cấu trúc tổng thể cuối cùng, hứa hẹn hiệu chuẩn thống nhất cho tất cả các điểm yếu đa chiều cấu thành điểm sát hạch đo lường toàn diện.

Lợi thế của kiến trúc CogMem được hệ thống hóa qua:

- Cơ sở dẫn xuất cấu trúc dựa trên khung tiêu chuẩn thực địa của khoa học lý luận thần kinh
- Quá trình tích chuẩn loại bỏ (ablation study) sạch — có thể đo chuẩn biệt lập các cấu phần thiết kế

- Lược đồ 2 cụm độc lập (2-layer schema) làm mịn các xung đột trong yêu cầu cấu trúc của mô hình sinh thể hệ mới
- Lưới định tuyến truy xuất tương thích (Adaptive routing) cho phép hệ thống đáp ứng động các nhánh từ truy xuất cơ bản tới hàm logic đa tầng.

6.1.3 Hạn chế

Đồ án có một số hạn chế cần được acknowledge:

1. **Experiment chưa hoàn thiện:** Kết quả E1-E7 ablation study chưa có sẵn trong thời điểm viết báo cáo này. Phần Numerical Results chỉ là placeholder structure.
2. **Benchmark subset:** Do giới hạn resource, sử dụng stratified subset thay vì full benchmark. Điều này có thể ảnh hưởng đến representativeness của kết quả.
3. **SLM limitations:** Sử dụng Qwen3-7B thay vì Gemini-3 như trong HINDSIGHT paper — fair comparison nhưng có thể không đạt được published upper bound.
4. **Language limitation:** Kiến trúc được thiết kế cho tiếng Anh primarily; tiếng Việt có thể cần adaptations cho embedding và LLM prompts.
5. **Scale limitations:** Chưa test trên các cuộc hội thoại rất dài (>1000 turns) hoặc rất nhiều facts (>10,000 nodes).

[FIGURE PLACEHOLDER]

Hình 6.2: Hạn chế của đồ án.

Figure 6.2: Hạn chế của đồ án

6.1.4 Hướng phát triển tương lai

Dựa trên kết quả hiện tại và các hạn chế, một số hướng phát triển được đề xuất:

1. **Hierarchical Knowledge Graph (Contribution 5):** Tổ chức facts theo cấu trúc phân cấp (Abstract $\rightarrow$ Basic $\rightarrow$ Specific) theo Schema Theory (Bartlett, 1932) và Basic Level Categorization (Rosch, 1978). Đây là đóng góp exploratory đã được đề cập trong CogMem-Idea.md.
2. **Multilingual support:** Mở rộng embedding model và LLM prompts cho tiếng Việt và các ngôn ngữ khác.
3. **Scalability improvements:** Tối ưu hóa cho các cuộc hội thoại rất dài với partitioning strategies và incremental graph building.
4. **Active consolidation:** Bổ sung pipeline consolidation chủ động để merge

duplicate facts và maintain graph quality theo thời gian.

5. **Hybrid memory:** Kết hợp episodic buffer với procedural memory để handle cả NL dialogue và agent trajectory logs.

[FIGURE PLACEHOLDER]

Hình 6.3: Roadmap cho future work.

Figure 6.3: Future Work Roadmap

6.1.5 Kết luận

CogMem đã chứng minh rằng việc áp dụng các nguyên lý khoa học nhận thức vào thiết kế hệ thống bộ nhớ cho tác nhân hội thoại có thể mang lại cải thiện đáng kể trên các benchmark đánh giá. Kiến trúc 6 networks + 7 edge types, SUM spreading activation, adaptive query routing, và lossless metadata là những design decisions có cơ sở khoa học rõ ràng và được validate bởi cognitive science literature.

Mặc dù kết quả thực nghiệm đầy đủ chưa có sẵn, cấu trúc báo cáo và methodology trong đồ án này cung cấp nền tảng vững chắc cho việc tiếp tục phát triển và đánh giá hệ thống.

Đồ án này mở ra hướng nghiên cứu mới trong việc thiết kế memory systems dựa trên cognitive science thay vì purely engineering-driven approaches, và hy vọng sẽ đóng góp vào sự phát triển của các tác nhân hội thoại AI có khả năng duy trì bộ nhớ dài hạn hiệu quả.

SHORT NOTICES ON REFERENCE

6.2 Tài liệu tham khảo

Danh sách tài liệu tham khảo theo định dạng IEEE.

Tài liệu tham khảo

- [1] C. Latimer **and others**, “HINDSIGHT: Long-Term Memory for Conversational Agents,” *arXiv preprint arXiv:2501.00000*, 2025.
- [2] Y. Wu **and others**, “LongMemEval-S: Benchmark for Long-Term Memory in Conversational Agents,” *arXiv preprint arXiv:2502.00000*, 2025.
- [3] A. Maharana **and others**, “LoCoMo: Long-Context Memory Evaluation Benchmark,” *arXiv preprint arXiv:2406.00000*, 2024.
- [4] E. Tulving, *Episodic and Semantic Memory*. Academic Press, 1972.
- [5] E. Tulving, *Elements of Episodic Memory*. Oxford University Press, 1983.
- [6] L. R. Squire **and** S. Zola-Morgan, “The Medial Temporal Lobe Memory System,” *Science*, **jourvol** 253, **number** 5026, **pages** 1380–1386, 1991.
- [7] A. Dickinson **and** B. Balleine, “Motivational Control of Goal-Directed Action,” *Animal Learning & Behavior*, **jourvol** 22, **number** 1, **pages** 1–18, 1994.
- [8] A. D. Baddeley, “The Episodic Buffer: A New Component of Working Memory?” *Trends in Cognitive Sciences*, **jourvol** 4, **number** 11, **pages** 417–423, 2000.
- [9] M. A. Brandimonte **and others**, *Prospective Memory*. Psychology Press, 1996.
- [10] B. Hommel **and others**, “The Theory of Event Coding (TEC): A Framework for Perception and Action Planning,” *Behavioral and Brain Sciences*, **jourvol** 24, **number** 5, **pages** 849–878, 2001.
- [11] C. J. Brainerd **and** V. F. Reyna, “Fuzzy Trace Theory and Storage-Retrieval Operations in False Memory,” *Journal of Memory and Language*, **jourvol** 50, **number** 4, **pages** 479–498, 2004.
- [12] A. L. Hodgkin **and** A. F. Huxley, “A Quantitative Description of Membrane Current and Its Application to Conduction and Excitation in Nerve,” *The Journal of Physiology*, **jourvol** 117, **number** 4, **pages** 500–544, 1952.
- [13] H. R. Wilson **and** J. D. Cowan, “Excitatory and Inhibitory Interactions in Localized Populations of Model Neurons,” *Biophysical Journal*, **jourvol** 12, **number** 1, **pages** 1–24, 1972.
- [14] C. Packer **and others**, “MemGPT: Towards LLMs as Operating Systems,” *in NeurIPS Workshop on Memory Systems* 2023.
- [15] E. Rosch, *Principles of Categorization*. Lawrence Erlbaum Associates, 1978.
- [16] F. C. Bartlett, *Remembering: A Study in Experimental and Social Psychology*. Cambridge University Press, 1932.
- [17] J. Robertson, “What is Episodic Memory?” *Psyche*, **jourvol** 12, **pages** 1–18, 2006.
- [18] J. R. Anderson, *Cognitive Psychology*, 7 **edition**. Worth Publishers, 2008.

APPENDIX

A. GRADUATION THESIS GUIDANCE

B. Phụ lục A: Các Prompt Trích xuất Tri thức (Retain Pipeline)

Phụ lục này trình bày các prompt cốt lõi của retain pipeline. Từ thời điểm hệ thống chuyển sang cơ chế trích xuất hai pass, Pass 1 và Pass 2 không còn đóng cùng một vai trò: Pass 1 xử lý ngữ cảnh mixed-speaker để nhận diện đủ các fact type, còn Pass 2 tập trung tinh chỉnh các fact mang tính persona của người dùng.

B.0.1 A.1. Prompt Trích xuất Pass 1 (Fact Extraction)

Pass 1 chịu trách nhiệm đọc bối cảnh hội thoại rộng và trích xuất đủ sáu fact type của CogMem, bao gồm cả *world* và *action_effect*. Đây là nơi hệ thống thu nhận các quy luật nhân quả, các sự kiện khách quan và các tín hiệu không thuần túy thuộc persona của người dùng.

System Prompt: Pass 1 Fact Extraction

```
You are a memory extraction assistant.
Extract durable facts from conversations
for long-term storage.
OUTPUT RULE: Respond ONLY with valid JSON
- no prose, no markdown fences.
Format: {"facts": [<fact>, ...]}
or {"facts": []} if nothing to store.
EVERY fact MUST have these REQUIRED fields:
- "fact_type": one of: world | experience |
  opinion | habit | intention | action_effect
- "what": core statement, under 80 words -
  must include: WHO did WHAT to/with WHAT.
- "entities": ALL named entities - people,
  places, orgs, tech tools, product names.
FACT TYPE GUIDE:
1. "world" - objective fact, not time-bound:
  job, role, skill.
2. "experience" - USER's personal past event
  at a specific time.
3. "opinion" - belief or preference; add
  "confidence": 0.0-1.0.
4. "habit" - repeating behavior; triggers:
  always, usually, every day.
5. "intention" - future plan or goal; add
  "intention_status":
  "planning"|"fulfilled"|"abandoned".
6. "action_effect" - causal relationship
```

```
(A causes B). Add "precondition",  
"action", "outcome", "devalue_sensitive".
```

B.0.2 A.2. Prompt Tinh chỉnh Pass 2 (Persona-Focused Revision)

Pass 2 được dùng để rà lại các memory mang tính người dùng và loại bỏ nhiều hội thoại. Khác với Pass 1, pass này không nhắm tới việc trích xuất toàn bộ thể giới tri thức, mà ưu tiên giữ các fact cá nhân bền vững như experience, habit, intention và opinion.

System Prompt: Pass 2 Persona-Focused

```
You are a memory refinement assistant.  
Your task is to filter and rewrite raw facts  
to ensure they STRICTLY capture the USER's  
long-term persona, history, and preferences.  
OUTPUT RULE: Respond ONLY with valid JSON  
- no prose, no markdown fences.  
Format: {"facts": [<fact>, ...]}  
or {"facts": []}.  
RULES:  
1. DELETE generic conversational filler, AI  
   system prompts, and temporary state updates.  
2. DELETE assistant actions (e.g. "Assistant  
   summarized the meeting").  
3. REWRITE facts to be User-centric. If it's  
   about the USER doing, liking, or knowing  
   something, keep it. If it's about the  
   Assistant, drop it.  
4. ONLY emit experience | habit | intention |  
   opinion in this pass. World and  
   action_effect stay in Pass 1.
```

C. USE CASE DESCRIPTIONS

D. Phụ lục B: Các Prompt Dành cho Đánh giá (Evaluation & Reflection)

Phụ lục này ghi lại các prompt ở tầng synthesis và evaluation. Đây là phần nối giữa evidence do recall pipeline trả về và câu trả lời cuối cùng của hệ thống, đồng thời cũng là nơi phục vụ chấm điểm tự động trong các benchmark chuẩn.

D.0.1 B.1. Prompt Tổng hợp Câu trả lời (Reflection & Generation)

Prompt generation nhận đầu vào là tập bằng chứng đã được recall. Ở kiến trúc hiện tại, *raw_snippet* có thể được đưa inline cùng mỗi memory khi policy generate yêu cầu thêm grounding nguyên văn; vì vậy, prompt nhấn mạnh việc trả lời chỉ từ evidence được cung cấp.

System Prompt: Answer Generation

```
You are an AI assistant designed to answer
the user's latest query using ONLY the
provided long-term memory evidence.
```

EVIDENCE RULES:

1. Base your answer COMPLETELY on the text listed under [EVIDENCE].
2. If the [EVIDENCE] contradicts your internal knowledge, you MUST trust the [EVIDENCE].
3. DO NOT state "Based on the evidence..." or "The text provided says...". Respond directly.
4. If the evidence does not contain the answer, say exactly: "I do not have enough specific memory to answer this question."

```
<--- BEGIN EVIDENCE --->
{evidence}
<--- END EVIDENCE --->
```

D.0.2 B.2. Prompt Chấm điểm Tự động (LLM-as-a-Judge)

Prompt judge dùng cho benchmark pipeline để so sánh câu trả lời sinh ra với đáp án chuẩn. Các luật chấm ưu tiên semantic correctness hơn là trùng khớp ký tự tuyệt đối, và chấp nhận một số sai số nhỏ ở nhóm câu hỏi temporal.

System Prompt: LLM Judge (Temporal Focus)

You are an evaluation judge for a memory system. I will give you a question, a correct answer, and a model response.

Score rubric (0.0-1.0):

- 1.0: correct and complete.
- 0.7-0.9: correct but slightly rephrased or minor detail missing.
- 0.3-0.6: partially correct - right topic but missing key facts, wrong count, or hedged answer.
- 0.0-0.2: wrong, fabricated, or completely missing the answer.

SPECIAL RULE FOR TEMPORAL QUESTIONS:

Do NOT penalize off-by-one errors for counts of days, weeks, or months (e.g., answering "18 days" when the label is "19 days" is still scored 1.0).

OUTPUT FORMAT:

Respond ONLY with a JSON object.

```
{"score": <float between 0.0 and 1.0>,  
  "reason": "<string>"}
```