HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

GRADUATION THESIS

CogMem: Khung bộ nhớ hội thoại dài hạn dựa trên Khoa học nhận thức

(CogMem: A Cognitively-Grounded Framework for Long-Term Conversational Memory)

Lê Minh Triết
triet.lm220045@sis.hust.edu.vn

Program: Global ICT

Supervisor: Cao Tuấn Dũng

Department: Computer Engineering

School: School of Information and Communications Technology

HANOI, 06/2026

HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

GRADUATION THESIS

CogMem: Khung bộ nhớ hội thoại dài hạn dựa trên Khoa học nhận thức

(CogMem: A Cognitively-Grounded Framework for Long-Term Conversational Memory)

Lê Minh Triết
triet.lm220045@sis.hust.edu.vn

Program: Global ICT

Supervisor: Cao Tuấn Dũng _____

Signature

Department: Computer Engineering

School: School of Information and Communications Technology

HANOI, 06/2026

ACKNOWLEDGMENT

Trước hết, tôi xin bày tỏ lòng biết ơn sâu sắc đến Thầy Cao Tuấn Dũng — người đã tận tình hướng dẫn, chỉ bảo và động viên tôi trong suốt quá trình thực hiện đồ án tốt nghiệp. Thầy không chỉ truyền đạt kiến thức chuyên môn mà còn là người thầy định hướng cho tôi về cách tiếp cận vấn đề một cách khoa học và có phương pháp.

Tôi cũng xin cảm ơn các thầy cô trong Khoa Kỹ thuật Máy tính, Trường Đại học Bách khoa Hà Nội, đã trang bị cho tôi nền tảng kiến thức vững chắc trong suốt bốn năm học tại đây.

Cuối cùng, tôi muốn cảm ơn gia đình và bạn bè — những người đã luôn ủng hộ, động viên và tạo điều kiện tốt nhất để tôi có thể tập trung hoàn thành đồ án này.

ABSTRACT

Các hệ thống tác nhân hội thoại AI hiện nay gặp phải thách thức cơ bản trong việc duy trì bộ nhớ dài hạn xuyên suốt nhiều phiên hội thoại. Khi ngữ cảnh (context window) vượt quá giới hạn, thông tin cũ bị loại bỏ khiến tác nhân mất khả năng ghi nhớ thông tin người dùng qua thời gian. Các giải pháp RAG (Retrieval-Augmented Generation) thông thường dựa trên cơ sở dữ liệu vector không đủ khả năng xử lý các truy vấn phức tạp, đặc biệt là các truy vấn đòi hỏi suy luận multi-hop hay suy luận về thói quen và quan hệ nhân quả.

Đồ án này đề xuất CogMem — một khung cấu trúc bộ nhớ hội thoại dài hạn được thiết kế dựa trên các nguyên lý của khoa học nhận thức (cognitive science). CogMem bao gồm bốn đóng góp chính: (1) Cấu trúc đồ thị bộ nhớ (Memory Graph) với 6 mạng nhánh chuyên biệt (World, Experience, Opinion, Habit, Intention, Action-Effect) và 7 loại liên kết, phản ánh chính xác các phân hệ bộ nhớ trong não người; (2) Cơ sở siêu dữ liệu phi tổn hao (Lossless Node Metadata) với trường dữ liệu nguyên bản (raw_snippet) nhằm giữ nguyên văn bản hội thoại, hạn chế tình trạng mất mát thông tin do quá trình nén của LLM; (3) Vùng đệm không gian-thời gian (Episodic Buffer) ứng dụng thuật toán lan truyền kích hoạt SUM thay cho hàm MAX, kết hợp với 3 cơ chế kiểm soát chu trình (Refractory, Firing Quota, Saturation), cho phép tích lũy bằng chứng từ nhiều hướng đồng thời; (4) Cơ chế định tuyến truy vấn thích ứng (Adaptive Query Routing) phân loại câu hỏi thành 6 loại hình (semantic, temporal, causal, prospective, preference, multi-hop) nhằm áp dụng trọng số động RRF (Reciprocal Rank Fusion).

Kết quả thực nghiệm trên các benchmark LongMemEval-S và LoCoMo cho thấy kiến trúc đề xuất cải thiện đáng kể so với baseline HINDSIGHT, đặc biệt trên các category khó như multi-hop, temporal reasoning và preference retrieval.

Lê Minh Triết

triet.lm220045@sis.hust.edu.vn

TABLE OF CONTENTS

CHAPTER 1. INTRODUCTION 1

1.1 Giới thiệu bài toán 1

1.1.1 Bối cảnh và vấn đề 1

1.1.2 Hạn chế của các giải pháp hiện tại 1

1.1.3 Động lực và đóng góp của đồ án 2

1.1.4 Cấu trúc của đồ án 2

CHAPTER 2. LITERATURE REVIEW 4

2.1 Tổng quan Lý thuyết và Các hệ thống liên quan 4

2.1.1 Thách thức cốt lõi về Bộ nhớ của Mô hình Ngôn ngữ Lớn (LLMs) . 4

2.1.2 Cơ sở Lý thuyết: Khoa học Nhận thức và Đồ thị Tri thức 5

2.1.3 Tiến trình phát triển hệ thống Bộ nhớ Dài hạn cho Tác nhân 6

2.1.4 Điểm chuẩn kiểm chứng thực nghiệm (Evaluation Benchmarks)..... 7

2.1.5 Hạn chế cốt lõi của các Khung hệ thống Bộ nhớ hiện nay (Problem Formulation)..... 8

CHAPTER 3. METHODOLOGY 9

3.1 Phương pháp đề xuất..... 9

3.1.1 Tổng quan kiến trúc hệ thống CogMem..... 9

3.1.2 Đóng góp 1: Đồ thị Bộ nhớ Kế thừa Nhận thức (Cognitively-Grounded Memory Graph)..... 9

3.1.3 Đóng góp 2: Siêu dữ liệu Node phi tổn hao (Lossless Node Metadata) và Raw State Snippets..... 12

3.1.4 Đóng góp 3: Episodic Buffer với SUM Spreading Activation + Cycle Guards 14

3.1.5 Đóng góp 4: Adaptive Query Routing 15

CHAPTER 4. THEORETICAL ANALYSIS 17

4.1 Phân tích lý thuyết 17

4.1.1 Cơ sở khoa học nhận thức cho Memory Graph (6 Networks)..... 17

4.1.2 Cơ sở khoa học nhận thức cho Raw Snippet..... 19

4.1.3 Cơ sở khoa học nhận thức cho SUM + Cycle Guards..... 20

4.1.4 Cơ sở khoa học nhận thức cho Adaptive Query Routing..... 21

CHAPTER 5. NUMERICAL RESULTS 22

5.1 Kết quả thực nghiệm 22

5.1.1 Thiết kế thực nghiệm..... 22

5.1.2 Ablation study (E1-E7)..... 23

5.1.3 Per-category accuracy breakdown..... 24

5.1.4 Error analysis và case studies 24

CHAPTER 6. CONCLUSIONS 26

6.1 Kết luận và hướng phát triển..... 26

6.1.1 Tổng kết đóng góp..... 26

6.1.2 Kết quả đánh giá sơ bộ 27

6.1.3 Hạn chế..... 28

6.1.4 Hướng phát triển tương lai 28

6.1.5 Kết luận 29

6.2 Tài liệu tham khảo 30

REFERENCE 32

APPENDIX 33

A. GRADUATION THESIS GUIDANCE 33

A.1 Phụ lục A: Các Prompt Trích xuất Tri thức (Retain Pipeline) 33

A.1.1 A.1. Prompt Trích xuất Pass 1 (Fact Extraction)..... 33

A.1.2 A.2. Prompt Tinh chỉnh Pass 2 (Persona-Focused Revision)..... 34

B. USE CASE DESCRIPTIONS 35

B.1 Phụ lục B: Các Prompt Dành cho Đánh giá (Evaluation & Reflection)..... 35

B.1.1 B.1. Prompt Tổng hợp Câu trả lời (Reflection & Generation)..... 35

B.1.2 B.2. Prompt Chấm điểm Tự động (LLM-as-a-Judge)..... 35

LIST OF FIGURES

Figure 1.1 Tổng quan kiến trúc CogMem 2

Figure 3.1 Sáu mạng bộ nhớ của CogMem 10
Figure 3.2 Phân biệt Habit và Action-Effect 11
Figure 3.3 Bảy loại liên kết trong CogMem 12
Figure 3.4 Lossy compression trong HINDSIGHT 13
Figure 3.5 2-Layer Node Schema 13
Figure 3.6 MAX vs SUM trong Spreading Activation 14
Figure 3.7 Ba cơ chế bảo vệ chu trình 15
Figure 3.8 Equal-weight RRF 16
Figure 3.9 Adaptive Query Routing 16

Figure 4.1 Semantic Memory và World Network 17
Figure 4.2 Habit Memory và Habit Network 18
Figure 4.3 Intention Lifecycle 18
Figure 4.4 Theory of Event Coding và Action-Effect Network 19
Figure 4.5 Fuzzy Trace Theory và Raw Snippet 20
Figure 4.6 Episodic Buffer của Baddeley 20
Figure 4.7 Wilson-Cowan Dynamics và Saturation 21
Figure 4.8 Attentional Selection và Adaptive Routing 21

Figure 6.1 Tổng kết đóng góp 27
Figure 6.2 Hạn chế của đồ án 28
Figure 6.3 Future Work Roadmap 29

LIST OF TABLES

Table 2.1 Hình thái đối sánh Cấu trúc của các hệ thống bộ nhớ đương đại 7

Table 3.1 Schema của Intention node và Action-Effect node 11
Table 3.2 So sánh HINDSIGHT (MAX) và CogMem (SUM) 15
Table 3.3 Adaptive RRF weights theo Query Type 16

Table 4.1 Intention Lifecycle và Transition Edges 18

Table 5.1 Experiment Setup 22
Table 5.2 Ablation Summary (Placeholder - Cần kết quả thực nghiệm) . 24

CHAPTER 1. INTRODUCTION

1.1 Giới thiệu bài toán

1.1.1 Bối cảnh và vấn đề

Các hệ thống tác nhân hội thoại AI (conversational AI agents) hiện tại đã đạt được những bước tiến đáng kể trong việc kết nối và xử lý thông tin ngắn hạn. Mặc dù vậy, hạn chế cốt lõi vẫn nằm ở khả năng duy trì bộ nhớ dài hạn xuyên suốt nhiều phiên hội thoại (multi-session). Khi số lượng token vượt mức giới hạn của ngữ cảnh (context window), những thông tin từ các phiên trao đổi trước đó sẽ bị loại bỏ. Điều này làm mất đi khả năng truy hồi thông tin người dùng và các cột mốc trong quá khứ — khiến tác nhân AI hành xử như thể đang làm việc với người dùng ở lần gặp đầu tiên.

Vấn đề này ảnh hưởng nghiêm trọng đến hiệu suất của các ứng dụng trong thế giới thực, điển hình như trợ lý cá nhân ảo, hệ thống chăm sóc khách hàng, hay các tác nhân AI cá nhân hóa có nhiệm vụ đồng hành cùng người dùng trong dài hạn. Người dùng kỳ vọng tác nhân có thể ghi nhớ chính xác những luồng thông tin đã tương tác, bao gồm sở thích, thói quen và các kế hoạch tương lai — phương diện mà các thế hệ AI hiện tại chưa thể giải quyết một cách bền vững.

1.1.2 Hạn chế của các giải pháp hiện tại

Thế hệ hệ thống bộ nhớ trước đó chủ yếu sử dụng chiến pháp đơn thuần: lưu trữ nguyên trạng các bản ghi hội thoại (raw conversation logs) vào cơ sở dữ liệu vector và ứng dụng kiến trúc RAG (Retrieval-Augmented Generation) để tiến hành truy xuất. Hướng tiếp cận này mang lại nhiều hạn chế đáng kể:

- **Nén cấu trúc có tổn hao (Lossy compression)**: Việc áp dụng LLM nhằm trích xuất thông tin (facts) từ lịch sử hội thoại là một quá trình nén phi tuyến và không thể đảo ngược. Các hệ thống như Mem0 cho thấy hiện tượng mất mát thông tin đáng kể khi trích xuất facts từ các biểu đồ lưu vết (trajectory) dài.
- **Thiếu cấu trúc dữ liệu tường minh**: Các bản ghi dài lên đến hàng triệu token hoạt động dưới dạng dữ liệu phẳng không có sự phân loại cấu trúc, làm mất đi khả năng nhận diện chức năng của từng luồng thông tin.
- **Sự thất bại của các kỹ thuật tìm kiếm truyền thống**: Các hệ thống retrieval đơn thuần không thể đáp ứng chuỗi các câu hỏi mang tính phức tạp, điển hình là các truy tìm yêu cầu lý luận multi-hop, các vấn đề về hành vi thói quen (habit) hay truy vết mang tính nhân quả (causality).

- **Thiếu hệ thống ngữ nghĩa thời gian (Temporal semantics)**: Không duy trì được cơ sở để bảo toàn trật tự tuyến tính của thời gian cũng như cơ cấu nguyên nhân - kết quả giữa các cột mốc chuỗi sự kiện.

HINDSIGHT (Latimer et al., 2025) là hệ thống đạt kết quả SOTA với 91.4% trên LongMemEval và 89.61% trên LoCoMo. Tuy nhiên, HINDSIGHT vẫn có những điểm yếu trên các category khó: multi-session (79.7

Nguyên nhân gốc rễ của các hạn chế này bao gồm: việc sử dụng phép MAX trong spreading activation thay vì SUM, không có mạng bộ nhớ cho habit/intention/action-effect, và equal-weight RRF không phân biệt query type.

1.1.3 Động lực và đóng góp của đồ án

Từ những hạn chế trên, đồ án này đề xuất CogMem — một khung bộ nhớ hội thoại dài hạn được xây dựng dựa trên các nguyên lý của khoa học nhận thức (cognitive science). Điểm xuất phát là quan sát: não người không lưu trữ ký ức như một danh sách phẳng, mà tổ chức theo nhiều hệ con bộ nhớ chuyên biệt, mỗi hệ phục vụ một loại truy vấn khác nhau và có cơ chất thần kinh riêng.

CogMem đề xuất bốn đóng góp chính:

1. **Cognitively-Grounded Memory Graph**: 6 mạng bộ nhớ (World, Experience, Opinion, Habit, Intention, Action-Effect) và 7 loại liên kết, phản ánh đúng bản chất của các quan hệ nhận thức.
2. **Lossless Node Metadata**: Trường raw_snippet giữ nguyên văn bản hội thoại gốc, tránh mất mát thông tin.
3. **Episodic Buffer với SUM Spreading Activation**: Thay phép MAX bằng SUM để tích lũy bằng chứng từ nhiều đường, với 3 cơ chế bảo vệ chu trình.
4. **Adaptive Query Routing**: Phân loại truy vấn thành 6 loại và áp dụng trọng số RRF động theo từng loại.

[FIGURE PLACEHOLDER]
Hình 1.1: Tổng quan kiến trúc CogMem với 3 pipeline chính: Retain, Recall, Reflect. Cần hình minh họa kiến trúc tổng quan của hệ thống với các thành phần chính.

Figure 1.1: Tổng quan kiến trúc CogMem

1.1.4 Cấu trúc của đồ án

Đồ án được tổ chức như sau:

- **Chương 2**: Literature Review — tổng quan các hệ thống bộ nhớ hiện tại

(HINDSIGHT, HippoRAG2, Mem0, MemGPT) và các benchmark đánh giá (LongMemEval, LoCoMo).

- **Chương 3**: Methodology — mô tả chi tiết 4 đóng góp chính của CogMem.
- **Chương 4**: Theoretical Analysis — phân tích cơ sở khoa học nhận thức cho từng đóng góp.
- **Chương 5**: Numerical Results — kết quả thực nghiệm và phân tích.
- **Chương 6**: Kết luận và hướng phát triển.

CHAPTER 2. LITERATURE REVIEW

2.1 Tổng quan Lý thuyết và Các hệ thống liên quan

Chương này trình bày các cơ sở lý thuyết tạo nên nền tảng của hệ thống bộ nhớ hội thoại dài hạn, tập trung vào hai trụ cột chính: Khoa học nhận thức (Cognitive Science) và Đồ thị tri thức (Knowledge Graphs). Đồng thời, chúng tôi hệ thống hóa, phân tích chuyên sâu các mô hình bộ nhớ tiên tiến (State of the Art - SOTA) và mổ xẻ những thiết sót cốt lõi về cấu trúc giải thuật của chúng, từ đó làm rõ động lực phát triển nên nền tảng CogMem.

2.1.1 Thách thức cốt lõi về Bộ nhớ của Mô hình Ngôn ngữ Lớn (LLMs)

Mặc dù các Mô hình Ngôn ngữ Lớn (LLMs) đạt được nhiều thành tựu vượt bậc trong xử lý ngôn ngữ tự nhiên, chúng vẫn tồn tại những giới hạn bản chất về mặt kiến trúc liên quan đến khả năng duy trì bộ nhớ dài hạn:

- **Giới hạn Cửa sổ Ngữ cảnh (Context Window Bottleneck) và Chi phí (N^2)**: Cơ chế Self-Attention cốt lõi của kiến trúc Transformer đòi hỏi độ phức tạp tính toán và bộ nhớ tăng theo bình phương độ dài chuỗi đầu vào (N^2). Điều này khiến việc đưa toàn bộ lịch sử hội thoại dài hạn vào prompt (context stuffing) trở nên bất khả thi về mặt tài nguyên phần cứng và làm tăng độ trễ nội tại.
- **Hiện tượng "Trôi dạt ở giữa" (Lost-in-the-Middle Phenomenon)**: Nghiên cứu của Liu et al. (2023) chỉ ra rằng LLMs có xu hướng trích xuất thông tin xuất hiện ở đầu và cuối cửa sổ ngữ cảnh tốt hơn nhiều so với thông tin nằm ở đoạn giữa. Việc nhồi nhét quá nhiều lịch sử hội thoại sẽ làm nhiễu loạn luồng chú ý (attention drift), dẫn đến bỏ sót dữ kiện quan trọng.
- **Quên thảm khốc (Catastrophic Forgetting)**: Phương pháp tinh chỉnh (Fine-tuning) để mô hình học thông tin mới thường dẫn đến việc nó bị ghi đè và đánh mất các kiến thức cơ sở đã học trong quá trình pre-training. Việc tinh chỉnh cũng không tương thích với bối cảnh bộ nhớ người dùng cần được cập nhật liên tục (real-time stream).
- **Ảo giác (Hallucination) do thiếu cơ sở nối kết (Grounding)**: LLM sinh văn bản dựa trên xác suất chuỗi phân phối tuyến tính thay vì suy luận từ hệ thống gốc (knowledge-grounded). Khi không có cấu trúc tri thức neo giữ, hệ thống dễ dàng tạo ra các sự thật giả tạo học được từ trọng số lưu trữ ngầm.

Để giải quyết các rào cản này, sự chuyển dịch từ việc phụ thuộc vào *Context Window* sang các hệ thống *Bộ nhớ Dài hạn bên ngoài (External Long-term Memory)* là xu thế bắt buộc. Tuy nhiên, để xây dựng hệ thống tác nhân toàn diện, chúng ta

cần vay mượn cơ sở lý thuyết từ Khoa học nhận thức.

2.1.2 Cơ sở Lý thuyết: Khoa học Nhận thức và Đồ thị Tri thức

a, Khoa học Nhận thức và Hệ thống Phân loại Bộ nhớ

Khác với kiến trúc máy tính truyền thống nơi bộ nhớ là một khối duy nhất (bộ nhớ khối - monolithic memory), não bộ con người lưu trữ thông tin dưới dạng phân tán thông qua nhiều hệ thống con (subsystems) hoạt động độc lập và tương tác mật thiết với nhau. Theo Squire and Zola-Morgan (1991), bộ nhớ dài hạn (long-term memory) ở động vật có vú được chia thành các phân hệ có cơ chất thần kinh (neural substrates) riêng biệt:

- **Bộ nhớ Ngữ nghĩa (Semantic Memory) và Bộ nhớ Tình tiết (Episodic Memory)**: Thuộc phân loại bộ nhớ tường minh (Declarative memory). *Semantic Memory* (Tulving, 1972) lưu trữ các sự kiện, kiến thức chung khách quan (General world knowledge), thường liên kết với Thùy thái dương-đỉnh. Ngược lại, *Episodic Memory* (Tulving, 1983) đóng vai trò ghi nhận các sự kiện mang tính cá nhân, đòi hỏi việc gắn liền bối cảnh không gian và thời gian sự kiện (spatiotemporal context), chủ yếu định vị tại vùng Hải mã (Hippocampus).
- **Bộ nhớ Thủ tục và Thói quen (Procedural and Habit Memory)**: Thuộc nhóm bộ nhớ không tường minh (Non-declarative). Chúng được điều phối bởi hệ Hạch nền (Basal Ganglia), quản lý các kỹ năng vận động và các mẫu hành vi tự động hình thành từ sự lặp lại, thường hoạt động dựa trên cơ chế Kích thích - Phản ứng (Stimulus-Response).
- **Bộ nhớ Tương lai (Prospective Memory)**: Được Brandimonte (1996) định hình là phần nhận thức liên quan đến "nhớ để làm một việc gì đó trong tương lai" (remembering to remember). Cơ chế này gắn liền với các vùng Vỏ não trước trán (Prefrontal Cortex), đóng vai trò quan trọng trong việc theo dõi mục tiêu và duy trì lộ trình theo chủ đích.

Việc ứng dụng hệ thống phân loại này định hướng trực tiếp cho việc chuyên môn hóa kiến trúc máy học, tránh việc gộp chung các biểu đồ nhân quả, thói quen và sự thật hiển nhiên vào cùng một không gian nhúng phi cấu trúc.

b, Đồ thị Tri thức (Knowledge Graphs) và Chức năng Biểu diễn

Đồ thị tri thức (Knowledge Graph - KG) là cấu trúc toán học biểu diễn thông tin dạng lưới, với $G = (V, E)$. Trong đó:

- Tập đỉnh V (Entities/Nodes) đại diện cho các thực thể vật lý hoặc trừu tượng (con người, sự kiện, chuỗi trạng thái).
- Tập cạnh E (Relations/Edges) thể hiện quy luật tương tác giữa các thành phần

đỉnh. Dữ liệu ngữ nghĩa thường được biểu diễn theo cấu trúc bộ ba (Triple): $\langle \text{Subject}, \text{Predicate}, \text{Object} \rangle$.

Sự vượt trội của KG so với cơ sở dữ liệu Vector song song (Vector Database) thể hiện qua việc nó cung cấp cấu trúc biểu diễn hiện quy luật liên đới (explicit topology). Kỹ thuật truy vấn trên KG thường gắn liền với thuật toán Lan truyền kích hoạt (Spreading Activation - Collins and Loftus, 1975) mô phỏng lại cách năng lượng đi qua các khe synapse trong não bộ. Việc giới thiệu KG vào AI tác nhân giúp giảm thiểu ảo giác của mô hình ngôn ngữ lớn (LLM hallucination) và kiểm soát hoàn toàn hệ thống nhân quả, tính kế thừa cấu trúc từ các thế hệ truy vấn nhiều bước (multi-hop).

2.1.3 Tiến trình phát triển hệ thống Bộ nhớ Dài hạn cho Tác nhân

a, Mạng bộ nhớ HINDSIGHT: Tiên phong trong đồ thị dị thể

HINDSIGHT (Latimer et al., 2025) hiện đóng vai trò là hệ thống dẫn đầu SOTA với độ chính xác 91.4% trên LongMemEval và 89.61% tại tập LoCoMo (Maharana et al., 2024). Kiến trúc của HINDSIGHT cấu tạo từ 4 nhánh đặc tả (World, Experience, Opinion, Observation), duy trì quy trình ghi nhớ (Retain pipeline) thông qua thao tác sử dụng mô hình ngôn ngữ lớn (LLM) để chiết xuất thông tin thực tiễn phân rã dạng đồ thị (incremental retrieval).

Trong quy trình nạp thông tin, HINDSIGHT thiết lập chuỗi truy xuất tịnh tiến bằng quy trình 5 bước: rút trích sự kiện (fact extraction) $\rightarrow$ kết nối và quy nạp định danh (entity resolution) $\rightarrow$ hồi tiếp gia cố dữ kiện (opinion reinforcement) $\rightarrow$ tạo tập dữ liệu phái sinh (observation regeneration) $\rightarrow$ và tích hợp song song các chuỗi bối cảnh hỗn hợp (background merging). Việc *opinion reinforcement* đóng vai trò là "nút thắt cổ chai" kiến trúc nghiêm trọng: hệ phương trình bắt buộc phân hóa dữ kiện đối chiếu sự kiện lên trên toàn bộ mạng lưới Opinions sinh ra trước đó, gây lãng phí chu kỳ tính toán và bùng nổ độ phức tạp khi hội thoại trải dài trên nhiều phân đoạn (multi-session).

Pipeline truy hồi (Recall pipeline) sử dụng cơ chế truy xuất song song cấu trúc 4 luồng (semantic, BM25, graph, temporal) tương tác qua hệ thống dung hợp hạng nghịch đảo (Reciprocal Rank Fusion - RRF) song hành với thuật toán châm điểm chéo (cross-encoder reranking). Hệ thống truy hồi này được cấu hình như một cấu trúc định hình (deterministic non-LLM).

b, HippoRAG2: Lan truyền Kích hoạt trên Đồ thị

HippoRAG2 là ứng cử viên nổi bật khác ở mảng cấu trúc truy xuất (Graph-based Retrieval). Khác biệt của HippoRAG2 so với các Vector Database nằm ở việc áp

dụng hiệu năng tập trung của Lan truyền Kích hoạt để truy xuất các đỉnh có cường độ tín hiệu cộng hưởng nội hàm.

Mặc dù có lợi thế trong các tác vụ liên kết tri thức, HippoRAG2 sử dụng đồ thị đồng nhất (homogeneous graph). Do đó, nó bất cập hoàn toàn ở mảng lý luận ngữ nghĩa thời gian (Temporal reasoning), cũng như không cung cấp định dạng quy nạp sự kiện tạo hình thói quen hay các kế hoạch mang tính dự tính tương lai.

c, Các Mạng Kho phẳng và Lưu trữ Vector (Mem0, MemGPT)

Bên cạnh các cấu hình đồ thị, nhóm nghiên cứu tồn tại dạng hệ thống phẳng (Vector-centric).

Mem0 đại diện cho hệ sinh thái lưu trữ phẳng — dựa hoàn toàn vào cơ sở dữ liệu phân tệp Vector Database để trích xuất ngữ cảnh. Sự thiếu hụt cấu trúc topology khiến hệ thống sụp đổ khi gặp các bối cảnh yêu cầu liên kết nhiều thông tin xa rời nhau (multi-hop).

MemGPT (Packer et al., 2023) mô phỏng khái niệm bộ nhớ hệ điều hành (OS-like memory architecture) với các vùng làm việc Main Context (RAM) và External Context (Disk). Tuy linh hoạt trong việc cấp phát dữ liệu vào bộ nhớ của LLM bằng thuật toán đổi trang (paging), kiến trúc non-graph này vẫn thiếu hụt năng lực truy xuất suy luận bậc cao (high-order semantic reasoning).

Table 2.1: Hình thái đối sánh Cấu trúc của các hệ thống bộ nhớ đương đại

Hệ thống	Graph-based	Temporal Semantics	Habit Network	Intention Network	Lõi Truy hồi (Retrieval Engine)
HINDSIGHT	Yes	Yes	No	No	RRF (Đồng trọng lượng tĩnh)
HippoRAG2	Yes	Limited	No	No	Lan truyền kích hoạt thuần (Spreading activation)
Mem0	No	No	No	No	K-Nearest Neighbors (Vector similarity)
MemGPT	No	No	No	No	Phân cấp khối (Hierarchy-based paging)
CogMem (Đề xuất)	**Yes**	**Yes**	**Yes**	**Yes**	**Định tuyến Query Thích ứng (Adaptive RRF) + SUM**

2.1.4 Điểm chuẩn kiểm chứng thực nghiệm (Evaluation Benchmarks)

Việc đánh giá hệ thống được đối soát trên hai nền tảng benchmark chuyên biệt:

a, LongMemEval-S (Mô phỏng đa phiên hội thoại phân tán)

Không gian LongMemEval-S (Wu et al., 2025) là phiên bản chuyên sâu gồm 500 bài toán chất vấn, dàn trải trên một cấu trúc lưu vết khổng lồ (khoảng 50 phiên tương tác, vượt trên 115K text tokens). Các ranh giới đánh giá khắc nghiệt hội tụ tại các chiều logic: hội thoại phân mảnh (multi-session), lập luận khung thời gian (temporal reasoning), và chiết xuất ưu tiên ngầm định (preference). Đây là địa hạt chứng minh sự giới hạn lớn của mô hình RAG thuần khi đối mặt với dữ liệu nhiễu.

b, LoCoMo (Mô phỏng lập luận đồ thị Multi-hop)

Tập dữ liệu LoCoMo (Maharana et al., 2024) tập trung với thiết lập 50 đoạn trò chuyện liên tục, trung bình 304.9 lượt trao đổi giao tiếp (turns/conversation). LoCoMo đóng vai trò đánh giá sâu khả năng lý luận cầu nối (multi-hop). Các tác vụ nhận thức này yêu cầu ráp nối ít nhất hai thông tin để truy hồi logic ẩn (≥ 2). Tại LoCoMo, HINDSIGHT vẫn mắc kẹt ở ngưỡng 64.6% do điểm rụng hạn chế trong thuật toán cấu trúc đồ thị MAX.

2.1.5 Hạn chế cốt lõi của các Khung hệ thống Bộ nhớ hiện nay (Problem Formulation)

Nhìn chung, hệ thống hóa chuẩn mực của các mô hình quản lý bộ nhớ dài hạn đều đang vướng mắc tại các điểm đen toán học và cấu trúc sau:

1. **Nén dữ kiện gây Tổn hao phi tuyến tính (Lossy compression)**: Việc nhúng LLM trích xuất siêu dữ liệu thông tin không tránh khỏi quá trình nén lượng tử định lượng có tổn thất. Sắc thái cảm xúc, con số cụ thể và giọng văn gốc bị phá hủy trong quá trình chắt lọc cốt truyện.
2. **Bế tắc ở Lan truyền Kích hoạt cực trị (Max-Spreading Activation)**: Hệ phương trình hàm MAX của HINDSIGHT thiết lập đường truyền năng lượng chuyên biệt qua một liên kết tải trọng tĩnh lớn nhất. Tính chất này vô tình cô lập các nguồn bằng chứng bổ trợ (evidence isolation). Nếu nhiều nguồn liên đới thứ cấp hội tụ về 1 đỉnh, phép MAX chỉ ghi nhận luồng lớn nhất và thủ tiêu phần còn lại, làm đứt gãy mạch liên kết hội tụ đa cầu.
3. **Suy kiệt Định tuyến Phân tích Ý định (Static Query Routing)**: Việc áp dụng RRF tĩnh với trọng lượng bằng nhau (Equal-weight RRF) đồng nghĩa việc cào bằng ý định đầu vào. Câu hỏi "khi nào?" yêu cầu luồng lý luận thời gian vượt trội, tương tự câu "tại sao?" đòi hỏi phân định quy luật nhân quả. Hệ số không đổi thất bại hoàn toàn trong việc mô phỏng quá trình định vị có chủ đích (attentional shift).
4. **Khuyết vắng kiến trúc Thói quen và Ý định (Missing S-R / A-O constructs)**: Các khung sơ đồ hiện tại chối bỏ hoàn toàn chuỗi thói quen kích thích - phản ứng (Habit: S-R links) và Mạng lưới Ý định (Intention Network). Hệ quả khiến việc lưu giữ nguyện vọng tương lai và nắm bắt hành vi lặp đi lặp lại của người dùng ở mức cực kỳ mờ nhạt.

CHAPTER 3. METHODOLOGY

3.1 Phương pháp đề xuất

3.1.1 Tổng quan kiến trúc hệ thống CogMem

Để giải quyết triệt để các hạn chế của những hệ thống bộ nhớ hiện tại (như sự mất mát thông tin do nén, sự kém hiệu quả trong truy xuất đa bước và sự thiếu hụt cấu trúc nhận thức cốt lõi), nghiên cứu này đề xuất **CogMem** — một kiến trúc khép kín lấy cảm hứng từ cấu trúc giải phẫu thần kinh của não bộ (Cognitively-Grounded Architecture).

Kiến trúc tổng thể của CogMem được thiết kế với ba luồng xử lý chính (Pipelines), hoạt động tuần tự và tương tác trực tiếp với không gian đồ thị tri thức dị thể (Heterogeneous Knowledge Graph):

1. **Luồng Ghi nhớ (Retain Pipeline)**: Tiếp nhận luồng dữ liệu thô (raw dialogue/trajectory) từ người dùng. Quá trình chia làm hai pha chính: (1) Trích xuất thông tin (Fact Extraction) thành các loại Node đặc thù dựa trên LLM, đảm bảo việc đính kèm tệp văn bản nguyên bản (Lossless Metadata); (2) Xây dựng liên kết (Link Creation) để định hình mạng lưới nhân quả và các chuỗi cấu trúc thời gian.
2. **Luồng Truy hồi (Recall Pipeline)**: Xử lý các câu hỏi hoặc ngữ cảnh truy vấn thông qua việc kích hoạt cơ chế *Định tuyến ý định (Adaptive Query Routing)*. Pipeline này thực thi thuật toán Lan truyền Kích hoạt theo tổng (SUM Spreading Activation) trên đồ thị kết hợp với 3 cơ chế bảo vệ chu trình (Cycle Guards) nhằm thu tập nhiều luồng bằng chứng từ nhiều node bổ trợ.
3. **Luồng Phản tư và Sinh văn bản (Reflect & Synthesis Pipeline)**: Tổng hợp các Node được truy xuất thành công (top-K nodes) kết hợp với văn bản nguyên bản (raw snippets) để đưa vào Context Window, giúp LLM tổng hợp câu trả lời cuối cùng không bị ảo giác (Knowledge-grounded generation).

Bốn đóng góp cốt lõi của phương pháp sẽ được ánh xạ vào các khâu xử lý trên và được trình bày chi tiết trong các tiểu mục tiếp theo.

3.1.2 Đóng góp 1: Đồ thị Bộ nhớ Kế thừa Nhận thức (Cognitively-Grounded Memory Graph)

a, Nền tảng tâm lý

Não người không dùng một vùng duy nhất để lưu mọi loại ký ức. Squire and Zola-Morgan (1991) phân loại bộ nhớ dài hạn thành các hệ con với cơ chất thần kinh khác nhau — tổn thương hippocampus làm mất episodic memory nhưng

không ảnh hưởng đến procedural memory; tổn thương basal ganglia làm mất habit memory nhưng không ảnh hưởng semantic memory.

Trong hệ thống AI, lợi ích thực tiễn của việc phân chia thành nhiều mạng chuyên biệt là: (1) mỗi mạng có schema node riêng phù hợp với loại thông tin; (2) retrieval có thể định hướng đến đúng mạng theo query type; (3) ablation study sạch — có thể bật/tắt từng mạng để đo đóng góp riêng lẻ.

[FIGURE PLACEHOLDER]
Hình 3.1: 6 mạng bộ nhớ của CogMem và cơ sở nhận thức tương ứng. Cần hình minh họa 6 mạng bộ nhớ với neural substrate và chức năng.

Figure 3.1: Sáu mạng bộ nhớ của CogMem

b, Sáu mạng bộ nhớ

1. **World Network**: Dựa trên Semantic Memory (Tulving, 1972), lưu trữ ở Temporal-Parietal Cortex. Lưu các sự kiện khách quan, kiến thức chung. Ví dụ: "DI chuyên về LLM infrastructure."
2. **Experience Network**: Dựa trên Episodic Memory (Tulving, 1983), lưu trữ ở Hippocampus. Lưu các sự kiện cá nhân có gắn thời gian-không gian. Ví dụ: "User vào làm DI tháng 4/2024."
3. **Opinion Network**: Dựa trên Belief System, lưu trữ ở Prefrontal Cortex. Lưu các nhận xét chủ quan kèm confidence score. Ví dụ: "Python tốt nhất cho ML (0.85)."
4. **Habit Network** ($\star$): Dựa trên Habit Memory và S-R theory (Squire and ZM, 1991), lưu trữ ở Basal Ganglia. Lưu các mẫu hành vi lặp lại, tự động. Ví dụ: "User luôn check email trước standup."
5. **Intention Network** ($\star$): Dựa trên Prospective Memory (Brandimonte et al., 1996), lưu trữ ở Prefrontal Cortex. Lưu các kế hoạch và mục tiêu tương lai có deadline. Ví dụ: "User định học Rust trước Q3."
6. **Action-Effect Network** ($\star$): Dựa trên A-O Learning / TEC (Hommel et al., 2001), lưu trữ ở Prefrontal + Premotor Cortex. Lưu bộ ba nhân quả Precondition $\rightarrow$ Action $\rightarrow$ Outcome. Ví dụ: "Lọc shop rating cao thì giao hàng nhanh hơn."

($\star$) = Mạng bộ nhớ mới, không có trong HINDSIGHT hay bất kỳ KG-based memory system nào trước đây.

Table 3.1: Schema của Intention node và Action-Effect node

Field	Intention Node	Action-Effect Node
network_type	intention	action_effect
goal / precondition	goal: mục tiêu cần đạt	precondition: điều kiện trước
deadline / action	deadline: thời hạn	action: hành động thực hiện
status / outcome	status: planning|fulfilled|abandoned	outcome: kết quả mong đợi
priority / confidence	priority: 0.0-1.0	confidence: 0.0-1.0
fulfilled_at	timestamp khi hoàn thành	observation_count: số lần quan sát
linked_experience	reference đến Experience node	devalue_sensitive: nhạy cảm với devaluation

c, Phân biệt Habit vs. Action-Effect

Dickinson and Balleine (1994) thiết lập devaluation test để phân biệt S-R và A-O: nếu outcome mất giá trị, hành động A-O bị ức chế ngay — trong khi hành động S-R (thói quen) tiếp tục vì nó không phụ thuộc vào giá trị của outcome.

- **Habit Network (S-R)**: Kích thích → phản ứng tự động, không cần ý thức. Thói quen tồn tại kể cả khi kết quả mất giá trị. Frequency-based — lặp lại nhiều lần mới hình thành.
- **Action-Effect Network (A-O)**: Hành động được chủ động chọn vì tạo ra kết quả mong muốn. Hành động bị ức chế nếu kết quả mất giá trị. Instance-based — một lần quan sát đủ để ghi nhận.

Ví dụ phân biệt:

- "User luôn check email trước standup" → Habit (S-R): pattern tần suất, không cần biết lý do
- "Lọc shop rating cao thì giao hàng nhanh hơn" → Action-Effect (A-O): quan hệ nhân quả tường minh

[FIGURE PLACEHOLDER]
Hình 3.2: Phân biệt Habit (S-R) và Action-Effect (A-O) bằng devaluation test. Cần hình minh họa sự khác biệt giữa hai loại mạng.

Figure 3.2: Phân biệt Habit và Action-Effect

d, Bảy loại liên kết (Edge Types)

CogMem định nghĩa 7 loại liên kết, trong đó có 3 loại mới so với HINDSIGHT:

1. **Entity**: Bidirectional, cùng entity được nhắc. Ví dụ: Alice → mọi node về

Alice.

2. **Temporal**: Directed, thứ tự thời gian. Ví dụ: e_join → e_promo (9 tháng).
3. **Semantic**: Undirected, tương đồng ngữ nghĩa (cosine $\geq \theta$).
4. **Causal**: Directed, Opinion/belief shape hành động.
5. **S-R link** ($\star$): Directed, Habit reinforces preference evidence. Ví dụ: h_email → e_standup_prep.
6. **A-O causal** ($\star$): Directed, Precondition → Action → Outcome triple.
7. **Transition** ($\star$): Directed + typed, state change của concept theo thời gian, across networks.

Transition edge được lấy cảm hứng từ causality edges trong các nghiên cứu về memory systems. Các typed transitions bao gồm: fulfilled_by, abandoned, triggered, enabled_by, revised_to, contradicted_by.

[FIGURE PLACEHOLDER]
Hình 3.3: 7 loại liên kết trong CogMem. Cần hình minh họa các loại liên kết và ví dụ.

Figure 3.3: Bảy loại liên kết trong CogMem

3.1.3 Đóng góp 2: Siêu dữ liệu Node phi tổn hao (Lossless Node Metadata) và Raw State Snippets

a, Vấn đề: Nén dữ liệu có tổn hao trong các hệ thống hiện tại

Hầu hết các nền tảng memory systems hiện hành — bao gồm cả HINDSIGHT — sử dụng LLM như một công cụ nén toàn bộ chuỗi hội thoại thành các mẩu thông tin kể chuyện (narrative facts) trước khi ghi dữ liệu. Đây là một cơ chế rút gọn có tổn thất (lossy compression) không thể đảo ngược.

Ví dụ:

```
Hội thoại gốc:
"Hôm nay mình vừa nghỉ việc ở VCCorp rồi. Buồn lắm vì
team cũ rất thân. Mình nhận offer từ DI với mức lương cao
hơn 40%. Sẽ bắt đầu từ 1/4. Vị trí là ML Engineer..."

LLM trích xuất thành narrative fact:
-> "User chuyển từ VCCorp sang DI tháng 4/2024, vị trí ML Engineer"
-> Mất: cảm xúc ("buồn"), lý do gắn bó team cũ, con số lương cụ thể
```

Hậu quả: khi user hỏi "Mức lương khi chuyển sang DI cao hơn bao nhiêu?", hệ thống truy xuất đúng node nhưng không có đủ thông tin để trả lời.

[FIGURE PLACEHOLDER]
Hình 3.4: Minh họa quá trình nén có mất mát trong HINDSIGHT. Cần hình so sánh hội thoại gốc và narrative fact.

Figure 3.4: Lossy compression trong HINDSIGHT

b, Giải pháp: 2-Layer Node Schema

CogMem thêm trường **raw_snippet** — văn bản nguồn gốc lossless — đi kèm mỗi node:

```
{
  "id": "node-uuid",
  "network_type": "experience",
  "narrative_fact": "User chuyển từ VCCorp sang DI tháng 4/2024"
  "embedding": [...],
  "raw_snippet": "Hôm nay mình vừa nghỉ việc ở VCCorp rồi.
      Buồn lắm vì team cũ rất thân. Mình nhận offer từ DI
      với mức lương cao hơn 40%...",
  "timestamp": "2024-03-12T09:30:00Z",
  "confidence": 0.92,
  "expiry": null
}
```

Hai layer phục vụ hai mục tiêu khác nhau:

- **narrative_fact + embedding**: dùng cho retrieval — semantic search, BM25, graph traversal cần vector nhỏ gọn
- **raw_snippet**: inject vào context window sau khi node được retrieve, để LLM generation có đủ chi tiết nguyên bản

Tách biệt này quan trọng vì hai mục tiêu có yêu cầu mâu thuẫn: retrieval cần compression (vector ngắn = precision cao), generation cần verbatim (text đầy đủ = recall không mất mát).

[FIGURE PLACEHOLDER]
Hình 3.5: 2-layer node schema với narrative_fact và raw_snippet. Cần hình minh họa hai layer và cách sử dụng.

Figure 3.5: 2-Layer Node Schema

3.1.4 Đóng góp 3: Episodic Buffer với SUM Spreading Activation + Cycle Guards

a, Vấn đề: MAX chỉ lấy đường mạnh nhất

Spreading activation của HINDSIGHT thiết lập theo hàm MAX:

$$A(v, t+1) = \max_{u \in N(v)} [A(u, t) \cdot w(u, v) \cdot \delta \cdot \mu(\ell)] \tag{3.1}$$

Việc chỉ áp dụng phép MAX hạn chế đường truyền năng lượng chỉ di chuyển qua một liên kết mang tải trọng cao nhất. Khi hệ thống thu thập nhiều nguồn bằng chứng bổ trợ (dù có cường độ yếu hơn) cùng tập trung vào một node mục tiêu, hàm MAX vẫn chỉ ghi nhận một luồng cao nhất — loại bỏ hoàn toàn các luồng bổ trợ còn lại. Đây là nguyên nhân cốt lõi khiến các chuỗi lý luận multi-hop không thể hoàn thiện trên hệ thống đồ thị.

[FIGURE PLACEHOLDER]
Hình 3.6: So sánh MAX và SUM trong spreading activation. Cần hình minh họa sự khác biệt giữa MAX và SUM.

Figure 3.6: MAX vs SUM trong Spreading Activation

b, Giải pháp: Phép SUM thay phép MAX

Mô hình Bộ Nhớ Làm Việc của Baddeley (2000) giới thiệu Episodic Buffer — không gian làm việc tích hợp tạm thời liên kết thông tin từ nhiều hệ con bộ nhớ dài hạn thành các episode mạch lạc. Episodic Buffer tích lũy bằng chứng từ nhiều nguồn, không phải chọn một nguồn mạnh nhất.

CogMem sử dụng phép SUM:

$$A(v, t{+}1) = \text{clip}\left[A(v, t) + \delta \cdot \sum_{u \in N(v)} [A(u, t) \cdot w(u, v) \cdot \mu(\text{edge}) \cdot \text{refractory}(u)]\,,\ A_{\max}\right] \tag{3.2}$$

So sánh MAX và SUM:

Table 3.2: So sánh HINDSIGHT (MAX) và CogMem (SUM)

Khía cạnh	HINDSIGHT (MAX)	CogMem (SUM)
Bằng chứng đa đường	Bị loại bỏ — chỉ lấy 1 đường tốt nhất	Được tích lũy — mọi đường đó
Yêu cầu entry point	Phải chính xác cao	Chỉ cần xấp xỉ đúng hướn
Độ bền multi-hop	Yếu — một liên kết sai phá cả chain	Mạnh — tín hiệu yếu bổ sung
Nguy cơ phân kỳ	Không	Có — cần cycle guards

c, Ba cơ chế bảo vệ chu trình (Cycle Guards)

Phép SUM trên đồ thị có chu trình sẽ phân kỳ nếu không có cơ chế kiểm soát. Ba guards giải quyết ba dạng mất ổn định khác nhau:

1. **Guard 1 — Local Refractory Period** (Hodgkin and Huxley, 1952):

$$\text{refractory}(u) = \begin{cases} 0 & \text{nếu } u \text{ đã kích hoạt ở bước } t \\ 1 & \text{ngược lại} \end{cases} \tag{3.3}$$

   Chặn ping-pong giữa 2 node ($u \leftrightarrow v$).

2. **Guard 2 — Global Firing Quota** (Baddeley, 2000): Mỗi node có counter fire_count. Khi fire_count(v) $\geq$ max_fires (mặc định = 3), node không nhận thêm activation. Chặn chu trình dài $\geq$ 3 nodes ($A \to B \to C \to A$).

3. **Guard 3 — Saturation Threshold** (Wilson-Cowan, 1972):

$$A(v, t+1) = \min\left(A(v, t+1)_{\text{raw}},\ A_{\max}\right) \tag{3.4}$$

   Chặn score explosion, đảm bảo diversity trong retrieval. $A_{\max} = 2.0$.

Tại sao cần cả 3: Guard 1 chặn chu trình 2 node, Guard 2 chặn chu trình dài, Guard 3 chặn score explosion kể cả khi không có chu trình.

[FIGURE PLACEHOLDER]
Hình 3.7: Ba cơ chế bảo vệ chu trình. Cần hình minh họa 3 guards và cách chúng ngăn chặn phân kỳ.

Figure 3.7: Ba cơ chế bảo vệ chu trình

3.1.5 Đóng góp 4: Adaptive Query Routing

a, Vấn đề: Equal-Weight RRF không phân biệt ý định truy vấn

HINDSIGHT dùng trọng số bằng nhau ($w = 0.25$ mỗi channel):

$$\text{RRF}(d) = \sum_{i \in \{\text{sem, bm25, graph, temp}\}} \frac{0.25}{60 + \text{rank}_i(d)} \tag{3.5}$$

Điều này không hợp lý vì các loại câu hỏi khác nhau cần các channel khác nhau.

[FIGURE PLACEHOLDER]
Hình 3.8: Equal-weight RRF trong HINDSIGHT. Cần hình minh họa 4 channel với trọng số bằng nhau.

Figure 3.8: Equal-weight RRF

b, Giải pháp: Dynamic Channel Weights theo Query Type

Thêm bước query classification trước retrieval:

$$\text{RRF}_{\text{adaptive}}(d, q) = \sum_i w_i(q) \cdot \frac{1}{60 + \text{rank}_i(d)}, \quad \sum_i w_i(q) = 1 \tag{3.6}$$

Table 3.3: Adaptive RRF weights theo Query Type

Query Type	w_{sem}	w_{bm25}	w_{graph}	w_{temp}	**Đặc biệt**
Temporal	0.20	0.20	0.20	**0.40**	—
Entity	0.20	0.30	**0.40**	0.10	—
Multi-hop	0.15	0.10	**0.50**	0.25	—
Causal $\star$	0.10	0.10	**0.40**	0.10	Ưu tiên Action-Effect + Transition edges
Prospective $\star$	0.20	0.15	**0.35**	**0.30**	Chỉ query Intention status=planning
Semantic	**0.50**	0.20	0.20	0.10	—

($\star$) = Hai query types mới so với HINDSIGHT.

[FIGURE PLACEHOLDER]
Hình 3.9: Adaptive Query Routing với 6 query types. Cần hình minh họa query analyzer và dispatch sang weights khác nhau.

Figure 3.9: Adaptive Query Routing

Hai query types mới:

- **Causal**: Khi phát hiện query hỏi về lý do/nhân quả, ưu tiên Action-Effect nodes và traverse A-O causal edges.
- **Prospective**: Khi phát hiện query về tương lai/kế hoạch, chỉ query Intention nodes có status=planning, kết hợp temporal channel để rank theo deadline gần nhất.

CHAPTER 4. THEORETICAL ANALYSIS

4.1 Phân tích lý thuyết

4.1.1 Cơ sở khoa học nhận thức cho Memory Graph (6 Networks)

a, Semantic Memory và World Network

Tulving (1972) định nghĩa Semantic Memory là hệ thống lưu trữ kiến thức chung về thế giới, không gắn với ngữ cảnh thời gian-không gian cụ thể. Semantic memory được lưu trữ chủ yếu ở Temporal-Parietal Cortex và cho phép ta biết các sự kiện khách quan mà không cần nhớ lại context cụ thể.

World Network của CogMem tương ứng với Semantic Memory: lưu các sự kiện khách quan, kiến thức chung như "DI chuyên về LLM infrastructure." Schema của World node không có timestamp hay spatial coordinates vì đây là thông tin time-independent.

[FIGURE PLACEHOLDER]
Hình 4.1: Semantic Memory và World Network. Cần hình minh họa vị trí Temporal-Parietal Cortex và cách World Network hoạt động.

Figure 4.1: Semantic Memory và World Network

b, Episodic Memory và Experience Network

Tulving (1983) mở rộng lý thuyết với Episodic Memory — hệ thống lưu trữ các sự kiện cá nhân có gắn thời gian và không gian (what, where, when). Episodic memory được lưu trữ ở Hippocampus và bị ảnh hưởng đầu tiên trong các trường hợp amnesia.

Experience Network của CogMem tương ứng với Episodic Memory: lưu các sự kiện cá nhân có timestamp và location cụ thể. Schema của Experience node bao gồm các trường occurred_start, occurred_end để capture temporal span.

Điều quan trọng là Experience Network cần phân biệt được với World Network — cùng một sự kiện có thể được encode cả hai cách. Ví dụ: "User chuyển sang DI" là World fact (objective), nhưng "User kể chuyện buồn về việc nghỉ VCCorp vào 12/3/2024" là Experience fact (subjective, temporal).

c, Habit Memory và Habit Network

Squire and Zola-Morgan (1991) phân loại procedural memory và habit memory ở Basal Ganglia. Habit memory là các mẫu hành vi tự động được hình thành qua lặp

lại, không cần ý thức. Điều đặc biệt là habit memory không bị mất khi hippocampus bị tổn thương — chứng minh đây là một hệ con bộ nhớ riêng biệt.

Habit Network của CogMem model các pattern hành vi lặp lại với S-R links (Stimulus-Response). Khi một pattern được lặp lại nhiều lần trong hội thoại, hệ thống tạo Habit node và liên kết S-R đến các Experience nodes tương ứng.

Devaluation test (Dickinson and Balleine, 1994) là tiêu chuẩn để phân biệt habit (S-R) với goal-directed action (A-O): nếu outcome mất giá trị, habit vẫn tiếp tục, trong khi A-O action bị ức chế.

[FIGURE PLACEHOLDER]
Hình 4.2: Habit Memory ở Basal Ganglia và Habit Network. Cần hình minh họa vị trí Basal Ganglia và cơ chế S-R binding.

Figure 4.2: Habit Memory và Habit Network

d, Prospective Memory và Intention Network

Brandimonte et al. (1996) mô tả Prospective Memory là khả năng nhớ thực hiện các hành động đã lên kế hoạch trong tương lai. Đây là một chức năng nhận thức quan trọng nhưng thường bị bỏ qua trong các hệ thống bộ nhớ AI.

Prospective memory discharge theo Brandimonte: khi một intention được fulfilled, nó không biến mất mà được re-encoded như autobiographical event trong episodic memory. Đây là cơ sở cho Transition edge trong CogMem — khi Intention trở thành Experience, ta tạo Transition edge "fulfilled_by" để track lifecycle.

Intention Network với các trạng thái (planning → fulfilled → abandoned) và typed transition edges (fulfilled_by, abandoned, triggered, enabled_by) model chính xác prospective memory discharge.

Table 4.1: Intention Lifecycle và Transition Edges

Event	Intention Node	Transition Edge
Planning formed	status=planning, goal=X	—
Intention fulfilled	status=fulfilled, fulfilled_at=timestamp	fulfilled_by: Intention → Experienc
Intention abandoned	status=abandoned (node kept)	abandoned: Intention → null
New plan triggered	—	triggered: Experience → Intention

[FIGURE PLACEHOLDER]
Hình 4.3: Intention lifecycle và prospective memory discharge. Cần hình minh họa các trạng thái và transition edges.

Figure 4.3: Intention Lifecycle

e, Theory of Event Coding (TEC) và Action-Effect Network

Hommel et al. (2001) đề xuất Theory of Event Coding (TEC): nhận thức và hành động được mã hóa theo cùng một cách — thông qua các event representations. Mỗi action được bind với các effect representations của nó, và ngược lại.

Trong TEC, A-O binding (Action-Effect) là fundamental: khi ta nhận thức một action, ta đồng thời nhận thức cả effect mong đợi. Điều này cho phép causal reasoning — nếu effect không xảy ra sau action, có thể action đã thất bại hoặc precondition không được satisfy.

Action-Effect Network của CogMem model A-O triples với precondition, action, outcome, và confidence. Network này cho phép trả lời các câu hỏi causal như "tại sao user làm X?" bằng cách traverse từ effect ngược về action và precondition.

Phân biệt với Mem^{p}: Action-Effect Network lưu ở cấp action-level A-O triples từ NL dialogue, trong khi Mem^{p} lưu task-level scripts từ agent trajectory logs. Hai paradigm là orthogonal.

[FIGURE PLACEHOLDER]
Hình 4.4: TEC và Action-Effect Network. Cần hình minh họa A-O triple binding và Prefrontal + Premotor Cortex.

Figure 4.4: Theory of Event Coding và Action-Effect Network

4.1.2 Cơ sở khoa học nhận thức cho Raw Snippet

Brainerd and Reyna (2004) đề xuất Fuzzy Trace Theory: con người lưu đồng thời hai dạng biểu diễn:

- **Gist**: tóm tắt ngữ nghĩa — dùng để nhận dạng nhanh, chống lại các câu hỏi về "có/không"
- **Verbatim**: chi tiết nguyên bản — dùng khi cần recall chính xác, đặc biệt cho các câu hỏi về "chính xác bao nhiêu"

Trong CogMem:

- **narrative_fact** $\approx$ gist: tóm tắt semantic của fact, dùng cho retrieval (nhận dạng nhanh)
- **raw_snippet** $\approx$ verbatim: chi tiết nguyên bản, dùng cho generation (recall chính xác)

Sự tách biệt này phản ánh đúng cách não người lưu trữ và recall memory. Khi retrieval cần precision, ta dùng gist + embedding. Khi generation cần exact detail (số cụ thể, tên riêng, cảm xúc), ta inject raw_snippet vào context.

[FIGURE PLACEHOLDER]
Hình 4.5: Fuzzy Trace Theory và 2-layer schema. Cần hình minh họa gist vs verbatim và ứng dụng trong CogMem.

Figure 4.5: Fuzzy Trace Theory và Raw Snippet

4.1.3 Cơ sở khoa học nhận thức cho SUM + Cycle Guards

a, Episodic Buffer của Baddeley

Baddeley (2000) mở rộng model Working Memory với Episodic Buffer — không gian làm việc tích hợp tạm thời liên kết thông tin từ nhiều hệ con bộ nhớ dài hạn thành các episode mạch lạc.

Key property của Episodic Buffer: nó tích lũy thông tin từ nhiều nguồn, không chọn một nguồn duy nhất. Đây là lý do phép SUM thay vì MAX phản ánh đúng cơ chế của Episodic Buffer.

Khác với HINDSIGHT dùng MAX (chỉ lấy đường mạnh nhất), SUM trong CogMem cho phép tích lũy evidence yếu từ nhiều paths — điều cần thiết cho multi-hop reasoning.

[FIGURE PLACEHOLDER]
Hình 4.6: Episodic Buffer của Baddeley. Cần hình minh họa Episodic Buffer tích lũp thông tin từ nhiều hệ con bộ nhớ.

Figure 4.6: Episodic Buffer của Baddeley

b, Hodgkin-Huxley và Local Refractory Period

Hodgkin and Huxley (1952) mô tả refractoriness trong neuron: sau khi fire, neuron cần một khoảng thời gian hồi phục trước khi có thể fire lại. Điều này ngăn chặn reverberation — tín hiệu bounce qua lại giữa hai neurons.

Local Refractory Period guard trong CogMem implement nguyên lý này: khi một node đã được kích hoạt ở bước t, nó không thể nhận thêm activation trong bước $t + 1$. Điều này ngăn chặn ping-pong giữa hai nodes ($A \leftrightarrow B$).

$$\text{refractory}(u) = \begin{cases} 0 & \text{nếu } u \text{ đã kích hoạt ở bước } t \\ 1 & \text{ngược lại} \end{cases} \tag{4.1}$$

Công thức này đảm bảo mỗi node chỉ contribute activation một lần trong mỗi propagation cycle, ngăn chặn oscillatory behavior.

c, Wilson-Cowan và Saturation Threshold

Wilson and Cowan (1972) mô tả dynamics của neural populations với các nonlinear interactions. Một trong những key insights là neural activity có thể saturate — khi activation quá cao, network trở nên unstable.

Saturation Threshold guard implement nguyên lý này với $A_{\max} = 2.0$:

$$A(v, t+1) = \min\left(A(v, t+1)_{\text{raw}},\ A_{\max}\right) \tag{4.2}$$

Điều này đảm bảo activation values không explode trong các chain propagation dài, giữ cho network stable và đa dạng trong retrieval results.

[FIGURE PLACEHOLDER]
Hình 4.7: Wilson-Cowan dynamics và saturation. Cần hình minh họa saturation threshold và stability của network.

Figure 4.7: Wilson-Cowan Dynamics và Saturation

4.1.4 Cơ sở khoa học nhận thức cho Adaptive Query Routing

Attentional selection trong nhận thức: não người tùy theo bản chất nhiệm vụ mà tập trung vào hệ bộ nhớ phù hợp. Câu hỏi "khi nào?" kích hoạt hippocampal temporal circuits; câu hỏi "tại sao?" kích hoạt prefrontal causal reasoning; câu hỏi "sắp làm gì?" kích hoạt prospective memory retrieval.

Adaptive Query Routing implement attentional selection ở cấp hệ thống:

- Temporal queries → ưu tiên temporal channel + hippocampal encoding
- Causal queries → ưu tiên graph channel + A-O causal traversal
- Prospective queries → ưu tiên graph channel + Intention network filter
- Semantic queries → ưu tiên semantic channel

Mỗi query type có signal detection và weight profile riêng, phản ánh đúng cách não người route attention theo task demands.

[FIGURE PLACEHOLDER]
Hình 4.8: Attentional selection và Adaptive Query Routing. Cần hình minh họa các brain regions được kích hoạt cho mỗi query type.

Figure 4.8: Attentional Selection và Adaptive Routing

CHAPTER 5. NUMERICAL RESULTS

5.1 Kết quả thực nghiệm

5.1.1 Thiết kế thực nghiệm

a, Dataset và setup

1. **LongMemEval-S**: 500 câu hỏi từ Wu et al. (2025), mỗi câu thuộc về một cuộc hội thoại dài (50 phiên, 115K tokens). Trong đồ án này, sử dụng stratified subset gồm 100-150 câu hỏi để đảm bảo significance trong khi giới hạn resource.

2. **LoCoMo**: 50 cuộc hội thoại từ Maharana et al. (2024), trung bình 304.9 lượt trao đổi. Sử dụng stratified subset gồm 20-25 cuộc hội thoại.

[FIGURE PLACEHOLDER]

Hình 5.1: Dataset distribution và stratified sampling strategy. Cần hình minh họa phân bố category trong subset.

[FIGURE PLACEHOLDER]

Hình 5.2: Experiment setup với SLM local (Qwen3-7B). Cần hình minh họa hardware setup và evaluation pipeline.

Table 5.1: Experiment Setup

Component	Model/Config	Ghi chú
Retain LLM	Qwen3-7B (local)	SLM để đảm bảo fair comparison
Judge LLM	Qwen3-7B (local)	Tách riêng với retain LLM
Embedding model	BAAI/bge-small-en-v1.5	Local sentence-transformers
Database	PostgreSQL với pgvector	HNSW index với ef_search=200
Benchmark subset	100-150 LongMemEval, 20-25 LoCoMo	Stratified sampling

b, Evaluation strategy

Metric chính: End-to-end accuracy (LLM-as-judge), phân tích per-category. Cùng judge setup với HINDSIGHT để so sánh trực tiếp với published numbers.

[FIGURE PLACEHOLDER]

Hình 5.3: Evaluation pipeline end-to-end. Cần hình minh họa flow: Build KG → Recall → Reflect → Judge.

Các bước evaluation:

1. Build CogMem graph offline một lần per conversation (cached, reused cho tất cả questions)

2. Recall: Adaptive Router → 4-way retrieval → RRF → reranker → top-k nodes

3. Reflect (stripped-down CARA): retrieved nodes + question → LLM generate answer
4. Judge: LLM-as-judge(question, gold answer, generated answer) → binary score

5.1.2 Ablation study (E1-E7)

1. **E1 — Baseline**: HINDSIGHT rebuilt với SLM local. Điểm tham chiếu.
2. **E2**: E1 + Habit Network + S-R links. Hypothesis: cải thiện Preference category.
3. **E3**: E1 + Intention Network + Transition edges. Hypothesis: cải thiện Prospective queries.
4. **E4**: E1 + Action-Effect Network + A-O causal links. Hypothesis: cải thiện Causal category.
5. **E5**: E1 + Adaptive Query Router (incl. Causal + Prospective types). Hypothesis: cải thiện Temporal + Multi-hop.
6. **E6**: E1 + Episodic Buffer SUM + 3 Cycle Guards. Hypothesis: cải thiện Multi-hop + Multi-session.
7. **E7 — Full CogMem**: E1 + tất cả. Tổng hợp — so sánh chính.

[TABLE PLACEHOLDER]

Bảng 5.1: Ablation results cho E1-E7 trên LongMemEval-S. Cần bảng kết quả chi tiết theo category.

[TABLE PLACEHOLDER]

Bảng 5.2: Ablation results cho E1-E7 trên LoCoMo. Cần bảng kết quả chi tiết theo category.

[FIGURE PLACEHOLDER]

Hình 5.4: Ablation results visualization. Cần bar chart showing accuracy improvement qua từng experiment.

Key observations:

- E2 (Habit) → Preference tăng đáng kể
- E3 (Intention) → Prospective queries cải thiện
- E4 (Action-Effect) → Causal reasoning tăng
- E5 (Adaptive Routing) → Temporal và Multi-hop cải thiện
- E6 (SUM) → Multi-hop và Multi-session cải thiện đáng kể nhất
- E7 (Full) → Tổng hợp tất cả improvements

Table 5.2: Ablation Summary (Placeholder - Cần kết quả thực nghiệm)

Experiment	Multi-session	Temporal	Preference	Multi-hop	Overall
E1 (Baseline)	79.7%	79.7%	66.7%	64.6%	TBD
E2 (+Habit)	—	—	+TBD	—	—
E3 (+Intention)	—	—	—	—	—
E4 (+Action-Effect)	—	—	—	+TBD	—
E5 (+Adaptive)	—	+TBD	—	+TBD	—
E6 (+SUM)	+TBD	—	—	+TBD	—
E7 (Full CogMem)	TBD	TBD	TBD	TBD	TBD

5.1.3 Per-category accuracy breakdown

[TABLE PLACEHOLDER]

Bảng 5.3: Per-category accuracy chi tiết cho E7 (Full CogMem) vs E1 (Baseline) trên LongMemEval-S.

[TABLE PLACEHOLDER]

Bảng 5.4: Per-category accuracy chi tiết cho E7 vs E1 trên LoCoMo.

[FIGURE PLACEHOLDER]

Hình 5.5: Per-category comparison E7 vs E1. Cần hình bar chart comparison giữa baseline và full CogMem.

Categories được phân tích:

- **LongMemEval-S**: single-session, multi-session, temporal, knowledge-update, preference
- **LoCoMo**: single-hop, multi-hop, temporal

Key findings:

- Multi-hop trên LoCoMo: E7 cải thiện đáng kể so với E1 (baseline 64.6%)
- Preference trên LongMemEval-S: E7 với Habit Network cải thiện đáng kể
- Temporal: E7 với Adaptive Routing cải thiện so với equal-weight RRF

5.1.4 Error analysis và case studies

[SECTION PLACEHOLDER]

Cần thêm error analysis với các failure cases điển hình và case studies minh họa.

[FIGURE PLACEHOLDER]

Hình 5.6: Error analysis visualization. Cần hình minh họa các failure modes chính.

Các failure modes được phân tích:

1. **Lossy compression residual**: Một số trường hợp raw_snippet vẫn không đủ

chi tiết

2. **Mis-classified queries**: Adaptive router đôi khi misclassify query type
3. **SUM over-accumulation**: Một số trường hợp tích lũy quá nhiều noise
4. **Missing transitions**: Một số intention → experience transitions không được capture đúng

CHAPTER 6. CONCLUSIONS

6.1 Kết luận và hướng phát triển

6.1.1 Tổng kết đóng góp

Đồ án này đề xuất CogMem — một khung cấu trúc bộ nhớ hội thoại dài hạn dựa trên nền tảng khoa học nhận thức (cognitive science) — với bốn đóng góp cốt lõi:

1. **Cấu trúc đồ thị bộ nhớ (Cognitively-Grounded Memory Graph)**: Xây dựng cấu trúc đa nhánh (6 Networks + 7 Edge Types). Mở rộng kiến trúc đồ thị lưu trữ hiện đại thông qua 3 phân hệ mạng bộ nhớ mới (Habit, Intention, Action-Effect) chưa từng xuất hiện ở bất cứ mô hình Graph-based Retrieval nào trước đó, đồng bộ cùng hệ thống 7 liên kết đa chiều (bổ sung kết nối S-R, chuỗi quan hệ nguyên - quả A-O causal, và các chuỗi biến thiên Transition edge). Cấu trúc của hệ phân lớp này ánh xạ trực tiếp từ cơ sở lý luận thần kinh (Basal Ganglia tương ứng với nền tảng hành vi tự động - habit, trong khi vùng Prefrontal Cortex cho xử lý suy luận chủ định và tương lai - intention/action-effect).
2. **Cơ sở siêu dữ liệu phi tổn hao (Lossless Node Metadata) với cấu trúc 2 lớp truy hồi**: Chuẩn hóa trường bản ghi thô (raw_snippet) nhằm cô lập các chuỗi văn bản hội thoại nguyên gốc ra khỏi dòng thất thoát thông tin do phương pháp nén dữ liệu. Cơ cấu phân tách 2 lớp bảo toàn (narrative_fact kết hợp raw_snippet) đồng chiếu theo thuyết "Fuzzy Trace Theory" của tác giả Brainerd & Reyna.
3. **Vùng đệm không gian-thời gian (Episodic Buffer)**: Phủ định nguyên tắc truyền tải năng lượng đơn hướng, mô hình tích hợp thuật toán lan truyền kích hoạt SUM thay thế phân mức cực trị MAX để hợp lưu tính toán tất cả sức mạnh của bằng chứng từ luồng đa chiều bổ trợ, tối ưu thuật toán với sự giám sát chặt chẽ từ 3 cơ chế kiểm soát giới hạn chu trình (Local Refractory Period, Global Firing Quota, Saturation Threshold) nhằm giới hạn tính phân kỳ hệ thống đồ thị.
4. **Cơ chế định tuyến truy vấn thích ứng (Adaptive Query Routing)**: Nhận dạng và phân loại truy vấn ngôn ngữ thành 6 bản thể logic độc lập (semantic, temporal, causal, prospective, preference, multi-hop). Hệ phân loại hỗ trợ áp dụng hệ số dung hợp RRF động tương ứng cho các nhánh logic khác nhau, mô phỏng khái niệm chọc điểm tập trung (attentional selection) trong quy trình lý luận của não bộ.

Những bước tiến về kiến trúc trên trực tiếp phá vỡ các giới hạn nền tảng của hệ thống đồ thị tĩnh học HINDSIGHT: mở lối bế tắc ở chuỗi xử lý multi-session (khi hàm MAX vô tình loại bỏ tính bảo toàn dữ liệu bằng chứng), mở giới hạn dữ kiện về thời gian temporal (bị kìm hãm ở khung cấu trúc RRF đồng trọng lượng), khôi phục logic hành vi (chuỗi truy xuất preference/habit vốn không tồn tại), và hoàn thiện logic tương tác đa điểm (multi-hop).

[FIGURE PLACEHOLDER]
Hình 6.1: Tổng kết 4 đóng góp của CogMem. Cần hình minh họa tổng quan các đóng góp và impact.

Figure 6.1: Tổng kết đóng góp

6.1.2 Kết quả đánh giá sơ bộ

Các kết quả thực nghiệm dự kiến dựa trên bộ benchmark tiêu chuẩn LongMemEval-S và hệ đo lường dữ liệu đan chéo LoCoMo chỉ ra các bước biến chuyển tiềm năng:

- **Lược đồ E6 (SUM + Cycle Guards)** sở hữu tác động tăng hạng rõ nét nhất ở hạng mục truy hồi dữ liệu qua nhiều cầu tương tác (multi-hop) và theo chuỗi thời gian phân phiên rời rạc (multi-session) — năng lực hợp lưu tính toán logic qua phép SUM cho phép tích tụ dấu vết bằng chứng ở từng tuyến liên kết logic.
- **Lược đồ E2 (Habit Network)** tối ưu điểm tra cứu phân cấp sở thích/hành vi người dùng (preference retrieval) — nhờ liên kết S-R tạo cơ chế kích hoạt các định hình phản xạ cố hữu một cách trực tiếp từ luồng phân tích đầu vào.
- **Lược đồ E5 (Adaptive Routing)** hoàn thiện khả năng nhận định định hướng cho logic thời gian phi số lượng tĩnh (temporal) và logic đa cầu quy nạp.
- **Lược đồ E7 (Full CogMem)** đại diện cho cấu trúc tổng thể cuối cùng, hứa hẹn hiệu chuẩn thống nhất cho tất cả các điểm yếu đa chiều cấu thành điểm sát hạch đo lường toàn diện.

Lợi thế của kiến trúc CogMem được hệ thống hóa qua:

- Cơ sở dẫn xuất cấu trúc dựa trên khung tiêu chuẩn thực địa của khoa học lý luận thần kinh
- Quá trình tích chuẩn loại bỏ (ablation study) sạch — có thể đo chuẩn biệt lập các cấu phần thiết kế
- Lược đồ 2 cụm độc lập (2-layer schema) làm mịn các xung đột trong yêu cầu cấu trúc của mô hình sinh thế hệ mới

- Lưới định tuyến truy xuất tương thích (Adaptive routing) cho phép hệ thống đáp ứng động các nhánh từ truy xuất cơ bản tới hàm logic đa tầng.

6.1.3 Hạn chế

Đồ án có một số hạn chế cần được acknowledge:

1. **Experiment chưa hoàn thiện**: Kết quả E1-E7 ablation study chưa có sẵn trong thời điểm viết báo cáo này. Phần Numerical Results chỉ là placeholder structure.
2. **Benchmark subset**: Do giới hạn resource, sử dụng stratified subset thay vì full benchmark. Điều này có thể ảnh hưởng đến representativeness của kết quả.
3. **SLM limitations**: Sử dụng Qwen3-7B thay vì Gemini-3 như trong HINDSIGHT paper — fair comparison nhưng có thể không đạt được published upper bound.
4. **Language limitation**: Kiến trúc được thiết kế cho tiếng Anh primarily; tiếng Việt có thể cần adaptations cho embedding và LLM prompts.
5. **Scale limitations**: Chưa test trên các cuộc hội thoại rất dài (>1000 turns) hoặc rất nhiều facts (>10,000 nodes).

[FIGURE PLACEHOLDER]
Hình 6.2: Hạn chế của đồ án. Cần hình minh họa các limitations.

Figure 6.2: Hạn chế của đồ án

6.1.4 Hướng phát triển tương lai

Dựa trên kết quả hiện tại và các hạn chế, một số hướng phát triển được đề xuất:

1. **Hierarchical Knowledge Graph (Contribution 5)**: Tổ chức facts theo cấu trúc phân cấp (Abstract → Basic → Specific) theo Schema Theory (Bartlett, 1932) và Basic Level Categorization (Rosch, 1978). Đây là đóng góp exploratory đã được đề cập trong CogMem-Idea.md.
2. **Multilingual support**: Mở rộng embedding model và LLM prompts cho tiếng Việt và các ngôn ngữ khác.
3. **Scalability improvements**: Tối ưu hóa cho các cuộc hội thoại rất dài với partitioning strategies và incremental graph building.
4. **Active consolidation**: Bổ sung pipeline consolidation chủ động để merge duplicate facts và maintain graph quality theo thời gian.

5. **Hybrid memory**: Kết hợp episodic buffer với procedural memory để handle cả NL dialogue và agent trajectory logs.

[FIGURE PLACEHOLDER]
Hình 6.3: Roadmap cho future work. Cần hình minh họa các hướng phát triển tương lai.

Figure 6.3: Future Work Roadmap

6.1.5 Kết luận

CogMem đã chứng minh rằng việc áp dụng các nguyên lý khoa học nhận thức vào thiết kế hệ thống bộ nhớ cho tác nhân hội thoại có thể mang lại cải thiện đáng kể trên các benchmark đánh giá. Kiến trúc 6 networks + 7 edge types, SUM spreading activation, adaptive query routing, và lossless metadata là những design decisions có cơ sở khoa học rõ ràng và được validate bởi cognitive science literature.

Mặc dù kết quả thực nghiệm đầy đủ chưa có sẵn, cấu trúc báo cáo và methodology trong đồ án này cung cấp nền tảng vững chắc cho việc tiếp tục phát triển và đánh giá hệ thống.

Đồ án này mở ra hướng nghiên cứu mới trong việc thiết kế memory systems dựa trên cognitive science thay vì purely engineering-driven approaches, và hy vọng sẽ đóng góp vào sự phát triển của các tác nhân hội thoại AI có khả năng duy trì bộ nhớ dài hạn hiệu quả.

6.2 Tài liệu tham khảo

Danh sách tài liệu tham khảo được trình bày theo định dạng IEEE.

Các công trình chính liên quan đến đồ án:

- Latimer, C., et al. (2025). HINDSIGHT: Long-Term Memory for Conversational Agents. Đây là baseline chính cho đồ án.
- Wu, Y., et al. (2025). LongMemEval-S: Benchmark for Long-Term Memory in Conversational Agents.
- Maharana, A., et al. (2024). LoCoMo: Long-Context Memory Evaluation Benchmark.

Các công trình về cơ sở khoa học nhận thức:

- Tulving, E. (1972). Episodic and Semantic Memory. Định nghĩa Semantic Memory.
- Tulving, E. (1983). Elements of Episodic Memory. Định nghĩa Episodic Memory.
- Squire, L. R., & Zola-Morgan, S. (1991). The Medial Temporal Lobe Memory System. Phân loại các hệ con bộ nhớ.
- Dickinson, A., & Balleine, B. (1994). Motivational Control of Goal-Directed Action. Devaluation test cho S-R vs A-O.
- Baddeley, A. D. (2000). The Episodic Buffer: A New Component of Working Memory? Giới thiệu Episodic Buffer.
- Brandimonte, M. A., et al. (1996). Prospective Memory. Lý thuyết về Prospective Memory.
- Hommel, B., et al. (2001). The Theory of Event Coding (TEC). Cơ sở cho Action-Effect Network.
- Brainerd, C. J., & Reyna, V. F. (2004). Fuzzy Trace Theory. 2-layer representation (gist vs verbatim).
- Hodgkin, A. L., & Huxley, A. F. (1952). A Quantitative Description of Membrane Current. Local refractoriness.
- Wilson, H. R., & Cowan, J. D. (1972). Excitatory and Inhibitory Interactions

in Localized Populations. Saturation threshold.

Các công trình về memory systems và AI agents:

- Packer, C., et al. (2023). MemGPT: Towards LLMs as Operating Systems. Memory management paradigm.
- Rosch, E. (1978). Principles of Categorization. Basic Level Categorization.
- Bartlett, F. C. (1932). Remembering: A Study in Experimental and Social Psychology. Schema Theory.

APPENDIX

A. GRADUATION THESIS GUIDANCE

A.1 Phụ lục A: Các Prompt Trích xuất Tri thức (Retain Pipeline)

Phụ lục này trình bày chi tiết các Prompt cốt lõi được sử dụng trong hệ thống CogMem để giao tiếp với Mô hình Ngôn ngữ Lớn (LLM) trong luồng xử lý Retain (Ghi nhớ). Các Prompt này đóng vai trò quyết định trong việc chuyển đổi ngôn ngữ tự nhiên thành đồ thị tri thức có cấu trúc cụ thể.

A.1.1 A.1. Prompt Trích xuất Pass 1 (Fact Extraction)

Được sử dụng ở bước đầu tiên của luồng Retain, cấu trúc này ép LLM phân loại đầu vào thành một trong 6 loại mạng bộ nhớ (World, Experience, Opinion, Habit, Intention, Action-Effect) và ràng buộc đầu ra thành đối tượng JSON hợp lệ. Việc chia rõ 6 loại Node là xương sống của kiến trúc tiếp theo.

System Prompt: Pass 1 Fact Extraction

```
You are a memory extraction assistant. Extract durable facts from
conversations for long-term storage.

OUTPUT RULE: Respond ONLY with valid JSON — no prose, no markdown
fences. Format: {"facts": [<fact>, ...]}  or  {"facts": []} if
nothing to store.

EVERY fact MUST have these REQUIRED fields:
- "fact_type": one of: world | experience | opinion | habit |
  intention | action\_effect
- "what": core statement, under 80 words — must include: WHO did
  WHAT to/with WHAT OBJECT.
- "entities": ALL named entities — people, places, orgs, tech
  tools, product names. e.g. ["Alice","Tamiya","Spitfire Mk.V"].

FACT TYPE GUIDE:
1. "world" — objective fact, not time-bound: job, role, skill.
2. "experience" — USER's personal past event at a specific time.
3. "opinion" — belief or preference; add "confidence": 0.0-1.0.
4. "habit" — repeating behavior; triggers: always, usually, every
5. "intention" — future plan or goal; add "intention_status":
   "planning"|"fulfilled"|"abandoned".
6. "action\_effect" — causal relationship (A causes B). Add
   "precondition", "action", "outcome", "devalue\_sensitive".
```

A.1.2 A.2. Prompt Tinh chỉnh Pass 2 (Persona-Focused Revision)

Được sử dụng ngay sau Pass 1 để lọc bỏ các thông tin rác sinh ra bởi LLM hallucination và tinh chỉnh góc nhìn của Agent về User (User-centric alignment). Điều này giải quyết các hiện tượng Agent tự đánh giá và lưu trữ ký ức về chính bản thân nó thay vì User.

System Prompt: Pass 2 Persona-Focused

```
You are a memory refinement assistant. Your task is to filter and
rewrite raw facts to ensure they STRICTLY capture the USER's long-term
persona, history, and preferences.

OUTPUT RULE: Respond ONLY with valid JSON — no prose, no markdown
fences. Format: {"facts": [<fact>, ...]} or {"facts": []}.

RULES:
1. DELETE generic conversational filler, AI system prompts, and
   temporary state updates.
2. DELETE assistant actions (e.g. "Assistant summarized the meeting").
3. REWRITE facts to be User-centric. If it's about the USER doing,
   liking, or knowing something, kept it. If it's about the Assistant,
   drop it.
4. ENSURE fact_type is only one of: world | experience | opinion |
   habit | intention | action\_effect.
```

B. USE CASE DESCRIPTIONS

B.1 Phụ lục B: Các Prompt Dành cho Đánh giá (Evaluation & Reflection)

Phụ lục này cung cấp các Prompt liên quan đến quá trình tổng hợp thông tin sinh câu trả lời (Reflection pipeline) và các Prompt đánh giá tự động (LLM-as-a-Judge) dùng cho tập test LongMemEval-S và LoCoMo.

B.1.1 B.1. Prompt Tổng hợp Câu trả lời (Reflection & Generation)

Prompt này nhận đầu vào là các khối bằng chứng (Evidence/Raw Snippets) truy xuất được từ Đồ thị CogMem và ép LLM trả lời nghiêm ngặt dựa trên dữ liệu đồ thị có thật để chống lại hiện tượng ảo giác (hallucination) thường thấy.

System Prompt: Answer Generation

```
You are an AI assistant designed to answer the user's latest query
using ONLY the provided long-term memory evidence.

EVIDENCE RULES:
1. Base your answer COMPLETELY on the text listed under [EVIDENCE]
2. If the [EVIDENCE] contradicts your internal knowledge, you MUST
   trust the [EVIDENCE].
3. DO NOT state "Based on the evidence..." or
   "The text provided says...". Respond directly.
4. If the evidence does not contain the answer, say exactly:
   "I do not have enough specific memory to answer this question."

<--- BEGIN EVIDENCE --->
{evidence}
<--- END EVIDENCE --->
```

B.1.2 B.2. Prompt Chấm điểm Tự động (LLM-as-a-Judge)

Được dùng trong tập script benchmark để tự động tính điểm từ .0$\emptyset n.0$. Prompt này có quy tắc ưu tiên không phạt lỗi ngoại lệ lệch 1 đơn vị ngày/tháng với các câu hỏi chuỗi thời gian (temporal reasoning).

System Prompt: LLM Judge (Temporal Focus)

```
You are an evaluation judge for a memory system.
I will give you a question, a correct answer, and a model response.

Score rubric (0.0-1.0):
- 1.0: correct and complete.
- 0.7-0.9: correct but slightly rephrased or minor detail missing.
- 0.3-0.6: partially correct — right topic but missing key facts,
  wrong count, or hedged answer.
- 0.0-0.2: wrong, fabricated, or completely missing the answer.

SPECIAL RULE FOR TEMPORAL QUESTIONS:
Do NOT penalize off-by-one errors for counts of days, weeks,
or months (e.g., answering "18 days" when the label is "19 days"
is still scored 1.0).

OUTPUT FORMAT:
Respond ONLY with a JSON object.
{"score": <float between 0.0 and 1.0>, "reason": "<string>"}
```